

УДК 004.934, 004.85

Мультизадачный анализ музыкальных композиций с помощью предобученного аудио-трансформера

Антонов М. Е.

Тверской государственный университет

Представил доцент кафедры информационных технологий

М. Ю. Кудряшов

АННОТАЦИЯ. Реализована мультизадачная модель на основе предобученного Audio Spectrogram Transformer с общим стволом и четырьмя классификационными головами: сегментация структуры, классификация возбуждения и валентности, определение жанра. Обучение проведено на датасетах DEAM, Harmonix Set и GTZAN методом Round-Robin.

КЛЮЧЕВЫЕ СЛОВА: глубокое обучение, мультизадачное обучение, Audio Spectrogram Transformer, музыкальный информационный поиск, классификация аудио.

Введение

Музыкальный информационный поиск (MIR) объединяет ряд задач: определение жанра трека, оценку его эмоционального содержания, выделение структурных секций (вступление, куплет, припев и т. д.). На практике каждая из них решается отдельной моделью, что требует независимого хранения весов и игнорирует общую акустическую природу входных данных. Парадигма мультизадачного обучения [2] позволяет обойти это ограничение за счёт совместного использования общего ствола сети.

В области аудиоанализа стандартом сегодня являются модели на основе механизма самовнимания [3]; одной из наиболее успешных среди них является Audio Spectrogram Transformer (AST) [1] — адаптация Vision Transformer для спектрограммного представления звука, предобученная на датасете AudioSet (около 2 млн размеченных аудиоклипов). В настоящей работе AST используется как общий

ствол мультизадачной модели, поверх которого размещены четыре классификационные головы.

1. Архитектура модели

Входной аудиосигнал длительностью 10 с с частотой дискретизации 22,05 кГц преобразуется в лог-мел-спектрограмму размера $128 \times T$, где 128 — количество мел-фильтров, T — число временных кадров. Спектрограмма разбивается на патчи 16×16 , проецируемые линейным слоем в 768-мерное пространство; к полученной последовательности добавляются обучаемый служебный токен CLS и позиционные эмбединги.

Последовательность обрабатывается стеком из 12 блоков трансформера; каждый блок содержит многоголовое самовнимание (12 голов) и полносвязную сеть с расширением до 3072 нейронов. Веса первых 8 блоков инициализируются из AST, предобученного на AudioSet, и остаются замороженными. Последние 4 блока дообучаются на целевых данных, что помогает избежать катастрофического забывания признаков, выученных на AudioSet. Применяется дифференциальная скорость обучения: $5 \cdot 10^{-5}$ для бэббона и 10^{-3} для голов.

С выхода последнего блока берётся эмбединг CLS-токена ($\mathbb{R}^{768}$), агрегирующий информацию о всём фрагменте, и подаётся в общий полносвязный слой $768 \rightarrow 256$; затем результат поступает на четыре независимые головы. Общее число параметров — 87 млн, из них 14 млн обучаемые (4 блока трансформера + общий слой + головы). Схема приведена на рис. 1.

2. Мультизадачное обучение

Каждая из четырёх голов — линейный слой $256 \rightarrow K_i$ с последующей функцией SOFTMAX; число классов K_i для каждой задачи приведено в табл. 1.

Частная функция потерь $\mathcal{L}_i$ для каждой задачи — взвешенная кросс-энтропия со сглаживанием меток ($\varepsilon = 0,1$); веса классов обратно пропорциональны их частотам в обучающей выборке, что компенсирует дисбаланс (особенно выраженный для сегментации, где Verse




Рис. 1. Архитектура мультизадачной модели на основе AST.

Таблица 1. Классификационные головы модели.

Задача	K	Классы
Сегментация структуры	6	Intro, Verse, Bridge, Chorus, Instrumental, O
Возбуждение (arousal)	3	low, mid, high
Валентность (valence)	3	negative, neutral, positive
Жанр	10	blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, rock

и Chorus встречаются в 3–5 раз чаще Bridge и Outro). Совокупная функция потерь:

$$\mathcal{L} = \sum_{i=1}^4 \lambda_i \mathcal{L}_i,$$

где $\lambda_{\text{seg}} = 1,5$, $\lambda_i = 1,0$ для остальных задач (значения подобраны по валидационной выборке).

Используемые датасеты содержат метки только для одной из задач: DEAM — эмоции, Harmonix Set — структура, GTZAN — жанр. Поэтому применяется стратегия Round-Robin: батч на каждом шаге обучения формируется только из одного датасета, потеря вычисляется только по активным головам. Общий ствол модели при этом поочерёдно получает градиенты от всех задач, реализуя жёсткое разделение параметров (*hard parameter sharing*).

3. Эксперименты и результаты

Обучающая выборка составлена из трёх открытых датасетов: DEAM (1802 трека с непрерывными аннотациями возбуждения и валентности), Harmonix Set (743 трека с разметкой структуры) и GTZAN (999 треков с разметкой по 10 жанрам). Совокупный объём данных — 3544 трека. Окна длительностью 10 секунд извлекаются с шагом 1 секунда, что даёт около 176 000 обучающих примеров.

Обучение проводилось в течение 8 эпох с использованием оптимизатора AdamW и планировщика COSINEANNEALING WARMRESTARTS. Размер эффективного батча — 64 (16 примеров с накоплением градиента за 4 шага). Применялась аугментация SpecAugment — маскирование случайных частотных и временных полос лог-мел-спектрограммы.

Результаты на тестовой выборке приведены в табл. 2.

На задаче определения жанра модель выходит на уровень, сопоставимый с однозадачными моделями для GTZAN (82,7 % против 85–90 % у SOTA). Возбуждение и валентность — 65,9 % и 55,9 % соответственно при базовой линии 33,3 %; разница между ними отражает известную в литературе большую субъективность разметки валентности. Сегментация (31,4 % при базовой 16,7 %) остаётся наиболее сложной задачей: помимо дисбаланса классов, на качество

Таблица 2. Метрики качества предложенной модели.

Задача	Ассурасу	Макро-F1	Случайная базовая
Сегментация (6 классов)	31,4 %	31,5 %	16,7 %
Возбуждение (3 класса)	65,9 %	65,3 %	33,3 %
Валентность (3 класса)	55,9 %	56,0 %	33,3 %
Жанр (10 классов)	82,7 %	81,9 %	10,0 %

влияет неоднозначность ручной разметки границ секций (расхождения между аннотаторами в Harmonix Set достигают ± 3 с).

Заключение

Реализована мультизадачная модель на основе предобученного AST с общим стволом и четырьмя классификационными головами. Round-Robin-обучение на трёх датасетах с непересекающимися наборами меток позволило получить рабочее качество по всем четырём задачам в рамках одной модели в 87 млн параметров: 82,7 % для жанра, 65,9 % и 55,9 % для возбуждения и валентности, 31,4 % F1 для сегментации.

Дальнейшие шаги: добавление регрессионных голов для непрерывных шкал возбуждения и валентности; постобработка предсказаний сегмента (декодирование Витерби с позиционными априорными вероятностями); расширение набора задач — определение темпа и тональности.

Список литературы

- [1] Gong, Y. AST: Audio Spectrogram Transformer / Y. Gong, Y.-A. Chung, J. Glass // Proceedings of Interspeech. — 2021. — P. 571–575. — DOI: <https://doi.org/10.21437/Interspeech.2021-698>
- [2] Ruder, S. An Overview of Multi-Task Learning in Deep Neural Networks // arXiv preprint. — 2017. — arXiv:1706.05098. — URL: <https://arxiv.org/abs/1706.05098>

- [3] Vaswani, A. Attention Is All You Need / A. Vaswani, N. Shazeer, N. Parmar [et al.] // Advances in Neural Information Processing Systems (NeurIPS). — 2017. — Vol. 30. — P. 5998–6008.

Библиографическая ссылка

Антонов, М. Е. Мультизадачный анализ музыкальных композиций с помощью предобученного аудио-трансформера // Студенческая конференция факультета ПМиК. Сборник трудов. — Тверь : ТвГУ, 2026. — С. 1–6.

Сведения об авторах

АНТОНОВ МИХАИЛ ЕВГЕНЬЕВИЧ

Студент магистратуры

Направление «Прикладная математика и информатика»