

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Тверской государственный университет»

Факультет прикладной математики и кибернетики

Направление 02.04.02 Фундаментальная информатика и
информационные технологии

Профиль «Информационные технологии в управлении и принятии
решений»

АВТОРЕФЕРАТ

выпускной квалификационной работы
(магистерской диссертации)

тема: **«Определение структурных сегментов и
эмоциональных характеристик музыкальных
композиций методами машинного обучения»**

Автор:

Антонов Михаил
Евгеньевич

Научный руководитель:

Кудряшов Максим
Юрьевич, кандидат
физико-математических
наук

Тверь — 2026

Актуальность

Объём музыкальных записей в стриминговых сервисах и цифровых архивах растёт быстрее, чем возможности их ручной разметки. Из-за этого автоматический анализ композиций, то есть выделение структурных секций, оценка эмоциональной окраски и определение жанра, выделился в самостоятельное направление области поиска музыкальной информации (Music Information Retrieval).

Обычно эти задачи решают порознь, обучая под каждую отдельную модель. Однако они опираются на общие свойства звука и содержательно связаны между собой: припев и куплет различаются по энергии и настроению, а смена секции часто совпадает со сменой эмоции. Это оправдывает мультизадачный подход, при котором один аудио-энкодер обслуживает сразу несколько классификационных голов. Совместное обучение даёт регуляризующий эффект, экономит вычисления при работе модели и позволяет анализировать трек согласованно по нескольким измерениям.

Цель работы

Разработка и экспериментальное исследование программного модуля автоматического анализа музыкальных композиций, выполняющего структурную сегментацию, оценку эмоциональных характеристик и жанровую классификацию аудиозаписей на основе мультизадачной модели глубокого обучения.

Задачи

Для достижения поставленной цели в работе решались следующие задачи:

- 1) Провести обзор области Music Information Retrieval и обосновать мультизадачный подход к объединению четырёх задач.
- 2) Подготовить обучающий корпус на основе трёх открытых датасетов (DEAM, Harmonix Set, GTZAN) с унифицированным пайплайном извлечения признаков.

посвящена экспериментам и сравнению конфигураций, шестая описывает веб-прототип, седьмая содержит анализ результатов и ограничений подхода. В заключении собраны основные выводы и направления дальнейшей работы.

Основные результаты

- 1) Обоснован мультизадачный подход к совместному решению задач структурной сегментации, оценки эмоциональных характеристик и классификации жанра.
- 2) Собран объединённый корпус из 3545 композиций на основе датасетов DEAM, Harmonix Set и GTZAN с единым конвейером извлечения признаков.
- 3) Реализованы и обучены пять архитектур; лучшей оказалась конфигурация на основе аудио-трансформера AST со средней точностью 58,5 % по четырём задачам.
- 4) Разработан декодер на основе алгоритма Витерби, повысивший граничную F1-меру сегментации на 14 процентных пунктов.
- 5) Построен веб-прототип с синхронизированным дашбордом для интерактивного анализа произвольных треков.
- 6) Определены ограничения подхода и намечены направления его дальнейшего развития.

Публикации автора по теме ВКР

Антонов М. Е. Мультизадачный анализ музыкальных композиций с помощью предобученного аудио-трансформера // Студенческая конференция факультета ПММК. Сборник трудов. — Тверь: ТвГУ, 2026. — С. 6–11.

- 3) Разработать и реализовать пять архитектур мультизадачных моделей: CNN, CNN + BiLSTM, PANNs + Linear, PANNs + BiLSTM и AST.
- 4) Выполнить экспериментальное сравнение пяти архитектур по четырём задачам на едином тестовом корпусе.
- 5) Реализовать постобработку сегментных предсказаний на базе декодера Витерби с музыкалогическими априорными распределениями.
- 6) Разработать веб-прототип для интерактивной демонстрации результатов.
- 7) Сформулировать ограничения подхода и направления дальнейшей работы.

Постановка задачи и данные

Система решает четыре задачи классификации, вычисляемые для каждого окна записи. Структурная сегментация относит окно к одной из шести секций: вступление, куплет, припев, мост, инструментальный фрагмент, концовка. Возбуждение и валентность по модели Рассела оцениваются по трём градациям каждая (низкая, средняя, высокая). Жанровая классификация работает с десятью категориями коллекции GTZAN.

Входом модели служит логарифмическая мел-спектрограмма со 128 частотными фильтрами, нарезанная на окна длиной 10 секунд с шагом 1 секунда. Обучающий материал собран из трёх открытых датасетов: DEAM с эмоциональными аннотациями, Harmonix Set со структурной разметкой (743 трека загружены с видеохостинга утилитой yt-dlp) и GTZAN с жанровыми метками. Объединённый корпус насчитывает 3545 композиций и 176 127 окон; разбиение на обучающую, валидационную и тестовую выборки в пропорции 70/15/15 выполнено на уровне треков, что исключает утечку данных между ними.

Мультизадачная модель и архитектуры

Модель состоит из общего аудио-энкодера и набора независимых голов: четырёх классификационных по числу задач и двух регрессионных для непрерывных значений возбуждения и валентности. Обучение ведётся в мультизадачном режиме с чередованием батчей из разных датасетов и суммарной функцией потерь

$$\mathcal{L} = \sum_t \lambda_t \mathcal{L}_t,$$

где $\mathcal{L}_t$ обозначает focal loss отдельной головы, а λ_t задаёт её вес. Дополнительно применяются сглаживание меток, аугментация SpecAugment, оптимизатор AdamW с расписанием скорости обучения OneCycle и обрезка нормы градиента.

Чтобы оценить вклад временного моделирования и предварительного обучения энкодера, реализованы и обучены пять архитектур:

- свёрточная сеть с блоками канального внимания, обрабатывающая каждое окно независимо (около 800 тысяч параметров);
- та же сеть с надстройкой двунаправленной LSTM, учитывающей соседние окна;
- линейный классификатор поверх замороженных эмбеддингов PANNs CNN14 размерности 2048;
- двунаправленная LSTM поверх тех же эмбеддингов;
- частично дообученный аудио-трансформер AST, предобученный на наборе AudioSet (14,4 млн обучаемых параметров из 87 млн).

Программная реализация

Модель и весь конвейер обработки оформлены в виде пакета musicml на языке Python с использованием библиотек PyTorch и librosa. Для наглядной демонстрации построен веб-прототип с трёхзвенной архитектурой: сервис инференса на FastAPI держит в памяти веса лучшей модели, серверная часть на Elysia поверх среды Bun управляет коллекцией

треков, а клиент на React выводит результат. Центральным элементом интерфейса служит синхронизированный дашборд из шести панелей с общим временным курсором, объединяющий структурную разметку, эмоциональные кривые, жанровое распределение и мел-спектрограмму.

Апробация и результаты

Проведены четыре последовательных эксперимента: базовый запуск, его улучшенная версия, расширение трансформером AST и отдельный неудачный запуск свёрточной сети с чрезмерным перевзвешиванием классов, зафиксированный как отрицательный результат. Лучшей по среднему качеству оказалась конфигурация на основе AST: средняя точность 58,5 % по четырём задачам, 40,6 % на структурной сегментации (на 5,3 процентного пункта выше лучшей свёрточной модели) и 81,5 % на классификации жанра. Победители по отдельным задачам распределились между AST (сегментация), связкой PANNs с двунаправленной LSTM (возбуждение и валентность) и свёрточной сетью (жанр); архитектуры, доминирующей сразу по всем задачам, выявить не удалось.

Для сегментных предсказаний разработан декодер на основе алгоритма Витерби. Он объединяет температурное масштабирование вероятностей, асимметричную матрицу переходов с музыкологическими априорными ограничениями, позиционные приоры для вступления и концовки и поклассовые ограничения минимальной длительности секции. Постобработка повышает граничную F1-меру с 0,31 до 0,45, то есть на 14 процентных пунктов, и сокращает среднее число выдаваемых секций с 28 до 7–8 на трёхминутный трек.

Структура работы

Работа состоит из введения, семи глав, заключения, списка литературы и приложений. Первая глава содержит обзор области и обоснование выбранного подхода. Вторая формализует постановку задачи. Третья глава описывает сбор данных и извлечение признаков, четвёртая представляет архитектуру модели и процедуру обучения. Пятая глава