




Что это. «Отпечаток» 10-секундного фрагмента: 768 чисел, в которые трансформер упаковал ВСЁ о звуке (тембр, ритм, гармонию, энергию).

Шаг 1: сжатие. Из 768 признаков оставляем 256 самых полезных — как ZIP-архивация.


Шаг 2: выравнивание. Все 256 признаков приводим к одному диапазону — как перевод валют в единую.

Шаг 3: отсечение. Всё отрицательное $\rightarrow 0$. Оставляем «положительные сигналы» — это фильтр, дающий нелинейность.

Шаг 4: регуляризация. Во время обучения случайно «выключаем» 30% признаков (белые клетки). Модель учится не полагаться на один признак.

Результат. 256-мерное «краткое описание» фрагмента. Его подают сразу ВСЕМ шести головам одновременно.

классификация
(argmax $\rightarrow$ ярлык)



регрессия
(прямое число)

Главная идея: 6 «экспертов» смотрят на одно и то же 256-мерное описание и каждый отвечает на свой вопрос — структура, эмоции, жанр. Поэтому модель называется мульти-задачной (multi-task).