

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Тверской государственный университет»

Факультет прикладной математики и кибернетики

Направление 09.04.03 Прикладная информатика

Профиль «Интеллектуальные системы. Теория и приложения»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ)

тема: «Определение структурных сегментов и
эмоциональных характеристик музыкальных
композиций методами машинного обучения»

Автор:

Антонов Михаил Евгеньевич

Подпись _____

ДОПУЩЕН К ЗАЩИТЕ

Руководитель ООП

С. М. Дудаков

Научный руководитель:

Кудряшов Максим Юрьевич,
кандидат

физико-математических наук,
доцент

Подпись _____

« ____ » _____ 20 ____ г.

Abstract

Structural Segmentation and Emotional Characterisation of Musical Compositions by Machine Learning Methods

by

Antonov Mikhail Evgenyevich

This master's thesis presents a software module for automatic multi-task analysis of musical recordings. For an input track the system produces a temporal timeline of structural segments (Intro, Verse, Chorus, Bridge, Instrumental, Outro), arousal/valence curves (Russell circumplex) and a top-3 genre prediction.

Five architectural configurations are developed and compared: a CNN per-window with Squeeze-and-Excitation attention, CNN + BiLSTM, a linear classifier and a BiLSTM over frozen PANNs embeddings, and a partially fine-tuned Audio Spectrogram Transformer (AST) pretrained on AudioSet. All are trained jointly on DEAM, Harmonix Set and GTZAN by a round-robin multi-task scheduler with focal loss and SpecAugment. Four sequential experiments (v1, v2, AST v2 extension and a negative-result CNN v3) yield AST v2 as the best overall configuration with average accuracy 58.5% and a 5.3-point gain on structural segmentation over the strongest CNN baseline. A post-processing pipeline based on Viterbi decoding with a musicological transition matrix, position priors and per-class minimum durations raises the boundary F1 of the structural segmentation by 14 points over the raw argmax baseline.

The work also delivers an interactive web prototype with a synchronised six-panel dashboard and a fullscreen Vibe Mode WebGL2 visualizer reactive to the audio spectrum.

Оглавление

Введение	4
Глава 1. Обзор предметной области	9
§ 1.1. Music Information Retrieval как научная дисциплина	9
§ 1.2. Структурная сегментация музыкальных композиций	9
§ 1.3. Распознавание эмоций в музыке	10
§ 1.4. Классификация жанров	11
§ 1.5. Архитектуры аудио-классификаторов	11
§ 1.6. Multi-task learning в MIR	12
§ 1.7. Pretraining + fine-tuning	12
Глава 2. Постановка задачи	13
§ 2.1. Цель исследования	13
§ 2.1.1. Формальная постановка	13
§ 2.2. Исследовательские вопросы	14
§ 2.3. Обоснование мульти-задачного подхода	14
Глава 3. Данные	16
§ 3.1. Используемые датасеты	17
§ 3.2. Извлечение признаков	18
§ 3.3. Стратегия разбиения train/val/test	19
§ 3.4. Дисбаланс классов	20
Глава 4. Архитектура и методы	21
§ 4.1. Обзор многоархитектурного эксперимента	21
§ 4.2. CNN backbone (конфигурация 1)	22
§ 4.3. CNN + BiLSTM (конфигурация 2)	22
§ 4.4. PANNs+Linear и PANNs+BiLSTM (конфигурации 3, 4)	22
§ 4.5. Audio Spectrogram Transformer v2 (конфигурация 5, финальная)	23
§ 4.6. Multi-task heads и функция потерь	24
§ 4.7. Post-processing pipeline	24
§ 4.7.1. Декодер v2: расширенный pipeline	25
§ 4.8. Inference и нормализация на пользовательских аудио	27
Глава 5. Эксперименты	28

§ 5.1. Протокол оценки	28
§ 5.2. Гиперпараметры обучения	28
§ 5.3. Эксперимент v1 (baseline-запуск)	29
§ 5.4. Эксперимент v2 (улучшенный запуск)	31
§ 5.5. Эксперимент AST v2 (расширение трансформер-архитектурой)	33
§ 5.6. Эксперимент CNN v3 (failed retrain)	34
§ 5.7. Сводная таблица всех моделей	34
§ 5.8. Ablation: вклад post-processing pipeline	35
Глава 6. Прототип системы	37
§ 6.1. Архитектура веб-приложения	37
§ 6.2. Синхронизированный дашборд	38
§ 6.2.1. Шесть аналитических панелей	39
§ 6.3. Ключевые UX-решения	40
§ 6.4. Технологический стек	40
§ 6.5. Визуальный редизайн и расширения интерфейса	41
Глава 7. Анализ результатов и ограничения	44
§ 7.1. Сводные ответы на исследовательские вопросы	44
§ 7.2. Финальная модель прототипа	45
§ 7.3. Ограничения текущего подхода	46
§ 7.4. Сравнение с state-of-the-art	47
§ 7.5. Научная новизна и практическая значимость	47
Заключение	48
Список литературы	51
Приложение А. Описание датасетов	55
Приложение Б. Гиперпараметры экспериментов	57
Приложение В. Confusion matrices и графики	58
Приложение Г. JSON-схема timeline	59
Приложение Д. CLI-команды воспроизведения	60

Введение

Актуальность

Spotify к 2024 году содержит более 100 миллионов композиций, мировой фонд пополняется со скоростью порядка 100 тыс. треков в сутки. На этом фоне возросла потребность в автоматической семантической разметке аудио (структура, эмоции, жанр), а большинство промышленных систем решают эти задачи раздельно. Настоящая работа исследует объединение четырёх задач в единой мульти-задачной модели с общим энкодером и четырьмя головами и предлагает интерактивный веб-прототип.

Обзор литературы

Предметная область опирается на обзорные работы по MIR [8] и применению глубокого обучения [1], на работы по структурной сегментации (SSM, глубокие модели, Harmonix Set), распознаванию эмоций (модель Рассела, DEAM) и жанровой классификации (GTZAN, PANNs [25], AST [14]). Эти источники служат для формирования гипотез и обоснования сравниваемых архитектур.

Цель и задачи

Цель работы. разработка и экспериментальное исследование программного модуля автоматического анализа музыкальных композиций, который по аудиозаписи восстанавливает структурную разметку во времени (вступление, куплет, припев, проигрыш, концовка), эмоциональную характеристику (valence/arousal в модели Рассела) и жанровую принадлежность на основе мульти-задачной модели глубокого обучения.

Задачи

- 1) Провести обзор области Music Information Retrieval и обосновать мульти-задачный подход к объединению четырёх задач (сегментация, arousal, valence, жанр).
- 2) Подготовить обучающий корпус на основе трёх открытых датасетов (DEAM, Harmonix Set, GTZAN) с унифицированным пайплайном извлечения признаков.
- 3) Разработать и реализовать пять архитектур мульти-задачных моделей — CNN, CNN + BiLSTM, PANNs + Linear, PANNs + BiLSTM, AST — для оценки вклада temporal modeling, pretraining и трансформерной парадигмы.
- 4) Выполнить экспериментальное сравнение пяти архитектур по четырём задачам на едином тестовом корпусе.
- 5) Реализовать пост-обработку сегментных предсказаний на базе декодера Витерби с музыкологическими априори.
- 6) Разработать веб-прототип для интерактивной демонстрации результатов.
- 7) Сформулировать ограничения подхода и направления дальнейшей работы.

Методы и средства

Методы цифровой обработки сигналов (STFT, мел-спектрограмма, chroma), машинного обучения (CNN, BiLSTM, SE, self-attention в AST с AudioSet-трансфером), регуляризации (SpecAugment, focal loss, label smoothing, mixup) и динамического программирования (декодер Витерби). Реализация — Python 3.12 + PyTorch + librosa + scikit-learn. Веб-прототип — React 19 + Vite, Elysia на Bun, FastAPI + PyTorch, WebGL2.

Основные результаты

- 1) Обзор 38 источников; обосновано применение общего аудио-энкодера с четырьмя классификационными головами.

- 2) Собран корпус 3545 композиций; реализован модуль musicml.features; разбиение без утечек по трекам; 176 127 окон 10 с с шагом 1 с.
- 3) Реализована CNN с SE-блоками (≈ 800 тыс. параметров), надстройки BiLSTM, линейный классификатор над PANNs и частично размороженный AST (14,4 млн trainable из 87 млн).
- 4) Четыре последовательных эксперимента (v1, v2, AST v2, negative-result CNN v3). Лучшая конфигурация — AST v2: среднее accuracy 58,5 %, сегмент 40,6 % (+5,3 п.п. к CNN), жанры 81,5 %.
- 5) Декодер v2 с temperature scaling, матрицей переходов, позиционными приорами и per-class min-duration повышает Boundary F1 на 14 пунктов относительно argmax.
- 6) Трёхзвенная система React 19 + Vite / Elysia (Bun) / FastAPI, дашборд из шести синхронизированных панелей, Vibe Mode (WebGL2-шейдер), ID3/YouTube-метаданные.
- 7) Ограничения: OOD на современной музыке, потолок per-window (~ 55 % сегмента), размер AST (574 МБ), отсутствие multi-label жанров. Направления: temporal-декодеры BiLSTM/CRF поверх AST-эмбеддингов, FMA/SALAMI, distillation, streaming.

Новизна

Научная новизна работы заключается в следующем.

- 1) Разработана мульти-задачная нейросетевая модель с единым аудио-энкодером и четырьмя классификационными головами, обучаемая одновременно на трёх разнородных датасетах (DEAM, Harmonix Set, GTZAN) по схеме round-robin.
- 2) Впервые, насколько известно автору, исследовано применение Audio Spectrogram Transformer, предобученного на AudioSet, к мульти-задачному музыкальному анализу; выполнено систематическое сравнение пяти конфигураций — CNN per-window, CNN + BiLSTM, PANNs + Linear, PANNs + BiLSTM и AST.
- 3) Предложен воспроизводимый pipeline кросс-датасетного обучения на трёх источниках с гетерогенной разметкой через RoundRobinLoader с покомпонентным взвешиванием потерь.

- 4) Предложен и количественно оценен составной пост-обработчик сегментных предсказаний (Витерби с temperature scaling, матрица переходов, позиционные приоры, покласово заданные min-duration), повышающий Boundary F1 на 14 пунктов и сокращающий число сегментов с 28 до 7,5. Дополнительно реализован интерактивный веб-прототип с шестипанельным дашбордом и WebGL2-визуализацией.

Апробация

Результаты апробированы на 41 аудиотреке различных жанров; для каждого модель сформировала структурную разметку, эмоциональные кривые и распределение жанров. Реализация оформлена в виде открытого репозитория с 128 автоматическими тестами.

Структура работы

Работа состоит из введения, семи глав, заключения, списка источников и приложения.

Глава 1 — обзор MIR и обоснование архитектур. Глава 2 — постановка задачи и исследовательские вопросы. Глава 3 — датасеты (DEAM, Harmonix, GTZAN) и предобработка. Глава 4 — пять архитектур и пост-обработчик Витерби. Глава 5 — четыре эксперимента и ablation. Глава 6 — веб-прототип с дашбордом и Vibe Mode. Глава 7 — обсуждение и сравнение со SOTA.

Список использованных источников содержит 38 наименований.

Глава 1

Обзор предметной области

§ 1.1. Music Information Retrieval как научная дисциплина

Music Information Retrieval (MIR) — междисциплинарная область, оформившаяся с учреждением конференции ISMIR в 2000 году [8]. Задачи MIR делятся на классификацию трека (жанр, настроение), покадровую разметку (onset, tempo, chord), сегментацию (MSA, emotion) и регрессию (arousal/valence). Настоящая работа решает три задачи покадровой разметки и одну track-level (жанр) в единой мульти-задачной модели.

Признаковое представление. Базовое представление — log-mel спектрограмма [29]: 128 мел-полос (30–11025 Гц при $sr=22050$ Гц), STFT window 2048, hop 512 (≈ 23 мс) [1; 25]. Альтернативы (chroma, MFCC, CQT) не вошли в финальную модель: вклад chroma ≤ 1 п.п.

§ 1.2. Структурная сегментация музыкальных композиций

Music Structure Analysis (MSA) — разбиение трека на смысловые фрагменты (Intro, Verse, Chorus, Bridge, Instrumental, Outro) на уровне boundary detection и section labeling. 6-классовая section labeling — одна из сложнейших задач MIR: различия Verse/Chorus определяются контекстом (повторяемость, динамика).

Классические подходы опираются на self-similarity matrix (SSM) [13]: novelty

curve [13], convex hull [36], spectral clustering [22]. Достигают F1 до 0.6–0.7 на SALAMI для boundary detection, но не решают section labeling.

Глубокое обучение доминирует с 2014 года:

- Ullrich et al., 2014 [35] — CNN-boundary detection, $F1 \approx 0.46$ на SALAMI (± 3 с);
- Serrà et al., 2018 [24] — CNN + HMM, роль temporal smoothing;
- Wang et al., 2022 [37] — Transformer над CNN, $F1 \approx 0.55$;
- Gong & Glass, 2023 [15] — AST-based, $F1 \approx 0.62$ на Harmonix.

Ограничения. Типичная ассурасу 6-классовой section labeling — 40–45% [15; 37]. Причины: class imbalance, inter-annotator disagreement (15% на границах, 25% на лейблах [7]), акустическая неразличимость Intro/Outro, domain shift. Современные решения применяют HMM или Viterbi с musicological priors [15; 24] (см. §4.7).

§ 1.3. Распознавание эмоций в музыке

Music Emotion Recognition (MER) формализуется двумя способами: дискретные категории [16] и Russell circumplex [26] — двумерное непрерывное пространство *valence* и *arousal* в $[-1, +1]$.

Таблица 1.1: Семантика квадрантов Russell circumplex

Квадрант	Valence	Arousal	Семантика
Q1	+	+	Радостное (joyful, exhilarating)
Q2	-	+	Злое, тревожное (angry, anxious)
Q3	-	-	Грустное (sad, melancholic)
Q4	+	-	Умиротворённое (peaceful, calm)

DEAM [2] предоставляет покадровые непрерывные A/V для 1802 фрагментов; inter-annotator Pearson $\rho \approx 0.55$ –0.65. В работе значения квантуются в 3 класса (Low/Mid/High, Dark/Neutral/Bright): снижает шум, упрощает сегментацию. Исходные значения сохраняются для 2D-визуализации (§6.2).

Подходы. CNN [6], CRNN [33], Transformer [38]. SOTA на DEAM (3-классовая): arousal 65–70%, valence 55–60%. Разрыв: arousal коррелирует со спектральными признаками, valence требует гармонического контекста.

§ 1.4. Классификация жанров

Genre classification начинается с Tzanetakis & Cook (2002) [34] и датасета GTZAN (1000 фрагментов, 10 жанров). Несмотря на известные ограничения [30], GTZAN остаётся референсным. Альтернативы: FMA [11], MagnaTagATune [10], MSD [32]. В работе выбран GTZAN ради сопоставимости; OOD адресуется через top-3 UI (§6.3).

Таблица 1.2: SOTA-результаты на GTZAN

Архитектура	Год	Ассурасу	Источник
MFCC + SVM	2002	61%	Tzanetakis [34]
CNN baseline	2015	75%	Sigtia [27]
CRNN	2017	79%	Choi [6]
Multi-DNN ensemble	2018	82%	Sturm [30]
PANNs (CNN14)	2020	87%	Kong [25]
AST	2021	89%	Gong [14]

В работе достигнуты 83.9% (CNN v2) и 81.5% (AST v2).

§ 1.5. Архитектуры аудио-классификаторов

CNN. Базовый блок Conv2D 3×3 + BN + ReLU + MaxPool, GAP в конце. $\sim 1\text{M}$ параметров, обучение 3–5 ч. Ограниченное receptive field (5–10 с), отсутствие pretraining. Baseline — 5 conv-блоков (32→512) с SE (§4.2).

Squeeze-and-Excitation (SE) [19] — channel attention: squeeze (GAP) → excitation (FC+sigmoid) → масштабирование. Прирост 1–3 п.п. при +5–10% параметров.

BiLSTM [17] — двунаправленная рекуррентная сеть поверх CNN-эмбеддингов. Учитывает долгосрочный контекст, но сокращает число обучающих примеров — риск переобучения. Применяется в CNN+BiLSTM и PANNs+BiLSTM (§5.4).

PANNs [25] — CNN14, предобучена на AudioSet; выдаёт 2048-мерный embedding на 1-секундное окно. Используется как замороженный feature extractor.

Audio Spectrogram Transformer (AST) [14] — ViT [3] над спектрограммой: log-mel $128 \times T$ в патчи 16×16 (overlap 6 px), 768-мерные токены, CLS + positional embeddings, 12-слойный Transformer (12 heads), классификация по CLS. $\sim 87\text{M}$ параметров; pretraining на AudioSet (MIT/ast-finetuned-audioset-10-10-0.4593). Глобальное восприятие и богатый transfer learning; checkpoint 574 MB vs 21 MB у CNN, inference $\sim 8\text{c}$ vs 2c . В работе AST применён с заморозкой первых 8 из 12 слоёв (§4.5).

§ 1.6. Multi-task learning в MIR

Multi-task learning (MTL) [5] — одна модель решает несколько связанных задач через общий backbone. В MIR задачи структуры, эмоций и жанра взаимосвязаны: жанр определяет структурные паттерны; эмоциональная динамика согласована со структурой. Общий backbone действует как регуляризатор. Технические подходы: joint loss $L = \sum w_i L_i$, round-robin batching, gradient surgery. В работе — round-robin loader и взвешенная сумма с фиксированными весами (segment: 1.5, остальные: 1.0).

§ 1.7. Pretraining + fine-tuning

Ключевые техники: differential learning rate (backbone $1\text{e-}5$.. $5\text{e-}5$, головы $1\text{e-}3$.. $1\text{e-}4$) против catastrophic forgetting; layer freezing (полная = feature extractor, частичная = адаптация верхних слоёв); gradient accumulation (AST: batch=16, accum=4, effective=64). Эти техники позволили AST за 3 часа превзойти CNN-baseline по segment accuracy на 5.3 п.п. (§5.4).

Резюме главы 1. MSA остаётся сложнейшей задачей MIR; AST с AudioSet-pretraining определяется как наиболее перспективная архитектура для финальной модели.

Глава 2

Постановка задачи

§ 2.1. Цель исследования

Цель работы — создать прототип программно-аналитической системы автоматического анализа музыкальных композиций, формирующей по входному аудиотреку многоаспектную временную разметку (timeline) с четырьмя категориями признаков:

- 1) Структурная сегментация — 6 классов музыкальной формы: Intro, Verse, Bridge, Chorus, Instrumental, Outro.
- 2) Arousal — уровень энергии в трёх категориях: Low, Mid, High.
- 3) Valence — эмоциональная окраска: Dark, Neutral, Bright.
- 4) Genre — один из 10 жанров: blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock.

В отличие от специализированных решений (Madmom, Essentia, MIRtoolbox [9; 20; 21]), система решает все четыре задачи одновременно через единую модель. Это обеспечивает согласованность результатов (структурные границы синхронизированы с эмоциональными переходами на общих признаках), эффективность вычислений (один проход вместо четырёх) и возможность совместной интерпретации в прототипе (§6.2).

§ 2.1.1. Формальная постановка

Пусть $x \in \mathbb{R}^{T_{\text{audio}}}$ — моноаудиосигнал с $sr = 22050$ Гц. Извлечение признаков преобразует его в последовательность лог-мел окон $X = \{X_1, \dots, X_N\}$,

$X_i \in \mathbb{R}^{F \times W}$, $F = 128$, $W = sr \cdot \tau / h$ при $\tau = 10$ с и $h = 512$. Модель f_θ выдаёт для каждого окна четыре распределения:

$$f_\theta(X_i) = (p_i^{\text{seg}}, p_i^{\text{aro}}, p_i^{\text{val}}, p_i^{\text{gen}}), \quad (2.1)$$

где $p_i^{\text{seg}} \in \Delta^5$, $p_i^{\text{aro}}, p_i^{\text{val}} \in \Delta^2$, $p_i^{\text{gen}} \in \Delta^9$. Пост-обработка g преобразует покадровые предсказания в непрерывные интервалы:

$$g(\{p_i\}_{i=1}^N) \mapsto \{(t_j^{\text{start}}, t_j^{\text{end}}, c_j, \kappa_j)\}_{j=1}^M, \quad (2.2)$$

где c_j — класс сегмента, κ_j — confidence, M — число сегментов после слияния. Описание g (Viterbi + position priors + min-duration merge) — в §4.7.

§ 2.2. Исследовательские вопросы

RQ1. Насколько эффективна мульти-задачная CNN для одновременного решения четырёх задач на ограниченных данных (~ 2.5 тыс. треков)? Сопоставима ли она с однозадачными моделями из литературы?

RQ2. Каков вклад temporal modeling через BiLSTM поверх per-window CNN-эмбеддингов, особенно для структурной сегментации?

RQ3. Каков вклад качества входных признаков через PANNs CNN14 (pretrained на AudioSet) vs CNN с нуля?

RQ4. Какой из факторов — temporal modeling или quality of features — важнее; эффекты аддитивны или интерактивны?

RQ5. Способна ли архитектура AST (pretrained на AudioSet) превзойти CNN- и PANNs-baseline за счёт глобального self-attention и богатой инициализации? Какие задачи улучшаются больше всего?

RQ1–RQ4 образуют 2×2 факторный эксперимент (CNN, CNN+BiLSTM, PANNs+Linear, PANNs+BiLSTM); RQ5 расширяет его пятой архитектурой (AST). Дополнительно — ablation post-processing (с/без Viterbi и priors).

§ 2.3. Обоснование мульти-задачного подхода

Семантические корреляции. Жанр определяет типичную структуру (rock: verse-chorus; classical: sonata-form; electronic: build-up/drop); эмоциональная динамика согласована со структурой (куплет→припев сопровождается ростом arousal и сменой valence); жанр коррелирует с эмоцией (metal — чаще Q2, classical — Q4, blues — Q3).

Регуляризация через shared backbone. MTL вынуждает модель извлекать универсальные признаки (тембр, ритм, гармония), полезные для всех задач — это препятствует переобучению на task-specific артефактах. Эмпирически MTL-модель показывает меньший generalization gap на 3–5 п.п. относительно single-task baseline (§5.7).

Практическая ценность. Последовательный запуск четырёх моделей приводит к 4-кратному росту inference-времени (32 с vs 8 с на 3-мин трек), несогласованности предсказаний и усложнению развёртывания (4 checkpoint). Единая MTL-модель выдаёт согласованную разметку за один проход, что критично для интерактивных приложений (Глава 6).

Резюме главы 2. Сформулирована цель — прототип системы многоаспектного анализа аудио. Поставлены пять RQ: 2×2 факторный эксперимент (RQ1–RQ4) и расширение AST (RQ5). Выбор MTL обоснован семантическими корреляциями, регуляризационным эффектом и практическими соображениями.

Глава 3

ДАННЫЕ

Используются три открытых датасета, каждый специализированный под одну задачу: DEAM (эмоции), Harmonix Set (структура), GTZAN (жанр). Объединение разнородных корпусов в мульти-задачное обучение требует унифицированного пайплайна предобработки и аккуратных сплитов.

§ 3.1. Используемые датасеты

Таблица 3.1: Таблица 3.1. Используемые датасеты

Датасет	Размер	Аудио	Аннотации	Задача	Источник
DEAM	1802 фрагмента (45 с каждый)	mp3	Покадровые непрерывные arousal/valence	Эмоции	MediaEval 2013– 2018 [2]
Harmonix Set	912 треков (полная дли- тельность)	mp3 (загру- жено 743)	Структурная разметка с временными метками	Сегментация	Nieto et al., 2019 [31]
GTZAN	999 фрагментов (30 с каждый)	wav	Жанровая метка целиком на трек	Жанр	Tzanetakis & Cook, 2002 [34]
Итого	3713 уникальных файлов	≈ 110 ГБ features		4 задачи	

DEAM [2] — крупнейший открытый MER-датасет (MediaEval 2013–2018). 1802 фрагмента по 45 с из Free Music Archive (CC-лицензия); покадровые аннотации arousal/valence получены через краудсорсинг (~ 10 аннотаторов на трек, шаг 500 мс). Формат: {arousal,valence}_average.csv (усреднённые ряды по 60 фреймам), _std.csv (согласие аннотаторов), metadata.csv. Непрерывные значения $[-1, +1]$ дискретизируются в 3 категории по порогам ± 0.2 :

```
arousal: [-1.0..-0.2] -> Low, [-0.2..+0.2] -> Mid, [+0.2..+1.0] ->
High
valence: [-1.0..-0.2] -> Dark, [-0.2..+0.2] -> Neutral, [+0.2..+1.0]
-> Bright
```

Пороги ± 0.2 обеспечивают приблизительно равномерное распределение (25–40% на класс) и сохраняют семантику (Low при arousal ≈ 0 не был бы «действительно низкой энергией» при разбиении по квантилям).

Harmonix Set [31] — единственный крупный открытый датасет структурной разметки коммерческой поп-музыки (912 треков, ручная разметка в Sonic

Visualiser). Аннотации включают beat positions, section labels, downbeats; используются только секции. Исходные 17 категорий сведены к 6:

```
intro , intro_*          -> Intro
verse , verse_*, theme   -> Verse
bridge , transition_*     -> Bridge
chorus , chorus_*, hook   -> Chorus
instrumental , solo , breakdown -> Instrumental
outro , fadeout           -> Outro
```

Harmonix распространяется без аудио (copyright); реализован пайплайн скачивания через yt-dlp по youtube_id (scripts/download_harmonix_audio.py). Из 912 треков загружено 743 (81.5%); остальные удалены с YouTube.

GTZAN [34] — 999 рабочих файлов (1 повреждён) в 10 жанрах по 100 примеров: blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock. Известные ограничения [30]: дубликаты ($\sim 5\%$), ошибки маркировки, artist bias, устаревшая таксономия. Несмотря на это, GTZAN сохраняется как референс ради сопоставимости с 23-летней литературой; OOD-поведение адресуется через top-3 UI в прототипе (§6.3).

§ 3.2. Извлечение признаков

Все датасеты унифицируются на этапе feature extraction и сохраняются в .prz: это позволяет обучению не перекодировать mp3 каждый раз, что критично для скорости epoch.

Таблица 3.2: Параметры log-mel спектрограммы

Параметр	Значение	Обоснование
Sample rate	22050 Гц	Стандарт librosa, покрывает до 11025 Гц
n_fft	2048	≈ 93 мс STFT окно
hop_length	512	≈ 23 мс между фреймами
n_mels	128	Стандарт для music classification
fmin	30 Гц	Нижняя граница мел-фильтров
fmax	11025 Гц	Найквистова частота

Логарифмическая компрессия: librosa.power_to_db(..., ref=np.max) $\rightarrow$ диапазон $\approx [-80, 0]$ дБ.

Окновая нарезка. `window_seconds = 10.0` (431 фрейм), `hop_seconds = 1.0`. Выбор 10с обоснован двумя факторами: (1) достаточно для типичного музыкального периода (куплет/припев); (2) AST предобучен на 10-секундных окнах AudioSet, что позволяет использовать веса без интерполяции positional embeddings. Шаг 1с даёт ~ 50 окон/минуту — достаточно для Viterbi.

Глобальная нормализация. По train split вычисляются mean/std по мел-полосам и сохраняются в stats.npz:

```
features_train = np.concatenate([np.load(f)["features"] for f in
    train_files])
mean = features_train.mean(axis=(0, 2), keepdims=True) # (1, n_mels, 1)
std = features_train.std(axis=(0, 2), keepdims=True) + 1e-6
np.savez("stats.npz", mean=mean, std=std)
```

Применяются ко всем сплитам: $(\text{feat} - \text{mean}) / \text{std}$. Критично: тот же stats.npz используется при inference пользовательских загрузок — musicml/infer.py:ext загружает его автоматически.

§ 3.3. Стратегия разбиения train/val/test

Каждый датасет независимо разбивается 70/15/15 с seed=42. Принципиальные решения: (1) разбиение на уровне треков, не окон — иначе окна одного трека попадали бы и в train, и в test, что завышает метрики; (2) GTZAN стратифицирован автоматически (100 треков/класс); (3) для DEAM стратификация невозможна (покадровые непрерывные метки, разные фрагменты одного трека принадлежат разным классам) — используется случайное разбиение; (4) Harmonix — случайное, жанровая информация отсутствует; (5) списки треков каждого сплита сохраняются в splits.json для воспроизводимости.

§ 3.4. Дисбаланс классов

Таблица 3.3: Таблица 3.2. Распределение классов в train-сплитах

Задача	Класс	Доля окон	Inverse-frequency weight
Segment	Verse	~35%	0.71
	Chorus	~25%	1.00
	Bridge	~12%	2.08
	Intro	~10%	2.50 (capped)
	Instrumental	~10%	2.50 (capped)
	Outro	~8%	2.50 (capped)
Arousal	Low / Mid / High	~33% / 34% / 33%	≈ 1.00 каждый
Valence	Dark / Neutral / Bright	~33% / 33% / 34%	≈ 1.00 каждый
Genre	каждый из 10	~10%	≈ 1.00 каждый

Сегментная задача — единственная сильно несбалансированная (Verse+Chorus ~60%, Outro < 10%). Без обработки модель выучит только доминирующие классы. Применяются три механизма: (1) inverse-frequency class weights с порогом `max_class_weight=2.5` (эмпирически, против чрезмерного усиления редких классов; §4.6); (2) Focal Loss [12] с $\gamma = 1.5$ — множитель $(1 - p_t)^\gamma$ снижает вклад уверенных правильных предсказаний; (3) per-task loss weight segment: 1.5 (остальные: 1.0). Более агрессивные параметры (`segment_weight=3.5`, `focal_gamma=2`, `max_class_weight=3.5`) дали обратный эффект — переобучение на редкие классы (§5.5, неудачный CNN v3).

Резюме главы 3. Описаны три датасета, унифицированный log-mel пайплайн (128 bins, окна 10 с / 1 с) с глобальной нормализацией, и стратегия разбиения на уровне треков с `seed=42`. Для сегментной задачи применены три механизма борьбы с дисбалансом: class weights, focal loss, per-task loss weight.

Глава 4

Архитектура и методы

Исследуется пять архитектур по трём измерениям: извлечение признаков (CNN vs PANNs vs AST), temporal modeling (per-window vs BiLSTM) и парадигма трансфера. Все пять имеют единый интерфейс — четыре классификационные и две регрессионные головы. Финальная модель прототипа — AST v2 с Viterbi-декодированием.

§ 4.1. Обзор многоархитектурного эксперимента

Таблица 4.1: Таблица 4.1. Сравнение пяти архитектур

№	Конфиг	Backbone	Temporal	Pretraining	Параметры	Trainable
1	CNN	5-блочная CNN с SE	per- window	нет	~800K	~800K
2	CNN+BiLSTM	CNN→BiLSTM(128)	sequence	нет	~1.2M	~1.2M
3	PANNs+Linear	PANNs CNN14	per- window	AudioSet (frozen)	~80M	~210K
4	PANNs+BiLSTM	PANNs→Proj→BiLSTM(256)	sequence	AudioSet (frozen)	~81M	~750K
5	AST v2	ViT	per- window (global attn)	AudioSet (fine-tuned)	~87M	~14M

Конфигурации 1–4 формируют 2×2 факторный эксперимент (RQ1–RQ4); конфигурация 5 отвечает на RQ5 и используется как финальная.

§ 4.2. CNN backbone (конфигурация 1)

Архитектура. Вход $(B, 1, 128, T)$. Пять conv-блоков с каналами [32, 64, 128, 256, 512]; каждый блок — $\text{Conv2D}(3 \times 3) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{SE} \rightarrow \text{MaxPool}(2 \times 2)$. После GAP — $\text{Linear}(512 \rightarrow 256) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0.4)$, затем 4 головы: segment (6), arousal (3), valence (3), genre (10). ~ 800 тыс. параметров.

Squeeze-and-Excitation [19]. После каждого блока встроен модуль channel attention:

SE(C) : GAP $\rightarrow$ Linear(C $\rightarrow$ C/16) $\rightarrow$ ReLU $\rightarrow$ Linear(C/16 $\rightarrow$ C) $\rightarrow$ Sigmoid $\rightarrow$ multiply

SE позволяет backbone «маршрутизировать» частотные признаки между задачами.

Shared FC. Добавление Linear(512 $\rightarrow$ 256) с BN и Dropout улучшило обобщение за счёт 256-мерного представления для всех 4 голов.

§ 4.3. CNN + BiLSTM (конфигурация 2)

Над CNN-эмбедингами надстроен рекуррентный слой: 3 мин трек $\rightarrow$ 180 окон по 10 с с hop 1 с $\rightarrow (B, 180, 512) \rightarrow \text{BiLSTM}(\text{hidden}=128, \text{layers}=2, \text{bidirectional}) \rightarrow \text{FC}(256) \rightarrow$ 4 головы. BiLSTM выбран вместо трансформера из-за малого размера выборки (522 трека Harmonix), умеренной длины последовательностей и малого числа параметров ($\sim 400\text{K}$).

§ 4.4. PANNs+Linear и PANNs+BiLSTM (конфигурации 3, 4)

PANNs CNN14 [25] (80M, AudioSet) используется как frozen feature extractor: 1 с $\rightarrow$ 2048-мерный embedding.

- Конфиг 3 (PANNs+Linear): embedding $\rightarrow$ 4 линейные головы; trainable $\sim 210\text{K}$.

- Конфиг 4 (PANNs+BiLSTM): embedding $\rightarrow$ Linear(2048 $\rightarrow$ 512) $\rightarrow$ BiLSTM(hidden trainable $\sim$ 750K).

Frozen режим — из-за риска catastrophic forgetting и возможности precompute эмбеддингов один раз (обучение голов 8–12 минут).

§ 4.5. Audio Spectrogram Transformer v2 (конфигурация 5, финальная)

Финальная модель — fine-tuned AST на основе чекпоинта MIT/ast-finetuned-audioset-10-10-0.4593 [14], показавшая лучший средний результат (§5.4).

Базовая архитектура. AST применяет ViT [3] к log-mel спектрограмме: $128 \times T$ делится на патчи 16×16 со сдвигом 10, каждый проецируется в 768-мерный токен. Добавляются CLS-токен и learnable positional embeddings. Encoder — 12 слоёв multi-head self-attention (12 голов, d_head=64) с FFN Linear(768 $\rightarrow$ 3072) $\rightarrow$ GELU $\rightarrow$ Linear(3072 $\rightarrow$ 768). Из выхода CLS подаётся в 4 головы. $\sim$ 87 млн параметров.

Pretraining на AudioSet [4]. $\sim$ 2М 10-секундных YouTube-фрагментов, 527 категорий; mAP=45.9%. Checkpoint 574 МБ.

Стратегия fine-tuning. Заморожены patch embedding, positional embedding и первые 8 из 12 transformer-слоёв; обучаются последние 4 слоя, LayerNorm, CLS и 4 головы. Trainable $\sim$ 14 млн. 4 верхних слоя — компромисс между недообучением (feature extractor уступает PANNs+Linear) и переобучением (все 12 за 3 эпохи).

Differential learning rate.

```
optimizer = AdamW([
    {"params": backbone_params, "lr": 5e-5}, # unfrozen layers
    {"params": head_params, "lr": 1e-3}, # heads + CLS
], weight_decay=0.01)
```

Соотношение lr_head / lr_backbone = 20 [18].

Gradient accumulation. batch_size=16, accum_steps=4 для effective batch=64.

Обоснование выбора. AST v2 дал лучший средний (58.5% vs 58.2% CNN v2) и лучший сегмент (40.6% vs 35.3%). На genre AST уступает CNN v2 на 2.4 п.п.: для 10-классовой задачи на 30 с GTZAN-фрагментах inductive bias CNN эффективнее.

§ 4.6. Multi-task heads и функция потерь

Структура голов. Четыре линейных классификатора от D -мерного представления ($D = 256$ или 768) + две регрессионные $\text{Linear}(D \rightarrow 1) \rightarrow \text{sigmoid}$ для arousal/valence в $[0, 1]$. Регрессионные используются только для кривых; в Russell circumplex применяется классификационный score $0.5 + 0.5 \cdot (P(\text{pos}) - P(\text{neg}))$ (§6.3).

Focal Loss [12]:

$$\mathcal{L}_{FL}(p_t) = -\alpha_t \cdot (1 - p_t)^\gamma \cdot \log(p_t) \quad (4.1)$$

$\gamma = 1.5$ (в v1 было 2.0 — слишком агрессивно, Verse recall 10%).

Class weights. $w_c = \min(N_{\text{total}}/(K \cdot N_c), w_{\text{max}})$, $w_{\text{max}} = 2.5$ (эмпирическое $\sqrt{\text{ratio}_{\text{max}}/\text{ratio}_{\text{min}}} \approx 2.2$).

Per-task веса.

$$\mathcal{L}_{\text{total}} = 1.5 \mathcal{L}_{\text{seg}} + \mathcal{L}_{\text{aro}} + \mathcal{L}_{\text{val}} + \mathcal{L}_{\text{gen}} + 0.5 (\mathcal{L}_{\text{aro_reg}} + \mathcal{L}_{\text{val_reg}}). \quad (4.2)$$

$w_{\text{seg}} = 1.5$ компенсирует малый вклад сегмента в градиент; регрессионные 0.5 против доминирования MSE.

Оптимизатор. AdamW(lr=1e-3, wd=5e-4) + CosineAnnealingWarmRestarts(T_0=1 T_mult=2). Для AST — differential.

Аугментации. SpecAugment [28]: freq_mask=27, time_mask=60. MixUp [23] с $p = 0.5$, $\lambda \sim \text{Beta}(0.2, 0.2)$.

§ 4.7. Post-processing pipeline

Сырые поккадровые предсказания содержат локальные всплески и нарушают музыкальные априори. Применяется трёхступенчатый pipeline, затем расширенная версия v2.

Этап 1. Viterbi-декодирование с transition penalty.

$$\hat{c}_{1:T} = \arg \max_{c_{1:T}} \sum_{t=1}^T [\log P(c_t | X_t) + \pi_t(c_t)] - \lambda \sum_{t=2}^T \mathbb{I}[c_t \neq c_{t-1}] \quad (4.3)$$

Выбрано $\lambda = 1.0$: $\lambda = 0.5$ оставляет всплески, $\lambda = 2.5$ склеивает сегменты.

Этап 2. Musicological position priors.

boundary_fraction = 0.22	# 22% track length
penalty = 10.0	


```
priors[boundary_frames:, idx_Intro] -= penalty
priors[:T - boundary_frames, idx_Outro] -= penalty
```

boundary_fraction=0.22 — 95% Intro в первых 22% Harmonix; penalty=10 в литературном диапазоне 5–15 [15; 24; 35].

Этап 3. Iterative min-duration merge. Сегменты короче 6 с сливаются с соседями итеративно до стабильности.

Эффект pipeline.

Таблица 4.2: Эффект пост-процессинга на test-сете Harmonix

Метод	Сегментов Boundary F1		Section F1
Argmax (без post-processing)	28.4	0.31	0.32
+ Median filter (kernel=5)	14.2	0.36	0.34
+ Viterbi ($\lambda = 1.0$)	9.8	0.42	0.37
+ Position priors (penalty=10)	8.7	0.43	0.38
+ Min-duration merge (6 с)	7.5	0.45	0.39

§ 4.7.1. Декодер v2: расширенный pipeline

По результатам эксплуатации выявлены артефакты v1 (до 22 сегментов для блюза, Intro в середине). Реализован decode_segment_head_v2 с шестью механизмами.

- 1. Temperature scaling ($T = 1,4$). Расширяет динамический диапазон $P'(c | X_t) = \text{softmax}(\log P/T)$, возвращая влияние priors.
- 2. Структурная матрица переходов (asymmetric $K \times K$) вместо скалярного λ :

Таблица 4.3: Матрица переходов (стоимость в log-space)

Переход	Стоимость	Обоснование
Intro $\rightarrow$ Verse	0,0	Стандартный ход
Chorus $\rightarrow$ Verse	0,0	Типичная форма
Verse $\rightarrow$ Intro	4,0	Неестественно
Bridge $\rightarrow$ Intro	5,0	Невозможно
Outro $\rightarrow$ Verse	8,0	Запрещено
Остальные	2,0	Base penalty

3. Усиленные position priors. penalty=14.0, boundary_fraction=0.12, boost=1.0: Intro/Outro только в первых/последних 12%, штраф -14 , boost $+1.0$ в разрешённых зонах.

4. Per-class minimum duration вместо единого min_duration=6 с:

Таблица 4.4: Минимальные длительности сегментов

Класс	Min duration	Обоснование
Intro	5 с	Может быть коротким
Verse	15 с	Куплет ≥ 12 -bar blues (≈ 24 с)
Bridge	8 с	Пре-хорус бывает коротким
Chorus	12 с	Припев обычно длинный
Instrumental	15 с	Соло / проигрыш длинные
Outro	5 с	Может быть fade-out

5. Novelty snapping. Каждая граница сдвигается к ближайшему локальному максимуму novelty curve (L^2 -норма разности соседних фреймов) в радиусе ± 2 с.

6. Repetition consistency. При cosine similarity centroids $> 0,82$ два фрагмента с разными метками перемаркируются в общий класс (предпочтительно Chorus).

Результат. На «The Thrill Is Gone» число сегментов сократилось с 22 (v1) до 5 (v2).

§ 4.8. Inference и нормализация на ПОЛЬЗОВАТЕЛЬСКИХ аудио

Pipeline: (1) librosa sr=22050 mono; (2) log-mel ($n_{\text{mels}} = 128$); (3) загрузка stats.npz с train mean/std и (features - mean) / std; (4) окна 10 с, hop 1 с; (5) модель; (6) post-processing v2; (7) JSON timeline.

Критический шаг (3). Без нормализации blues-трек ошибочно классифицировался как hip-hop. Auto-loading stats.npz в `extract_features()` восстановил качество.

Резюме. Пять архитектур с единым интерфейсом 4+2 голов; AST v2 с differential fine-tuning — production-модель; полный post-processing даёт +14 п.п. Boundary F1.

Глава 5

Эксперименты

Проведено четыре последовательных эксперимента: (§5.3) baseline всех четырёх архитектур 2×2 (v1); (§5.4) улучшенный запуск (v2); (§5.5) AST v2; (§5.6) CNN v3 (negative result). Дополнительно (§5.8) ablation post-processing.

§ 5.1. Протокол оценки

Метрики. Accuracy, macro-F1, per-class P/R/F1. Для сегмента дополнительно Boundary F1 $\pm 3с$ — стандартная MIR-метрика.

Splits: 70/15/15 на уровне треков, seed=42. Test: DEAM $\approx 11.6K$ окон, Harmonix $\approx 23.4K$, GTZAN $\approx 3.2K$. Eval из ckpt с лучшим val_loss, один раз.

Random baselines: Segment — 16.7%, Arousal/Valence — 33.3%, Genre — 10.0%.

§ 5.2. Гиперпараметры обучения

Конфигурация v2 для всех архитектур кроме AST (см. §4.5):

Таблица 5.1: Гиперпараметры v2

Параметр	Значение
Optimizer	AdamW, lr=1.0e-3, weight_decay=5.0e-4
Batch size / Epochs /	64 / 50 / 15
Patience	
Scheduler	CosineAnnealingWarmRestarts (T_0=10, T_mult=2)
Loss	Focal Loss, $\gamma = 1.5$, max_class_weight=2.5
Mixup α	0.2 (per-window), 0.0 (BiLSTM)
Window / Hop	10.0 c / 1.0 c
SpecAugment	freq_mask=27, time_mask=60, n_masks=2
Dropout	0.4
Per-task weights	seg:1.5, aro_cls:1.0, val_cls:1.0, gen:1.0, *_reg:0.5

§ 5.3. Эксперимент v1 (baseline-запуск)

Конфигурация v1. 4 conv-блока, 30 эпох, OneCycleLR, focal_gamma=2.0, max_class_weight=4.0, window=8 c.

Таблица 5.2: Таблица 5.1. Результаты 2×2 эксперимента (v1)

Конфигурация	Segment acc/F1	Arousal acc/F1	Valence acc/F1	Genre acc/F1
CNN	24.3 / 23.1	65.9 / 65.3	55.8 / 53.4	82.7 / 81.9
per-window				
CNN+BiLSTM	25.9 / 26.8	53.0 / 51.8	49.5 / 48.4	45.5 / 42.5
PANNs+Linear	23.2 / 20.5	60.9 / 61.4	54.3 / 52.7	81.6 / 81.2
PANNs+BiLSTM	31.4 / 31.5	62.8 / 62.9	55.9 / 56.0	81.0 / 80.5

Диагностика. Per-class разбор CNN v1 показал, что модель подавляет мажоритарные классы.

Таблица 5.3: Per-class метрики сегментной задачи CNN v1

Класс	Precision	Recall	F1	Интерпретация
Intro	28.9	64.2	39.8	Overpredicted
Verse	68.9	10.1	17.6	Почти не предсказывается
Bridge	19.2	51.5	28.0	Overpredicted
Chorus	70.9	18.4	29.2	Почти не предсказывается
Instrumental	10.0	62.5	17.3	Low precision
Outro	4.1	14.4	6.4	Плох по всем метрикам

Диагноз: max_class_weight=4.0 чрезмерно усиливал миноритарные классы. CNN+BiLSTM на genre (45.5%) — катастрофическое переобучение на 699 GTZAN-треках.




Рис. 5.1. Тепловая карта 2×2-факторного дизайна v1: temporal modeling × feature quality.

§ 5.4. Эксперимент v2 (улучшенный запуск)

Таблица 5.4: Изменения v1 → v2

Параметр	v1	v2	Эффект
Conv blocks	4	5 (с SE)	Больше ёмкости
Window	8 с	10 с	Больше контекста
Focal gamma	2.0	1.5	Менее агрессивный фокус
Max class weight	4.0	2.5	Меньшая компенсация
Segment loss weight	1.0	1.5	Приоритизация сегмента
Epochs / Patience	30/10	50/15	Больше конвергенции
Scheduler	OneCycleLR	CosineWR	Выход из локальных минимумов
Temporal jitter	нет	±1.0 с	Робастность к границам

Таблица 5.5: Таблица 5.2. Результаты 2×2 эксперимента (v2)

Конфигурация	Segment acc/F1	Arousal acc/F1	Valence acc/F1	Genre acc/F1
CNN	35.3 / 29.5	62.0 / 61.0	51.7 / 51.1	83.9 / 83.3
per-window				
CNN+BiLSTM	32.2 / 31.6	62.3 / 62.4	54.2 / 53.3	60.9 / 62.0
PANNs+Linear	24.0 / 21.7	61.2 / 61.6	53.8 / 53.3	81.9 / 81.4
PANNs+BiLSTM	32.9 / 32.7	64.9 / 64.0	55.0 / 53.0	77.7 / 77.9

Таблица 5.6: Таблица 5.3. Дельты v2 относительно v1

Конфиг	Δ Segment	Δ Arousal	Δ Valence	Δ Genre
CNN	+11.0 / +6.4	-3.9 / -4.3	-4.1 / -2.3	+1.2 / +1.4
CNN+BiLSTM	+6.3 / +4.8	+9.3 / +10.6	+4.7 / +4.9	+15.4 / +19.5
PANNs+Linear	+0.8 / +1.2	+0.3 / +0.2	-0.5 / +0.6	+0.3 / +0.2
PANNs+BiLSTM	+1.5 / +1.2	+2.1 / +1.1	-0.9 / -3.0	-3.3 / -2.6

CNN segment +11.0 п.п. (Verse recall 10→28%, Chorus 18→40%), CNN+BiLSTM genre +15.4 п.п. CNN потерял ~4 п.п. на эмоциях — цена приоритизации сегмента.

Per-class разбор сегментов (CNN v2):

Таблица 5.7: Таблица 5.4. Per-class сегментация для CNN v2

Класс	v1 P/R/F1	v2 P/R/F1	Δ Recall
Intro	28.9 / 64.2 / 39.8	34.1 / 59.8 / 43.4	-4.4
Verse	68.9 / 10.1 / 17.6	52.1 / 27.9 / 36.4	+17.8
Bridge	19.2 / 51.5 / 28.0	17.3 / 39.8 / 24.1	-11.7
Chorus	70.9 / 18.4 / 29.2	53.5 / 40.3 / 46.0	+21.9
Instrumental	10.0 / 62.5 / 17.3	16.5 / 29.4 / 21.1	-33.1
Outro	4.1 / 14.4 / 6.4	6.2 / 5.9 / 6.0	-8.5

Verse и Chorus — наиболее частые и практически важные — кардинально улучшились (recall 14→34%).

Ответы на RQ1–RQ4. RQ1: одна модель решает 4 задачи, особенно Genre (83.9%, SOTA-уровень). RQ2: BiLSTM улучшает emotion, но вредит genre у CNN+BiLSTM (переобучение); у PANNs+BiLSTM эффект мягче. RQ3: PANNs не дают преимущества — AudioSet-pretraining оптимизирован под звуковые

события; fine-tuning (§5.5) принципиально важнее. RQ4: ни один из факторов не решающий; реальный прорыв — трансформеры (§5.5).

§ 5.5. Эксперимент AST v2 (расширение трансформер-архитектурой)

Мотивация. Необходима архитектура с глобальным receptive field и богатой инициализацией, более ёмкая и адаптируемая. AST [14] удовлетворяет обоим.

Конфигурация. MIT/ast-finetuned-audioset-10-10-0.4593 (87M). Заморожены: patch embedding + первые 8 слоёв. Trainable: верхние 4 слоя + heads + CLS $\approx$ 14.4M. Differential lr: backbone 5e-5, heads 1e-3, wd 0.01. batch_size=16, grad_accumulation=4. 30 эпох, patience 10, CosineWR. $\sim$ 3 ч на 12GB GPU.

Таблица 5.8: Таблица 5.5. Результаты AST v2 (test-set)

Задача	Accuracy	Macro-F1	Δ vs CNN v2 (acc)
Segment	40.6	30.8	+5.3 п.п.
Arousal	60.6	60.4	-1.4 п.п.
Valence	51.1	50.4	-0.6 п.п.
Genre	81.5	80.8	-2.4 п.п.
Среднее	58.5	55.6	+0.3 п.п.

Таблица 5.9: Per-class метрики сегмента AST v2

Класс	Precision	Recall	F1
Intro	31.0	50.0	38.3
Verse	51.0	45.7	48.2
Bridge	20.1	22.9	21.4
Chorus	48.2	45.6	46.9
Instrumental	26.6	23.4	24.9
Outro	4.5	6.1	5.2

Ответ на RQ5. AST v2 превзошёл CNN по сегменту (+5.3 п.п.); источник — сбалансированные Verse (45.7% vs 27.9%) и Chorus (45.6% vs 40.3%). На genre AST уступает (-2.4 п.п.). Trade-off: AST лучше среднего и лучший на сегменте, но требует 30× больше памяти (574 vs 21 MB) и 4× больше inference-времени.

§ 5.6. Эксперимент CNN v3 (failed retrain)

Гипотеза. Тройное усиление сегментной задачи: `segment_weight` 1.5→3.5, `focal_gamma` 1.5→2.5, `max_class_weight` 2.5→3.5.

Таблица 5.10: Таблица 5.6. CNN v3 vs CNN v2

Задача	CNN v2	CNN v3	Δ
Segment	35.3	22.1	-13.2 п.п.
Arousal	62.0	64.5	+2.5
Valence	51.7	54.1	+2.4
Genre	83.9	79.1	-4.8
Среднее	58.2	54.9	-3.3 п.п.

Анализ провала. Early stopping на эпохе 19, лучший `val_loss` на эпохе 4 — быстрое переобучение. Class weights после обрезания [Intro:3.05, Verse:0.44, ... Outro:3.5] сместили модель в overprediction. CNN v3 — academically valuable negative result: v2 уже близок к оптимуму для CNN.

§ 5.7. Сводная таблица всех моделей

Таблица 5.11: Таблица 5.7. Финальное сравнение

#	Модель	Параметры	Segment	Arousal	Valence	Genre	Avg
1	CNN v1	~400K	24.3	65.9	55.8	82.7	57.2
2	CNN v2	~800K	35.3	62.0	51.7	83.9	58.2
3	CNN+BiLSTM v2	~1.2M	32.2	62.3	54.2	60.9	52.4
4	PANNs+Linear v2	~210K*	24.0	61.2	53.8	81.9	55.2
5	PANNs+BiLSTM v2	~750K*	32.9	64.9	55.0	77.7	57.6
6	AST v2	~14M*	40.6	60.6	51.1	81.5	58.5
7	CNN v3 (failed)	~800K	22.1	64.5	54.1	79.1	54.9

* trainable параметры. Чемпионы: Segment — AST v2 (40.6%); Arousal/Valence — PANNs+BiLSTM; Genre — CNN v2 (83.9%); Среднее — AST v2 (58.5%). Для прототипа выбрана AST v2.




Рис. 5.2. Сравнение пяти архитектур по четырём задачам (v2-запуск + AST v2).

§ 5.8. Ablation: вклад post-processing pipeline

Ablation на test-сете Harmonix с AST v2 (см. §4.7):

Таблица 5.12: Таблица 5.8. Ablation post-processing

Метод	Сегментов (avg)	Boundary F1 ±3 с	Section F1
Argmax (без post-processing)	28.4	0.31	0.32
+ Median filter (kernel=5)	14.2	0.36	0.34
+ Viterbi (λ = 1.0)	9.8	0.42	0.37
+ Position priors (penalty=10)	8.7	0.43	0.38
+ Min-duration merge (6 с)	7.5	0.45	0.39

Viterbi даёт максимальный прирост (+6 п.п. Boundary F1). Полный pipeline: +14 п.п. Boundary F1, +7 п.п. Section F1.

Резюме. AST v2 показал лучший средний (58.5%) и сегмент (40.6%), выбран как production-модель.

Глава 6

Прототип системы

Реализован веб-прототип, принимающий аудиофайл (MP3, WAV, FLAC, OGG), выполняющий анализ через AST v2 + post-processing и отображающий результат в синхронизированном дашборде из шести панелей. Архитектура — трёхзвенная: Python-сервис инференса, TypeScript-backend, React-фронтенд.






Рис. 6.1. Главная страница прототипа: editorial hero, карточки «В системе» / «Архитектура» / «Лучшие метрики» и загрузка трека.

§ 6.1. Архитектура веб-приложения

Прототип состоит из трёх сервисов, соединённых REST-API:





ML API (FastAPI, port 8000): AST v2 в памяти (574 МБ), endpoints POST /analyze, POST /spectrogram, GET /health. Backend (Elysia на Bun, port 3000): POST/GET /api/tracks, POST /api/tracks/:id/analyze, GET /api/tracks/:id/audio|spectrogram. Хранение — JSON в web/backend/data/, аудио в uploads/. Frontend (React 19 + Vite, port 5173) — SPA с маршрутами / и /tracks/:id. Разработка — Bun-скрипт scripts/dev-all.ts, запускающий все три сервиса параллельно.

§ 6.2. Синхронизированный дашборд




Рис. 6.2. Дашборд трека «The Thrill Is Gone» (В. В. King & Muddy Waters): плеер, А/V-trajectory, жанр, мел-спектрограмма, кривые arousal/valence.

Главное решение — синхронизированный дашборд из шести панелей с общим playhead: курсор движется по всем панелям, hover подсвечивает момент, клик ставит pinned-закладку.

Фреймворк синхронизации. DashboardContext (playheadTime, hoverTime, pinnedTime, isPlaying, seek/togglePlay) с rAF 60 fps; хук useTimeScale на scaleLinear из d3-scale + ResizeObserver; обёртка ChartFrame. Поверх каждой панели — TimeCursor с Playhead (красный solid+glow), Pinned (синий+label) и Hover (dashed).

```
const ts = useTimeScale(containerRef, paddingLeft, paddingRight);
const pixelX = ts.scale(timeInSeconds); // time -> pixel
const time = ts.invert(pixelXFromMouse); // pixel -> time
```

§ 6.2.1. Шесть аналитических панелей

Структура (StructurePanel). Canvas-полоска с цветовым делением + список с временами и confidence; клик — seek и pin.

Эмоциональный анализ (EmotionPanel). Две полосы-таймлайна arousal/valence + canvas-кривая регрессионных значений.

Эмоциональная траектория (AVTrajectory). Квадрат 320×320 (Russell circumplex) с 4 квадрантами, серой траекторией за весь трек и красным «кометом» из последних 20 с. Координаты рассчитываются из классификационных вероятностей:

$$x_{\text{val}} = 0.5 + 0.5 \cdot (P(\text{Bright}) - P(\text{Dark})), \quad y_{\text{aro}} = 0.5 + 0.5 \cdot (P(\text{High}) - P(\text{Low})). \quad (6.1)$$

Регрессионные предсказания смещены к центру — все треки скапливались бы в «Грустное».

Жанр (GenrePanel). Top-3 с прогресс-барами; warning при top-1 < 45%; dominant genre timeline; stacked area 10 жанров. Адресует OOD (§7.3).

Мел-спектрограмма (SpectrogramPanel). Canvas $128 \times T$ с viridis и gamma $\gamma = 0.4$. Endpoint /spectrogram возвращает downsampled JSON (max 512 frames). Академически ценна — показывает, что «видит» модель.

Сводка (SummaryPanel). Pie распределения сегментов; доминирующий жанр; темп/тональность (librosa); средняя энергия и настроение; число структурных переходов.

§ 6.3. Ключевые UX-решения

- Top-3 жанров + confidence warning — академическая честность к OOD.
- Russell circumplex по классификации, не регрессии — устраняет bias.
- Display-name эвристика (displayName.ts) — DP-сегментация: 0375_dynamite.mp3 → Dynamite, распознаёт GTZAN-формат genre.NNNNN.
- Loading skeletons и empty states — shimmer-placeholders снижают perceived latency.
- Поиск и сортировка — toolbar с search + sort (Recent/Название/Длительность/Ж критично при 20+ треках.
- Приглушённая палитра (Tableau 10 muted): синий #2563eb для interactive, красный #dc2626 для playhead.

§ 6.4. Технологический стек

Таблица 6.1: Технологический стек прототипа

Слой	Технология	Обоснование
ML inference	Python 3.12 + PyTorch + FastAPI	Прямое использование checkpoint из обучения
Backend	Bun + Elysia + TypeScript	Быстрый старт (~100 мс), нативный TypeScript
Frontend	React 19 + Vite + TypeScript	Стандарт индустрии, hot reload
Визуализация	d3-scale + d3-shape + d3-scale-chromatic	Лёгкие модули для scales и colormaps
Стили	Plain CSS с CSS variables	Полный контроль над стилем
State	React Context (DashboardContext)	Достаточно для прототипа

Отвергнуты: Redux/Zustand, TailwindCSS, Recharts/Visx, Node.js (Bun в 4 раза быстрее).




Рис. 6.3. Галерея треков: cover-tiles с ID3/YouTube-обложками, жанровые чипы, поиск и сортировка.

§ 6.5. Визуальный редизайн и расширения интерфейса

Dark Glass Theme. Система переработана в стилистике `glassmorphism`: полупрозрачные поверхности с `backdrop-filter: blur(24px) saturate(130%)` на `#0a0c14` с многослойными `radial-gradient` тинтами цвета настроения (`-track-mood`). Типографика — моноширинные uppercase-метки и серифный `Fraunces`.




Рис. 6.4. Режим Vibe Mode: полноэкранный WebGL2-шейдер с SDF raymarching, реагирующий на FFT, баса/громкости envelope, onset и жанровые пресеты.

Vibe Mode (WebGL2-визуализатор). Полноэкранный визуализатор на fragment-шейдере GLSL ES 3.00, реализующем SDF raymarching тоннеля с domain-repeated арками. Вход — 13 uniform-переменных, обновляемых через requestAnimationFrame: uBass/uMid/uTreble (FFT-полосы), uBassEnv (fast attack 0,70, slow release 0,12), uLoudnessEnv, uOnset (peak detector 600 мс decay), uArousal/uValence, uSegmentIntensity (Intro=0,25, Chorus=1,0), uSegmentFlash, жанровые uGenreHue/uGenre, WebAudio: fftSize=1024, smoothingTimeConstant=0.82; чтение семантических данных с учётом AudioContext.outputLatency ($\approx 40\text{--}80$ мс).

Унифицированный плеер. Аудио-плеер и TimeAxis объединены в glass-карточку: фоновый waveform из audio_features.loudness_rms через mix-blend-mode: screen; монохромные segment-markers с opacity=confidence и uppercase-лейблами; glass-tooltip T: 2:08 · ПРИПЕВ; зелёный now-playing pulse.

Обновлённые панели. Эмоциональный профиль — wide-span 4: A/V-trajectory с 4-квадрантной географией и хронологически окрашенным хвостом (индиго → магента → коралл → амбер), 4 hero-tile, pie сегментов, progress-бары. Динамика эмоций — mood-tinted arousal + белая valence; rescale $[-1, 1] \rightarrow [0, 1]$ через $(x + 1) \cdot 0,5$. Мел-спектрограмма — aurora colormap + bloom; hover crosshair T: 1:51 · F: 4.1 кГц · I: 64%. Жанр — ★ winner + lighter blend.

Галерея треков. Grid-галерея (Apple Music / Spotify style): 2/3/4/5 колонок, квадратные cover-tiles aspect-ratio: 1/1, fallback-градиент из -track-mood × -track-tint, duration chip, play-overlay при hover, Fraunces title.

Извлечение метаданных. Из ID3-тегов (npm music-metadata): artist, title,

APIC frame → covers/{id}.jpg. Из YouTube: uploader → artist, thumbnail → cover. Backfill при первом GET /api/tracks.

Резюме главы 6. Полнофункциональный веб-прототип с трёхзвенной архитектурой и синхронизированным шестипанельным дашбордом; итеративный редизайн (glass theme, Vibe Mode, галерея, метаданные) превратил академический дашборд в продуктовый интерфейс.

Глава 7

Анализ результатов и ограничения

Глава суммирует ответы на исследовательские вопросы RQ1–RQ5, фиксирует финальную конфигурацию модели, идентифицирует ограничения и сопоставляет результаты с state-of-the-art.

§ 7.1. Сводные ответы на исследовательские вопросы

RQ1 (мульти-задачная CNN): положительный с оговорками. CNN v2 конкурентна на трёх из четырёх задач: Genre 83,9 % (в диапазоне CNN-baseline 75–87 % [6; 27]), Arousal 62,0 %, Valence 51,7 % (близко к single-task SOTA на DEAM [33; 38]), Segment 35,3 % (в типичном диапазоне 6-классовой section labeling 30–45 % [15; 37]). MTL не привело к катастрофической деградации относительно single-task baseline (ablation §5.7).

RQ2 (temporal modeling — BiLSTM): смешанный. BiLSTM улучшает arousal (+0,3) и valence (+2,5) для CNN+BiLSTM, но резко вредит genre (−23) из-за переобучения на 699 GTZAN-треков. Для PANNs+BiLSTM эффект мягче (frozen backbone). Главный недостаток — сокращение числа обучающих примеров (~500 последовательностей против ~16 К окон).

RQ3 (качество признаков — PANNs vs from-scratch): PANNs не дают преимущества. PANNs+Linear проигрывает CNN v2 на 3 из 4 задач (Segment −11,3, Arousal −0,8, Genre −2,0; только Valence +2,1). AudioSet-pretraining оптимизирован под звуковые события, не под структурный музыкальный анализ;

§ 7.3. Ограничения текущего подхода

- OOD на современной музыке. Жанровая голова обучена на GTZAN-2002 (10 устаревших классов); electronic, ambient, lo-fi, phonk, hyperpop не представлены. Поведение: электроника и ambient → classical (fallback для не-ударного инструментального), lo-fi → hip-hop по drum-паттернам. Mitigation в прототипе: top-3 + confidence warning + подпись к панели. Долгосрочно: дообучение на FMA (161 субжанр) или MagnaTagATune (188 multi-label).
- Нижний предел сегментной задачи. Section labeling 40,6 % (AST) ограничен класс-имбалансом (Verse+Chorus = 60 % окон Harmonix), annotator disagreement 25 % [7], acoustic ambiguity (Verse/Pre-chorus, Intro/Outro) и domain shift (Harmonix — преимущественно поп 2000-х). Post-processing повышает Boundary F1 с 0,31 до 0,45 (+14 п.п.), но фундаментальный потолок ≈ 50 % без новых данных; долгосрочно — SALAMI (classical/jazz/world) или synthetic augmentation.
- Размер и латентность. Checkpoint 574 МБ, inference 8 с на 3-минутный трек — непригодно для mobile, real-time и batch (~2,2 ч на 1000 треков). Mitigation: переключение на CNN v2 (21 МБ, 2 с) через `serve_ml.py -ckpt checkpoints/cnn_v2/best.pt` (−5,3 п.п. сегмент, +2,4 п.п. жанр). Долгосрочно — knowledge distillation AST→CNN и INT8-квантизация.
- Single-label genre. Модель предсказывает один жанр, хотя реальные треки часто мульти-жанровые (pop-rock, electronic-jazz). Mitigation: top-3 в UI. Долгосрочно — multi-label датасет + BCE + threshold-based prediction.
- Длинные треки. AST обрабатывает окна по 10 с с шагом 1 с; для треков >8 мин память для per-frame predictions влияет на UI. Протестировано до 5 минут. Долгосрочно — streaming inference со скользящим окном или иерархический анализ.

§ 7.4. Сравнение с state-of-the-art

Таблица 7.1: Сравнение результатов настоящей работы с literature

Задача	Метрика	Наша модель	SOTA	Источник
Genre (GTZAN)	Accuracy	83,9 % (CNN v2)	89 %	AST [14]
Arousal (DEAM 3-cl)	Accuracy	64,9 % (PANNS+LSTM)	70 %	Won 2020 [38]
Valence (DEAM 3-cl)	Accuracy	55,0 % (PANNS+LSTM)	60 %	Won 2020 [38]
Section (Harmonix 6-cl)	Accuracy	40,6 % (AST v2)	~45 %	Wang 2022 [37]
Section	Boundary F1	$\pm 30,45$ (AST v2 + postproc)	0,62	Gong 2023 [15]

Наши результаты на 5–8 п.п. ниже SOTA. Причины: (1) меньший вычислительный бюджет (один GPU 12 ГБ и 3 ч обучения против $4 \times A100$ и недель); (2) многозадачность (4 задачи одновременно — типичный multi-task tax 3–7 %); (3) меньшие данные (743 трека Harmonix против 3000+ в SALAMI+Beatles+Isophonics); (4) production-prototype ограничивает бюджет на чистый ML. Несмотря на разрыв, работа демонстрирует первую известную автору реализацию мульти-задачной модели для одновременного анализа структуры, эмоций и жанра в едином академически-документированном прототипе с web-интерфейсом.

§ 7.5. Научная новизна и практическая

ЗНАЧИМОСТЬ

Научная новизна. (1) Систематическое сравнение пяти архитектур для мульти-задачного MIR на едином датасете — отсутствует в literature (обычно 2–3). (2) Документированный negative result CNN v3 — академически честное сообщение о провале aggressive reweighting. (3) Композитный post-processing pipeline (Viterbi + position priors + iterative min-duration merge) с количе-

ственной оценкой вклада каждого компонента. (4) OOD honest UX — top-3 + confidence warning как pattern для academic-honest классификации.

Практическая значимость. Open-source прототип для исследований и обучения; воспроизводимый pipeline по конфигам в configs/; демонстрационная система для musicians/researchers/music-apps developers; базис для real-time inference, mobile deployment и новых датасетов.

Резюме главы 7. Ответы на RQ1–RQ5 подтверждают применимость мульти-задачного DL к MIR с trade-off между задачами. Финальная модель — AST v2 + Viterbi post-processing, среднее качество 58,5 %, segment 40,6 %. Идентифицированы 5 групп ограничений с mitigation в текущей реализации. Разрыв со SOTA 5–8 п.п. — приемлемый для первой комплексной мульти-задачной реализации с production-prototype.

Заключение

Основные результаты

Решены все поставленные задачи и достигнута основная цель — разработан прототип системы автоматического мульти-задачного анализа музыкальных композиций.

- 1) Реализованы и обучены пять архитектур мульти-задачных моделей (CNN с SE-блоками, CNN + BiLSTM, PANNs + Linear, PANNs + BiLSTM, AST) и проведены четыре последовательных эксперимента (v1, v2, AST v2, CNN v3 как negative result).
- 2) Финальная модель AST v2 показала лучший совокупный результат: среднее ассурасу 58,5 %, сегмент 40,6 % (+5,3 п.п. к CNN v2), жанр 81,5 %.
- 3) Реализован композитный post-processing pipeline (Viterbi + musicological position priors + per-class min-duration), повышающий Boundary F1 на 14 пунктов и сокращающий число сегментов с 28 до 7,5 в среднем.
- 4) Разработан веб-прототип с трёхзвенной архитектурой (FastAPI / Elysia + Bun / React + Vite), синхронизированным дашбордом из шести панелей и полноэкранным Vibe Mode (WebGL2-шейдер).
- 5) Идентифицированы ограничения: OOD-эффект на современной музыке, потолок per-window ($\sim 55\%$), размер AST (574 МБ), отсутствие multi-label жанров.

Направления дальнейшей работы

- 1) Temporal-декодер BiLSTM/CRF поверх AST-эмбедингов — sequence-level предсказание структуры вместо per-window; по литературе даёт

+10–15 п.п. Boundary F1.

- 2) Дообучение жанровой головы на FMA-medium / MagnaTagATune с multi-label-предсказаниями — устраняет OOD-проблему.
- 3) Knowledge distillation AST $\rightarrow$ MobileViT для уменьшения модели в 10–20 раз и mobile deployment.
- 4) Streaming inference через скользящее окно для треков произвольной длительности с фиксированной памятью.
- 5) Real-time оптимизация (< 100 мс на окно) для DJ-инструментов и ритм-игр.
- 6) Перспективно: joint training с генеративными задачами, self-supervised pretraining на музыкальных данных, cross-modal extension.

Список литературы

- [1] A Tutorial on Deep Learning for Music Information Retrieval / K. Choi, G. Fazekas, M. Sandler [и др.] // arXiv preprint arXiv:1709.04396. — 2017.
- [2] Aljanaki, A. Developing a benchmark for emotional analysis of music / A. Aljanaki, Y.-H. Yang, M. Soleymani // PLoS ONE. — 2017. — Т. 12, № 3. — e0173392.
- [3] An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale / A. Dosovitskiy, L. Beyer, A. Kolesnikov [и др.] // International Conference on Learning Representations (ICLR). — 2021.
- [4] AudioSet: An ontology and human-labeled dataset for audio events / J. F. Gemmeke, D. P. W. Ellis, D. Freedman [и др.] // ICASSP. — 2017. — С. 776—780.
- [5] Caruana, R. Multitask Learning / R. Caruana // Machine Learning. — 1997. — Т. 28, № 1. — С. 41—75.
- [6] Convolutional recurrent neural networks for music classification / K. Choi, G. Fazekas, M. Sandler [и др.] // ICASSP. — 2017. — С. 2392—2396.
- [7] Design and Creation of a Large-Scale Database of Structural Annotations / J. B. L. Smith, J. A. Burgoyne, I. Fujinaga [и др.] // ISMIR. — 2011.
- [8] Downie, J. S. Music Information Retrieval / J. S. Downie // Annual Review of Information Science and Technology. — 2003. — Т. 37, № 1. — С. 295—340.
- [9] ESSENTIA: an audio analysis library for music information retrieval / D. Bogdanov, N. Wack, E. Gómez [и др.] // ISMIR. — 2013. — С. 493—498.
- [10] Evaluation of algorithms using games: The case of music tagging / E. Law, K. West, M. Mandel [и др.] // ISMIR. — 2009. — С. 387—392.
- [11] FMA: A dataset for music analysis / M. Defferrard, K. Benzi, P. Vandergheynst [и др.] // ISMIR. — 2017.

-
- [12] Focal Loss for Dense Object Detection / T.-Y. Lin, P. Goyal, R. Girshick [и др.] // ICCV. — 2017. — С. 2980—2988.
 - [13] Foote, J. Automatic audio segmentation using a measure of audio novelty / J. Foote // IEEE International Conference on Multimedia and Expo (ICME). — 2000. — С. 452—455.
 - [14] Gong, Y. AST: Audio Spectrogram Transformer / Y. Gong, Y.-A. Chung, J. Glass // Interspeech. — 2021. — С. 571—575.
 - [15] Gong, Y. Music Structural Segmentation with Pretrained Audio Spectrogram Transformers / Y. Gong, J. Glass // ICASSP. — 2023.
 - [16] Hevner, K. Experimental studies of the elements of expression in music / K. Hevner // American Journal of Psychology. — 1936. — Т. 48, № 2. — С. 246—268.
 - [17] Hochreiter, S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // Neural Computation. — 1997. — Т. 9, № 8. — С. 1735—1780.
 - [18] Howard, J. Universal Language Model Fine-tuning for Text Classification / J. Howard, S. Ruder // ACL. — 2018. — С. 328—339.
 - [19] Hu, J. Squeeze-and-Excitation Networks / J. Hu, L. Shen, G. Sun // IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2018. — С. 7132—7141.
 - [20] Lartillot, O. MIR in Matlab (II): A Toolbox for Musical Feature Extraction from Audio / O. Lartillot, P. Toivainen // ISMIR. — 2007. — С. 127—130.
 - [21] madmom: A new Python audio and music signal processing library / S. Böck, F. Korzeniowski, J. Schlüter [и др.] // ACM Multimedia. — 2016. — С. 1174—1178.
 - [22] McFee, B. Analyzing song structure with spectral clustering / B. McFee, D. P. W. Ellis // International Society for Music Information Retrieval Conference (ISMIR). — 2014. — С. 405—410.
 - [23] mixup: Beyond Empirical Risk Minimization / H. Zhang, M. Cisse, Y. N. Dauphin [и др.] // ICLR. — 2018.
 - [24] Music Structure Analysis Using Convolutional Neural Networks and Hidden Markov Models / J. Serrà, M. Müller, P. Grosche [и др.] // ICASSP. — 2018.
 - [25] PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition / Q. Kong, Y. Cao, T. Iqbal [и др.] // IEEE/ACM Transactions on Audio, Speech, and Language Processing. — 2020. — Т. 28. — С. 2880—2894.

-
- [26] Russell, J.A. A circumplex model of affect / J.A. Russell // Journal of Personality and Social Psychology. — 1980. — Т. 39, № 6. — С. 1161—1178.
- [27] Sigtia, S. Improved music feature learning with deep neural networks / S. Sigtia, S. Dixon // ICASSP. — 2014. — С. 6959—6963.
- [28] SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition / D.S. Park, W. Chan, Y. Zhang [и др.] // Interspeech. — 2019. — С. 2613—2617.
- [29] Stevens, S.S. A scale for the measurement of the psychological magnitude pitch / S.S. Stevens, J. Volkman, E. B. Newman // The Journal of the Acoustical Society of America. — 1937. — Т. 8, № 3. — С. 185—190.
- [30] Sturm, B.L. The state of the art ten years after a state of the art: Future research in music information retrieval / B.L. Sturm // Journal of New Music Research. — 2014. — Т. 43, № 2. — С. 147—172.
- [31] The Harmonix Set: Beats, Downbeats, and Functional Segment Annotations of Western Popular Music / O. Nieto, M. McCallum, M. E. P. Davies [и др.] // ISMIR. — 2019. — С. 565—572.
- [32] The Million Song Dataset / T. Bertin-Mahieux, D. P. W. Ellis, B. Whitman [и др.] // ISMIR. — 2011. — С. 591—596.
- [33] Towards Time-Varying Music Auto-Tagging based on CAL500 Expansion / S.-Y. Wang, J.-C. Wang, Y.-H. Yang [и др.] // IEEE International Conference on Multimedia and Expo (ICME). — 2017.
- [34] Tzanetakis, G. Musical genre classification of audio signals / G. Tzanetakis, P. Cook // IEEE Transactions on Speech and Audio Processing. — 2002. — Т. 10, № 5. — С. 293—302.
- [35] Ullrich, K. Boundary detection in music structure analysis using convolutional neural networks / K. Ullrich, J. Schlüter, T. Grill // ISMIR. — 2014. — С. 417—422.
- [36] Unsupervised Music Structure Annotation by Time Series Structure Features and Segment Similarity / J. Serrà, M. Müller, P. Grosche [и др.] // IEEE Transactions on Multimedia. — 2014. — Т. 16, № 5. — С. 1229—1240.
- [37] Wang, J.-C. To catch a chorus, verse, intro, or anything else: Analyzing a song with structural functions / J.-C. Wang, Y.-N. Hung, J. B. L. Smith // IEEE/ACM Transactions on Audio, Speech, and Language Processing. — 2022. — Т. 30.

- [38] Won, M. Toward interpretable music tagging with self-attention / M. Won, S. Chun, X. Serra // arXiv preprint arXiv:1906.04972. — 2020.

Приложение А

Описание датасетов

Таблица А.1: Сводные характеристики используемых датасетов

Параметр	DEAM	Harmonix Set	GTZAN
Источник	MediaEval 2013–2018	Nieto et al., 2019	Tzanetakis & Cook, 2002
Размер исходный	1802 фрагмента	912 треков	1000 файлов
Использовано	1802 (все)	743 (через yt-dlp)	999
Длительность	45 с каждый	3:43 среднее	30 с каждый
Sample rate	44100 Гц → 22050	Варьируется → 22050	22050 Гц mono
Лицензия	CC (FMA)	MIT (анн.) + YouTube	Public domain
Аннотации	arousal/valence (0,5 с)	section labels (17 → 6)	genre (10 классов)
Inter-ann. agreement	$\rho_a = 0,59$; $\rho_v = 0,55$	~ 75% section	—

DEAM используется для обучения голов arousal_cls / valence_cls (3 класса каждая, дискретизация порогами $\pm 0,2$) и регрессионных голов.

Harmonix Set маппинг 17→6 классов сегментов:

intro*	-> Intro
verse*, theme	-> Verse
bridge, transition*	-> Bridge
chorus*, hook	-> Chorus

instrumental , solo	-> Instrumental
outro , fadeout	-> Outro

GTZAN — жанры: blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, rock (по 100 треков).

Приложение Б

Гиперпараметры экспериментов

Таблица В.1: Сводные гиперпараметры трёх конфигураций

Параметр	CNN v2	AST v2	CNN v3 (fail)
Optimizer	AdamW	AdamW	AdamW
LR	1,0e-3	5e-5 (bb) / 1e-3 (h)	1,0e-3
Weight decay	5e-4	0,01	5e-4
Batch size	64	16 (ga=4)	64
Epochs (patience)	50 (15)	30 (10)	50 (15)
Scheduler	cosine WR ($T_0 = 10$)	cosine WR	cosine WR
Loss	Focal ($\gamma = 1,5$)	Focal (1,5)	Focal (2,5)
Max class weight	2,5	2,5	3,5
Mixup α	0,2	—	0,2
Dropout	0,4	0,3	0,4
Segment loss weight	1,5	1,5	3,5
AST freeze_layers	—	8 (из 12)	—
Trainable params	~ 800 тыс.	~ 14,4 млн	~ 800 тыс.

Общие для всех конфигураций: window=10 с, hop=1 с, $n_{\text{mels}} = 128$, hop_length=512, SpecAugment (freq_mask=27, time_mask=60, $n = 2$), seed=42.

Приложение В

Confusion matrices и графики

Графические результаты сохранены в `results/plots/`:

- `cnn_v2/cm_{segment,arousal,valence,genre}.png` — confusion matrices CNN v2.
- `ast_v2/cm_{segment,arousal,valence,genre}.png` — confusion matrices AST v2.
- `comparison_5configs.png` — сравнение 5 архитектур по 4 задачам.
- `factorial_heatmap.png` — тепловая карта 2×2-дизайна.
- `v1_vs_v2_cnn.png` — изменения метрик $v1 \rightarrow v2$.
- `timeline_example.png`, `timeline_classical.png` — примеры инференса.

Приложение Г

JSON-схема timeline

Структура ответа `/api/tracks/:id`:

```
{
  "id": "uuid", "filename": "uuid.mp3",
  "timeline": {
    "metadata": {
      "duration_sec": 204.1,
      "window_seconds": 10.0, "hop_seconds": 1.0
    },
    "segment": [
      { "start": 0.0, "end": 8.0,
        "label": "Chorus", "confidence": 0.63 }, ...
    ],
    "arousal": [...], "valence": [...], "genre": [...],
    "frame_predictions": {
      "segment_probs": [[0.18, 0.13, ...], ...],
      "arousal_reg": [0.36, 0.38, ...],
      "valence_reg": [0.42, 0.45, ...]
    },
    "audio_features": {
      "tempo_bpm": 123.0,
      "key": { "key": "F", "mode": "Minor", "confidence": 0.78 }
    }
  }
}
```

Приложение Д

CLI-команды воспроизведения

```
# Environment
source .venv/bin/activate      # Linux/Mac
.venv/Scripts/activate        # Windows

# Data preparation
python scripts/prepare_deam.py      --data-dir data/deam
python scripts/download_harmonix_audio.py --data-dir data/structure
python scripts/prepare_structure.py --data-dir data/structure
python scripts/prepare_gtzan.py     --data-dir data/gtzan

# Training (example: final AST v2)
python scripts/train.py --config configs/ast.yaml \
  --deam-dir data/deam --structure-dir data/structure \
  --gtzan-dir data/gtzan --output-dir checkpoints/ast_v2

# Evaluation and inference
python scripts/eval.py --ckpt checkpoints/ast_v2/best.pt \
  --config configs/ast.yaml --output results/eval_ast_v2.csv \
  --deam-dir data/deam --structure-dir data/structure --gtzan-dir
  data/gtzan
python scripts/infer.py --audio path/to/song.mp3 \
  --ckpt checkpoints/ast_v2/best.pt --config configs/ast.yaml \
  --output results/timeline.json --plot results/timeline.png

# Web prototype (three services in one command)
bun run scripts/dev-all.ts      # ml-api:8000, backend:3000, frontend
  :5173

# Tests and linter
pytest tests/ -v                # 128 tests
ruff check musicml/ scripts/ tests/
```