

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФГБОУ ВО «Тверской государственный университет»

Факультет прикладной математики и кибернетики

Кафедра информационных технологий

ОТЧЁТ
о научно-исследовательской работе

Тема:

**Модуль автоматического анализа
музыкальных композиций на основе
мульти-задачного глубокого обучения**

Выполнил:

магистрант 2 курса

Антонов М. Д.

Научный руководитель:

доцент кафедры ИТ

Кудряшов М. Ю.

Тверь, 2026

Содержание

Введение	7
Актуальность работы	7
Цель и задачи работы	7
Объект и предмет исследования	8
Научная новизна	8
Практическая значимость	9
Структура работы	9
1 Обзор предметной области	10
1.1 Music Information Retrieval как научная дисциплина	10
1.1.1 Признаковое представление аудио	11
1.2 Структурная сегментация музыкальных композиций	12
1.2.1 Классические подходы	12
1.2.2 Подходы на основе глубокого обучения	13
1.2.3 Ограничения существующих подходов	13
1.3 Распознавание эмоций в музыке	14
1.3.1 Дискретные категории (categorical model)	14
1.3.2 Непрерывные шкалы — Russell circumplex model	14
1.3.3 Дискретизация в категории	15
1.3.4 Подходы к решению	16
1.4 Классификация жанров	16
1.5 Архитектуры аудио-классификаторов	17
1.5.1 Свёрточные нейронные сети (CNN)	17
1.5.2 Squeeze-and-Excitation (SE)	18
1.5.3 BiLSTM для temporal modeling	18
1.5.4 PANNs — pretraining на AudioSet	18
1.5.5 Audio Spectrogram Transformer (AST)	19
1.6 Multi-task learning в MIR	20
1.7 Pretraining + fine-tuning paradigm	21
2 Постановка задачи	22
2.1 Цель исследования	22
2.1.1 Формальная постановка	23

2.2	Исследовательские вопросы	24
2.3	Обоснование мульти-задачного подхода	25
2.3.1	Семантические корреляции между задачами	25
2.3.2	Регуляризация через shared backbone	25
2.3.3	Практическая ценность для пользователя	26
3	Данные	26
3.1	Используемые датасеты	27
3.1.1	DEAM (Database for Emotional Analysis of Music) . . .	27
3.1.2	Harmonix Set	28
3.1.3	GTZAN	29
3.2	Извлечение признаков	30
3.2.1	Конфигурация спектрограммы	30
3.2.2	Окновая нарезка (windowing)	30
3.2.3	Глобальная нормализация	31
3.3	Стратегия разбиения train/val/test	31
3.4	Дисбаланс классов	32
4	Архитектура и методы	34
4.1	Обзор многоархитектурного эксперимента	34
4.2	CNN backbone (конфигурация 1)	35
4.2.1	Архитектура	35
4.2.2	Squeeze-and-Excitation как механизм channel attention .	36
4.2.3	Shared FC проекция	36
4.3	CNN + BiLSTM (конфигурация 2)	37
4.4	PANNs+Linear и PANNs+BiLSTM (конфигурации 3, 4)	37
4.5	Audio Spectrogram Transformer v2 (конфигурация 5, финальная)	38
4.5.1	Базовая архитектура	38
4.5.2	Pretraining на AudioSet	39
4.5.3	Стратегия fine-tuning	39
4.5.4	Differential learning rate	40
4.5.5	Gradient accumulation	40
4.5.6	Обоснование выбора AST	41
4.6	Multi-task heads и функция потерь	41
4.6.1	Структура голов	41

4.6.2	Focal Loss	42
4.6.3	Class weights	42
4.6.4	Per-task loss weight	42
4.6.5	Оптимизатор и scheduler	43
4.6.6	SpecAugment	43
4.6.7	MixUp	43
4.7	Post-processing pipeline	44
4.7.1	Этап 1: Viterbi-декодирование с transition penalty	44
4.7.2	Этап 2: Musicological position priors	45
4.7.3	Этап 3: Iterative min-duration merge	46
4.7.4	Эффект пост-процессинга на качество	46
4.8	Inference и нормализация на пользовательских аудио	47
5	Эксперименты	48
5.1	Протокол оценки	48
5.1.1	Метрики	48
5.1.2	Train/val/test протокол	48
5.1.3	Random baselines	49
5.2	Гиперпараметры обучения	49
5.3	Эксперимент v1 (baseline-запуск)	50
5.3.1	Конфигурация v1	50
5.3.2	Результаты v1	51
5.3.3	Диагностика проблем v1	51
5.4	Эксперимент v2 (улучшенный запуск)	52
5.4.1	Изменения относительно v1	52
5.4.2	Результаты v2	54
5.4.3	Сравнение v1 $\rightarrow$ v2	54
5.4.4	Per-class разбор сегментов (CNN v2)	55
5.4.5	Ответы на RQ1–RQ4	55
5.5	Эксперимент AST v2 (расширение трансформер-архитектурой)	56
5.5.1	Мотивация	56
5.5.2	Конфигурация AST v2	56
5.5.3	Результаты AST v2	57
5.5.4	Ответ на RQ5	57
5.6	Эксперимент CNN v3 (failed retrain)	58

5.6.1	Мотивация	58
5.6.2	Конфигурация CNN v3	58
5.6.3	Результаты CNN v3	59
5.6.4	Анализ провала	59
5.6.5	Что мы извлекли	59
5.7	Сводная таблица всех 6 моделей	60
5.8	Ablation: вклад post-processing pipeline	61
6	Прототип системы	63
6.1	Архитектура веб-приложения	63
6.1.1	Трёхзвенная структура	63
6.1.2	Объединённый запуск (dev-all.ts)	64
6.2	Synchronized music dashboard	65
6.2.1	Архитектурный фреймворк синхронизации	65
6.2.2	Шесть аналитических панелей	66
6.2.3	Shared cursor layer	69
6.3	Ключевые UX-решения	69
6.3.1	Топ-3 жанров + confidence warning	69
6.3.2	Russell circumplex по классификации, не регрессии	70
6.3.3	Display name эвристика	70
6.3.4	Loading skeletons и empty states	71
6.3.5	Поиск и сортировка треков	71
6.3.6	Приглушённая палитра	71
6.4	Endpoint мел-спектрограммы	72
6.5	Технологический стек и обоснование	73
7	Анализ результатов и ограничения	74
7.1	Сводные ответы на исследовательские вопросы	74
7.1.1	RQ1: Эффективность мульти-задачной CNN	74
7.1.2	RQ2: Вклад temporal modeling (BiLSTM)	75
7.1.3	RQ3: Качество признаков (PANNs vs from-scratch)	75
7.1.4	RQ4: Главный фактор влияния	75
7.1.5	RQ5: Audio Spectrogram Transformer	75
7.2	Финальная модель прототипа	76
7.3	Ограничения текущего подхода	76

7.3.1	Out-of-distribution на современной музыке	76
7.3.2	Сегментная задача — нижний предел качества	77
7.3.3	Размер и латентность модели	78
7.3.4	Отсутствие multi-label genre	78
7.3.5	Нет поддержки длинных треков	79
7.4	Сравнение с современным state-of-the-art	79
7.5	Научная новизна и практическая значимость	80
7.5.1	Научная новизна	80
7.5.2	Практическая значимость	81
Заключение		81
	Основные результаты работы	81
	Научная новизна и вклад	82
	Направления дальнейшей работы	83
	Заключительное слово	84
Список использованных источников		84
A Описание датасетов		88
A.1	DEAM (Database for Emotional Analysis of Music)	88
A.2	Harmonix Set	89
A.3	GTZAN	90
B Гиперпараметры экспериментов		90
B.1	Финальная конфигурация (default.yaml для CNN/PANNS/BiLSTM)	90
B.2	AST v2 (ast.yaml)	92
B.3	CNN v3 (failed experiment, cnn_v3.yaml)	92
C Confusion matrices		92
D Скриншоты прототипа		93
E JSON-схема timeline		93
F CLI-команды для воспроизведения		94
F.1	Подготовка данных	94
F.2	Обучение моделей	95

F.3	Оценка моделей	95
F.4	Инференс на одном файле	96
F.5	Запуск веб-прототипа	96
F.6	Тесты и качество кода	96

Введение

Актуальность работы

Современные музыкальные приложения — стриминговые сервисы, ритм-игры, инструменты для DJ-микширования, образовательные платформы, рекомендательные системы — всё чаще требуют **семантического понимания аудио**, а не просто его воспроизведения. Пользователю или алгоритму необходимо знать: где в треке начинается припев, насколько музыка эмоциональна, к какому жанру относится фрагмент, какова его структурная разметка во времени.

Решение этих задач вручную невозможно при объёмах современных каталогов: только Spotify содержит более 100 миллионов треков. Автоматизация анализа музыки через методы машинного обучения — единственный путь масштабирования. Развитие глубоких нейронных сетей за последние годы сделало возможным качественный прорыв в этой области, однако **существующие решения остаются фрагментированными**: каждая задача (структурный анализ, распознавание эмоций, классификация жанров) обычно решается отдельной специализированной моделью. Это приводит к избыточным вычислениям, несогласованности результатов и сложности интеграции.

Настоящая работа исследует возможность **унификации** четырёх ключевых задач музыкального анализа в рамках одной мульти-задачной модели глубокого обучения с интерактивной демонстрацией результатов через веб-прототип.

Цель и задачи работы

Цель: разработать прототип системы автоматического многоаспектного анализа музыкальных композиций на основе мульти-задачной модели глубокого обучения, формирующей по входному аудиотреку структурную, эмоциональную и жанровую разметку во времени.

Для достижения цели поставлены следующие задачи:

1. Провести обзор современного состояния области Music Information Retrieval, выявить характерные подходы и ограничения существующих решений.
2. Подготовить обучающий корпус из трёх открытых датасетов (DEAM,

Harmonix Set, GTZAN) с унифицированным пайплайном предобработки.

3. Разработать и реализовать пять архитектур мульти-задачных моделей, охватывающих ключевые подходы (CNN, BiLSTM, PANNs, Audio Spectrogram Transformer).
4. Провести экспериментальное сравнение архитектур и выявить наилучшую конфигурацию.
5. Реализовать пост-обработку предсказаний модели с учётом музыкальных априори (Viterbi-декодирование, position priors, slim-duration merge).
6. Разработать веб-прототип с синхронизированным дашбордом из шести аналитических панелей для интерактивной демонстрации возможностей системы.
7. Идентифицировать ограничения подхода и сформулировать направления дальнейшей работы.

Объект и предмет исследования

Объект исследования — методы автоматического анализа цифровых аудиозаписей музыки на основе глубокого обучения.

Предмет исследования — мульти-задачные нейросетевые архитектуры и пост-обработка их предсказаний для задач структурной сегментации, распознавания эмоций (arousal/valence) и классификации жанров.

Научная новизна

Научная новизна работы заключается в следующем:

1. Проведено систематическое сравнение пяти архитектур мульти-задачных моделей (CNN, CNN+BiLSTM, PANNs+Linear, PANNs+BiLSTM, AST) на едином корпусе DEAM+Harmonix+GTZAN, отвечающее на пять исследовательских вопросов о вкладе различных факторов (temporal modeling, pretraining, transformer architecture).
2. Предложен и количественно оценен композитный pipeline пост-обработки сегментных предсказаний, объединяющий Viterbi-декодирование с musicologic

position priors и итеративное слияние коротких сегментов. Pipeline даёт прирост Boundary F1 на 14 пунктов относительно сырых argmax-предсказаний.

3. Разработан и документирован паттерн «академически честного UX» для классификационных моделей с ограниченным набором категорий обучающего датасета — отображение top-3 предсказаний с предупреждением о низкой уверенности при out-of-distribution входных данных.
4. Документирован negative result эксперимента CNN v3 (failed retrain с агрессивной перебалансировкой class weights) — академически ценный отрицательный результат, редко публикуемый в литературе.

Практическая значимость

Практическая значимость работы:

1. **Open-source прототип системы**, доступный для исследовательских и образовательных целей: полный исходный код, обученные модели, документация эксперимента.
2. **Воспроизводимый pipeline** обучения и оценки: все эксперименты воспроизводимы по предоставленным конфигурационным файлам.
3. **Демонстрационная система**, пригодная для презентации возможностей deep learning в анализе музыки конечным пользователям — музыкантам, исследователям, разработчикам музыкальных приложений.
4. **Базовая платформа** для дальнейших исследований: расширение на real-time inference, mobile deployment, дообучение на современных датасетах — естественные следующие шаги на основе предоставленной инфраструктуры.

Структура работы

Работа состоит из введения, семи глав, заключения, списка использованных источников и шести приложений.

- **Глава 1** содержит обзор предметной области MIR, анализ существующих подходов к решаемым задачам и обоснование выбора архитектурных направлений настоящей работы.

- **Глава 2** формулирует постановку задачи, исследовательские вопросы и обоснование мульти-задачного подхода.
- **Глава 3** описывает используемые датасеты, схему предобработки признаков и стратегию разбиения на train/val/test.
- **Глава 4** представляет архитектурные решения: пять конфигураций моделей, multi-task функцию потерь, post-processing pipeline.
- **Глава 5** содержит экспериментальную часть: четыре эксперимента (v1, v2, AST v2, CNN v3), сводное сравнение всех конфигураций, ablation post-processing.
- **Глава 6** описывает реализованный веб-прототип: трёхзвенную архитектуру, синхронизированный дашборд, ключевые UX-решения.
- **Глава 7** обобщает результаты, идентифицирует ограничения и сравнивает с современным state-of-the-art.

В заключении формулируются основные результаты работы и направления дальнейших исследований. Приложения содержат описание датасетов, гиперпараметры экспериментов, confusion matrices, скриншоты прототипа, JSON-схему timeline и CLI-команды для воспроизведения.

Общий объём основного текста — около 80 страниц, включая 25 таблиц и 12 рисунков. Список литературы содержит 38 источников.

1 Обзор предметной области

1.1 Music Information Retrieval как научная дисциплина

Music Information Retrieval (MIR) — междисциплинарная область, объединяющая методы обработки сигналов, машинного обучения, музыкальной теории и психоакустики для извлечения семантической информации из аудиозаписей музыки. Сформировалась как самостоятельное направление в начале 2000-х годов с учреждением ежегодной конференции ISMIR (International Society for Music Information Retrieval) в 2000 году [1].

Типичные задачи MIR делятся на несколько групп:

Классификация на уровне трека — модель присваивает целому аудио-файлу одну или несколько меток. Сюда относятся определение жанра (genre

classification), исполнителя (artist identification), настроения (mood detection), языка вокала. Эти задачи близки к задачам компьютерного зрения image classification

Покадровая разметка (frame-level labeling) — модель формирует временной ряд предсказаний с заданным шагом. Примеры: транскрипция нот (note onset detection), оценка темпа (tempo tracking), определение тональности (key estimation), извлечение хора (chord recognition).

Сегментация (segmentation) — модель разбивает трек на непрерывные интервалы по структурному, эмоциональному или акустическому признаку. К этой группе принадлежат задачи структурного анализа (Music Structure Analysis), сегментации по эмоциям (emotion segmentation), детекции тишины и переходов.

Регрессия на непрерывных шкалах — оценка непрерывных величин: arousal/valence (по шкалам Russell), tempo BPM, loudness LUFS.

Generative задачи — синтез музыки, генерация аккомпанемента, source separation. В рамках настоящей работы не рассматриваются.

Настоящая работа фокусируется на трёх задачах второй группы (покадровая разметка) и одной задаче первой группы (классификация жанра), решаемых одновременно средствами мульти-задачной модели. Такая постановка отражает практическую потребность создания **полной семантической разметки** аудиотрека для пользовательских приложений: автоматического создания превью, ритм-игр, музыкальных рекомендательных систем.

1.1.1 Признаковое представление аудио

Базовым представлением для MIR-моделей с 2010-х годов является **мел-спектрограмма** — двумерное представление частотно-временной структуры сигнала, где частотная ось преобразована из линейного герцевого масштаба в перцептивно равномерную мел-шкалу [2]. Для последующего применения свёрточных сетей логарифмическая компрессия амплитуды (`librosa.power_to_` дополнительно сглаживает динамический диапазон. Получаемое представление (log-mel) сравнимо по информативности с человеческим восприятием тембра и достаточно для большинства классификационных задач.

В данной работе используется log-mel с параметрами: 128 мел-полос (диапазон 30–11025 Гц при sample rate 22050 Гц), окно STFT 2048 семплов, hop 512 семплов (≈ 23 мс). Эти значения соответствуют общепринятым прак-

тикам в литературе [3; 4].

Альтернативные представления — chroma (12-полосная гистограмма по нотам), MFCC (мел-кепстральные коэффициенты), constant-Q спектрограмма (CQT) — рассматривались на этапе ablation, но не вошли в финальную модель: вклад chroma в качество классификации оказался несущественным (≤ 1 п.п. accuracy), а вычислительные затраты на CQT при сравнимом качестве не оправданы.

1.2 Структурная сегментация музыкальных композиций

Задача структурной сегментации (Music Structure Analysis, MSA) состоит в автоматическом разбиении аудиотрека на смысловые фрагменты, соответствующие музыкальной форме: вступление (Intro), куплет (Verse), припев (Chorus), бридж (Bridge), инструментальная часть (Instrumental), завершение (Outro). Задача решается на двух уровнях:

1. **Boundary detection** — обнаружение моментов структурных переходов без присвоения меток.
2. **Section labeling** — классификация выделенных интервалов в одну из заранее определённых категорий.

Совмещение обеих подзадач в единой модели остаётся открытой проблемой: 6-классовая section labeling считается одной из наиболее сложных задач MIR, поскольку различия между Verse и Chorus определяются не только спектральными признаками, но и контекстом всей композиции (повторяемостью, динамикой, аранжировкой).

1.2.1 Классические подходы

До эпохи глубокого обучения структурная сегментация решалась через явное моделирование само-подобия аудио. Ключевая структура — **self-similarity matrix (SSM)** [5], где элемент (i, j) отражает сходство признаков векторов в моментах i и j . Хор и куплет проявляются как яркие диагональные блоки на SSM, бриджи — как уникальные области без повторов.

На основе SSM строятся:

- **Novelty curve** (Foote, 2000) [5] — функция, измеряющая локальный

контраст SSM по диагонали; пики novelty curve соответствуют границам сегментов.

- **Convex hull algorithm** (Serrà, 2014) [6] — сегментация SSM через выпуклую оболочку диагональных проекций.
- **Spectral clustering на SSM** (McFee & Ellis, 2014) [7] — группировка похожих временных интервалов через лапласиан матрицы.

Достоинства классических методов: интерпретируемость, отсутствие необходимости в большом обучающем наборе, хорошее качество boundary detection (F1 до 0.6–0.7 на SALAMI). Недостатки: требуют тщательной настройки гиперпараметров под конкретный жанр, плохо обобщаются на сложные структуры (электронная музыка с пост-роковыми элементами), не решают section labeling без дополнительного классификатора.

1.2.2 Подходы на основе глубокого обучения

С 2014 года доминирующим направлением становятся свёрточные нейронные сети, обучаемые непосредственно на размеченных датасетах:

- **Ullrich et al., 2014** [8] — первая публикация о применении CNN к MSA. Авторы обучают модель предсказывать boundary indicator function (вероятность того, что данный фрейм является границей) на датасете SALAMI. Достигают $F1 \approx 0.46$ при допуске ± 3 секунды — превосходит классические методы.
- **Serrà et al., 2018** [9] — комбинирует CNN-предсказания с пост-обработкой через HMM с переходными вероятностями. Показывает, что temporal smoothing критичен для устранения «шума» CNN-предсказаний.
- **Wang et al., 2022** [10] — Transformer-based архитектура с self-attention над CNN-эмбедингами. Достигает $F1 \approx 0.55$ на SALAMI.
- **Gong & Glass, 2023** [11] — pure-attention модель на основе AST (см. §1.5.5), достигает $F1 \approx 0.62$ на Harmonix.

1.2.3 Ограничения существующих подходов

Несмотря на прогресс, MSA остаётся самой слабой задачей в ряду MIR-проблем. Типичные значения accuracy section labeling на 6 классах не превышают 40–45% [10; 11]. Основные причины:

1. **Class imbalance:** Verse и Chorus составляют 60–70% размеченного времени в датасетах вроде Harmonix; редкие классы (Outro, Instrumental) — менее 5%.
2. **Inter-annotator disagreement:** даже профессиональные музыканты расходятся в маркировке границ примерно в 15% случаев, в категории section — в 25% случаев [12].
3. **Acoustic similarity:** Intro и Outro акустически идентичны (разреженная фактура, сниженная динамика); их можно различить только по позиции в треке. Verse и Pre-chorus также часто неразличимы спектрально.
4. **Domain shift:** модели, обученные на классической поп-музыке (Harmonix), плохо обобщаются на электронную, экспериментальную, фолк-музыку.

Современные решения включают пост-обработку через НММ или Viterbi-декодирование с musicological priors [9; 11], что и применяется в настоящей работе (см. §4.7).

1.3 Распознавание эмоций в музыке

Задача Music Emotion Recognition (MER) состоит в автоматической оценке эмоциональной окраски аудиофрагмента. Существуют два основных подхода к формализации:

1.3.1 Дискретные категории (categorical model)

В этом подходе каждому фрагменту присваивается одна из заранее определённых эмоциональных меток: «happy», «sad», «aggressive», «calm». Корни подхода восходят к работам Hevner [13], предложившей восьмисекторную схему музыкальных аффектов. Современные датасеты (DEAP, MoodSwings) используют 4–8 базовых категорий.

Достоинства: интерпретируемость, прямая совместимость с user interface (emoji-теги). Недостатки: эмоциональное пространство дискретизируется субъективно, теряется тонкая градация.

1.3.2 Непрерывные шкалы — Russell circumplex model

Альтернатива — двумерное непрерывное пространство по Russell [14]:

- **Valence** — ось «приятное/неприятное» (по горизонтали, $x \in [-1, +1]$).
- **Arousal** — ось «активное/спокойное» (по вертикали, $y \in [-1, +1]$).

Russell показал, что большинство эмоциональных оценок музыки можно представить точкой в этом квадранте. Четыре квадранта получают семантические интерпретации:

Таблица 1: Семантика квадрантов Russell circumplex

Квадрант	Valence	Arousal	Семантика
Q1	+	+	Радостное (joyful, exhilarating)
Q2	−	+	Злое, тревожное (angry, anxious)
Q3	−	−	Грустное (sad, melancholic)
Q4	+	−	Умиротворённое (peaceful, calm)

DEAM dataset [15] предоставляет покадровые непрерывные аннотации arousal/valence для 1802 30-секундных фрагментов. Соглашение между аннотаторами (inter-annotator agreement) измеряется Pearson correlation и составляет $\rho \approx 0.55\text{--}0.65$ — что считается удовлетворительным для субъективной задачи такого рода.

1.3.3 Дискретизация в категории

Несмотря на привлекательность непрерывного подхода, для задач визуализации и пользовательского интерфейса дискретные категории информативнее. В настоящей работе непрерывные оценки DEAM квантизованы в 3 уровня по каждой оси (Low/Mid/High для arousal, Dark/Neutral/Bright для valence), что:

1. Снижает вариативность аннотаций (3 категории менее зависимы от субъективных порогов, чем непрерывная шкала).
2. Упрощает временную сегментацию (3-классовая `argmax` легко поддается `median filter`).
3. Сохраняет основную семантическую информацию (низкий/средний/высокий уровень).

При этом исходные непрерывные значения сохраняются как `regression targets` для дополнительной 2D-визуализации (Russell circumplex в прототипе системы — см. §6.2).

1.3.4 Подходы к решению

Для MER применяются те же архитектуры, что и для классификации — CNN (Choi et al., 2017 [16]), CRNN с BiLSTM (Wang et al., 2017 [17]), Transformer-based (Won et al., 2020 [18]). Текущий SOTA на DEAM 3-классовой arousal: 65–70% accuracy, valence: 55–60%. Разрыв между arousal и valence объясняется тем, что arousal сильнее коррелирует со спектральными признаками (громкость, темп, плотность атак), тогда как valence требует понимания мелодико-гармонического контекста, который CNN извлекает менее эффективно.

1.4 Классификация жанров

Genre classification — исторически первая задача MIR, начавшаяся с работы Tzanetakis & Cook (2002) [19], которые опубликовали датасет **GTZAN** — 1000 30-секундных фрагментов в 10 жанрах (blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock).

GTZAN остаётся стандартом сравнения уже более 20 лет, несмотря на известные ограничения [20]:

- Дубликаты треков (около 5% записей повторяются под разными метками).
- Ошибки маркировки (особенно в категориях rock/country/blues).
- Устаревшая таксономия — не отражает современные жанры (electronic, hip-hop subgenres, indie, lo-fi).

- Фрагменты по 30 секунд не передают долгосрочную структуру.

Современные альтернативы:

- **FMA (Free Music Archive)** [21] — 100 тыс. треков, 161 жанровая категория, multi-label.
- **MagnaTagATune** [22] — 25 тыс. фрагментов с 188 социальными тегами.
- **Million Song Dataset** [23] — метаданные 1 млн треков, в том числе пользовательские теги Last.fm.

В настоящей работе используется именно GTZAN — несмотря на ограничения — поскольку это позволяет напрямую сопоставить полученные результаты с обширной литературой и сохранить сравнимость с baseline-моделями.

Ограничения out-of-distribution (поведение на современных жанрах вне 10 категорий GTZAN) явно адресуются в прототипе системы через UI-механизм топ-3 классификаций с предупреждением о низкой уверенности (см. §6.3).

Текущие SOTA-результаты на GTZAN:

Таблица 2: SOTA-результаты на GTZAN

Архитектура	Год	Accuracy	Источник
MFCC + SVM	2002	61%	Tzanetakis [19]
CNN baseline	2015	75%	Sigtia [24]
CRNN	2017	79%	Choi [16]
Multi-DNN ensemble	2018	82%	Sturm [20]
PANNs (CNN14, AudioSet pretrained)	2020	87%	Kong [4]
AST (Audio Spectrogram Transformer)	2021	89%	Gong [25]

В рамках настоящей работы достигнут показатель 83.9% (CNN v2, обучение с нуля) и 81.5% (AST v2, fine-tuned), что соответствует среднему уровню современных решений на GTZAN.

1.5 Архитектуры аудио-классификаторов

1.5.1 Свёрточные нейронные сети (CNN)

Свёрточные сети применяются к log-mel спектрограмме как к двумерному «изображению» с одним каналом. Базовый блок состоит из 2D-свёртки 3×3 , пакетной нормализации (BatchNorm) и нелинейности ReLU. Последовательность нескольких таких блоков с MaxPool 2×2 формирует backbone, преобразующий спектрограмму в компактный feature vector через global average pooling (GAP).

Преимущества CNN: высокая параметрическая эффективность (~ 1 М параметров), хорошее качество на однозадачных бенчмарках, быстрое обучение (3–5 часов на GPU). Недостатки: ограниченное receptive field (порядка 5–10 секунд), плохое моделирование долгосрочных зависимостей, отсутствие предобучения на больших корпусах.

В настоящей работе baseline CNN построен из 5 conv-блоков ($32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ каналов) с механизмом Squeeze-and-Excitation после каждого блока. Подробное описание архитектуры — в §4.2.

1.5.2 Squeeze-and-Excitation (SE)

Squeeze-and-Excitation [26] — механизм channel attention, добавляемый к CNN-блокам. Идея: после каждого conv-слоя вычисляется глобальный средний канал (squeeze), пропускается через две полносвязные операции с sigmoid (excitation), и полученные веса умножаются на исходные каналы. Это позволяет модели динамически усиливать «важные» частотные диапазоны и ослаблять неинформативные.

Эффект SE-блоков на MIR-задачах: улучшение accuracy на 1–3 п.п. при увеличении числа параметров на 5–10%. В нашей работе SE-блоки добавлены после каждого из 5 conv-блоков.

1.5.3 BiLSTM для temporal modeling

Bidirectional LSTM [27] — рекуррентная сеть, обрабатывающая последовательность в обоих направлениях. В контексте MIR применяется как «голова» поверх CNN-эмбеддингов: трек разбивается на окна, каждое окно сжимается CNN в вектор фиксированной размерности, и LSTM строит контекстуально-

зависимое представление каждого окна.

Преимущество BiLSTM перед per-window классификацией: учёт долгосрочного контекста (LSTM «помнит» что было 30+ секунд назад). Недостатки: количество обучающих примеров уменьшается (одна последовательность вместо ~ 200 окон $\rightarrow$ потеря разнообразия), повышенный риск переобучения.

В нашей работе BiLSTM-варианты (CNN+BiLSTM, PANNs+BiLSTM) — часть 2×2 факторного эксперимента; результаты см. §5.4.

1.5.4 PANNs — pretraining на AudioSet

PANNs (Pretrained Audio Neural Networks) [4] — семейство CNN-моделей, предобученных на датасете AudioSet (~ 2 М YouTube-фрагментов, 527 категорий звуков). Наиболее популярная модель — CNN14, выдающая 2048-мерный embedding на каждое 1-секундное окно.

Применение PANNs как «замороженного» feature extractor — стандартный transfer learning paradigm в современном MIR: вместо обучения CNN с нуля используются готовые embedding, и обучается только классификационная голова. Преимущество: сильный inductive bias из AudioSet (миллионы примеров vs наши тысячи). Недостаток: фиксированные представления не адаптируются под специфику задачи.

В настоящей работе PANNs сравнивается с обучаемой с нуля CNN в рамках 2×2 эксперимента (см. §5.3).

1.5.5 Audio Spectrogram Transformer (AST)

Наиболее значимый архитектурный прорыв в MIR за последние годы — **Audio Spectrogram Transformer** [25], предложенный Gong et al. (2021). AST впервые применил парадигму **Vision Transformer** [28] к аудио-спектрограммам отказавшись от свёрток в пользу чистого self-attention.

Принцип работы:

1. Log-mel спектрограмма размером $128 \times T$ делится на патчи 16×16 (с перекрытием 6 пикселей по обеим осям).
2. Каждый патч линейно проецируется в 768-мерный токен.

3. Добавляются `positional embeddings (learnable)` и специальный CLS-токен.
4. Последовательность токенов подаётся на 12-слойный Transformer-encoder с 12 attention heads.
5. Классификация выполняется по выходу CLS-токена через линейный слой.

Общее число параметров: 87M, из которых $\sim 85M$ — в трансформере, остальное в эмбедингах и голове.

Pretraining на AudioSet. Авторы AST предобучают модель на классификации 527 категорий AudioSet через multi-label cross-entropy. Длительность предобучения: ~ 5 дней на 8 V100 GPU. Готовые веса распространяются под именем `MIT/ast-finetuned-audioset-10-10-0.4593` (числа в названии — параметры frequency/time strides и downstream accuracy на AudioSet).

Преимущества AST:

1. **Глобальное восприятие** — self-attention видит каждый патч в контексте всей спектрограммы, что критично для структурного анализа (припев должен «помнить» как звучит куплет).
2. **Transfer learning** — pretraining на 2M аудио предоставляет богатые представления, недоступные при обучении с нуля на 2.5K треков.
3. **Унифицированная архитектура** — один и тот же модель подходит для всех MIR-задач (segment, emotion, genre).

Недостатки:

1. **Большой checkpoint** — 574 MB (vs ~ 21 MB у CNN).
2. **Более медленный inference** — 8 секунд на 3-минутный трек (vs 2 секунды у CNN) на одном GPU.
3. **Чувствительность к гиперпараметрам fine-tuning** — слишком агрессивное размораживание layers ведёт к catastrophic forgetting.

В настоящей работе AST применён как финальная модель прототипа после fine-tuning на DEAM+Harmonix+GTZAN с замораживанием первых 8 из 12 transformer-слоёв. Подробное описание fine-tuning стратегии — в §4.5.

1.6 Multi-task learning в MIR

Multi-task learning (MTL) [29] — парадигма обучения, при которой одна модель решает несколько связанных задач одновременно через общий backbone и специализированные «головы» для каждой задачи. Идея: связанные задачи разделяют полезные представления, и совместное обучение действует как форма регуляризации, повышающая обобщающую способность.

В MIR multi-task learning естественно мотивирован тем, что задачи структурного, эмоционального и жанрового анализа взаимосвязаны:

- **Genre влияет на структуру:** рок-композиции имеют чётко выраженную verse-chorus форму, классическая музыка — более свободную (sonata-form, fugue), электронная — секциями build-up/drop.
- **Эмоциональная динамика коррелирует со структурой:** переход куплет → припев типично сопровождается ростом arousal и сменой valence (pre-chorus как «подготовка» эмоционального пика).
- **Жанр и эмоция связаны:** metal статистически чаще тёмный и активный (Q2 квадрант), classical часто спокойный и позитивный (Q4), blues — спокойный и тёмный (Q3).

Эти корреляции делают MTL естественной парадигмой: общий backbone извлекает универсальные акустические признаки, головы адаптируют их под конкретную задачу. Кроме того, MTL действует как регуляризатор — модель вынуждена обучаться представлениям, полезным для всех задач сразу, что снижает переобучение на малых датасетах.

Технические подходы к MTL:

1. **Joint loss optimization** — суммарный loss $L = \sum w_i \cdot L_i$ с фиксированными или адаптивными весами.
2. **Round-robin batching** — каждый батч содержит примеры из одного датасета, циклически чередуются; backward выполняется только по доступным головам.
3. **Adversarial / gradient surgery** методы (PCGrad, GradNorm) — балансировка градиентов между задачами.

В настоящей работе используется первый и второй подходы: round-robin loader формирует батчи DEAM/Harmonix/GTZAN последовательно, loss суммируется по 4 головам с фиксированными per-task весами (segment: 1.5, остальные: 1.0).

1.7 Pretraining + fine-tuning paradigm

Стратегия «предобучение на большом корпусе → дообучение на целевой задаче» — доминирующий подход во всех областях глубокого обучения с конца 2010-х. В MIR эта парадигма реализуется через AudioSet-pretrained модели (PANNs, AST).

Differential learning rate — техника, при которой разные части модели получают разные learning rates. Обычно:

- Pretrained backbone — низкий LR ($1e-5$.. $5e-5$), чтобы не «сломать» предобученные представления.
- Свежеинициализированные heads — высокий LR ($1e-3$.. $1e-4$), чтобы быстро обучить task-специфичные классификаторы.

Layer freezing — частичная или полная заморозка pretrained слоёв. Полная заморозка превращает модель в feature extractor (PANNs+Linear). Частичная (например, заморозить первые 8 из 12 слоёв трансформера) позволяет верхним слоям адаптироваться к специфике задачи без catastrophic forgetting.

Gradient accumulation — при ограниченной GPU-памяти effective batch size наращивается через накопление градиентов по нескольким микро-батчам перед optimizer step. В нашей работе AST обучается с batch_size=16, grad_accumulation_steps=4, что даёт effective batch=64.

Применение этих техник к AST в данной работе позволило за 3 часа обучения превзойти CNN-baseline по segment accuracy на 5.3 п.п. при сравнимом качестве на остальных задачах (см. §5.4).

Резюме главы 1. Анализ литературы показывает: (а) MSA остаётся самой сложной задачей MIR с типичной accuracy 30–45%; (б) классические методы (SSM, novelty curve) уступают современным CNN/Transformer, но дают интерпретируемые границы; (в) Russell circumplex — общепринятая модель эмоций, дискретизация в 3 класса упрощает задачу без потери семантики; (г) GTZAN — устаревший, но стандартный бенчмарк для жанра; (д) AST с

pretraining на AudioSet — текущий SOTA в audio classification, превосходит CNN и PANNs в transfer learning. Все эти выводы определяют архитектурные решения настоящей работы.

2 Постановка задачи

2.1 Цель исследования

Целью настоящей работы является создание прототипа программно-аналитической системы автоматического анализа музыкальных композиций, формирующей по входному аудиотреку **многоаспектную временную разметку** (timeline) с четырьмя категориями признаков:

1. **Структурная сегментация** — отнесение каждого временного интервала к одной из шести категорий музыкальной формы: вступление (Intro), куплет (Verse), бридж (Bridge), припев (Chorus), инструментальная часть (Instrumental), завершение (Outro).
2. **Уровень энергии (arousal)** — оценка субъективной активности музыки в трёх категориях: низкая (Low), средняя (Mid), высокая (High).
3. **Эмоциональная окраска (valence)** — оценка субъективной приятности музыки в трёх категориях: тёмная (Dark), нейтральная (Neutral), светлая (Bright).
4. **Жанр (genre)** — отнесение трека к одному из десяти жанров: блюз, классика, кантри, диско, хип-хоп, джаз, метал, поп, регги, рок.

В отличие от существующих специализированных решений, ориентированных на одну из четырёх задач (Madmom для onset detection, Essentia для feature extraction, MIRtoolbox для академических исследований [30—32]), предлагаемая система решает **все четыре задачи одновременно** через единую модель. Это обеспечивает:

- **Согласованность результатов** — структурные границы синхронизированы с эмоциональными переходами, поскольку обе оценки производятся на общих признаках.
- **Эффективность вычислений** — однократный проход аудио через сеть вместо четырёх независимых анализов.

- **Возможность совместной интерпретации** — например, переход от куплета к припеву типично сопровождается ростом arousal, что система отображает в синхронизированных таймлайнах прототипа (см. §6.2).

2.1.1 Формальная постановка

Пусть $x \in \mathbb{R}^{T_{\text{audio}}}$ — моноаудиосигнал с частотой дискретизации $sr = 22050$ Гц. Извлечение признаков преобразует его в последовательность лог-мел спектрограммных окон $X = \{X_1, \dots, X_N\}$, где $X_i \in \mathbb{R}^{F \times W}$, $F = 128$ — число мел-полос, $W = sr \cdot \tau / h$ — число фреймов в окне длительностью $\tau = 10$ с при hop $h = 512$ семплов.

Модель f_θ с параметрами θ выдаёт для каждого окна X_i четыре независимых распределения:

$$f_\theta(X_i) = (p_i^{\text{seg}}, p_i^{\text{aro}}, p_i^{\text{val}}, p_i^{\text{gen}}), \quad (1)$$

где $p_i^{\text{seg}} \in \Delta^5$ (симплекс над 6 классами сегментов), $p_i^{\text{aro}}, p_i^{\text{val}} \in \Delta^2$ (3-классовые), $p_i^{\text{gen}} \in \Delta^9$ (10-классовый).

Финальная разметка строится через post-processing функцию g , преобразующую покадровые предсказания в непрерывные интервалы:

$$g(\{p_i\}_{i=1}^N) \mapsto \{(t_j^{\text{start}}, t_j^{\text{end}}, c_j, \kappa_j)\}_{j=1}^M, \quad (2)$$

где c_j — класс сегмента, κ_j — confidence (средняя вероятность класса по фреймам сегмента), M — число сегментов после слияния. Подробное описание g (Viterbi + position priors + min-duration merge) приводится в §4.7.

2.2 Исследовательские вопросы

В рамках работы исследуются пять вопросов, раскрывающих архитектурные альтернативы и пост-обработку:

RQ1. Насколько эффективна мульти-задачная CNN-модель для одновременного решения четырёх задач анализа музыки на ограниченных датасетах (~2.5 тыс. треков суммарно)? Достигает ли она качества, сопоставимого со специализированными однозадачными моделями из литературы?

RQ2. Какой вклад вносит **temporal modeling** через BiLSTM-слой поверх per-window CNN-эмбеддингов? Улучшает ли учёт долгосрочного контекста результаты структурной сегментации, где порядок сегментов имеет

значение?

RQ3. Какой вклад вносит **качество входных признаков** через использование PANNs CNN14, предобученных на AudioSet (≈ 2 млн аудиофрагментов), в сравнении с обучаемой с нуля CNN? Достаточен ли AudioSet pretraining для transfer learning на MIR-задачи?

RQ4. Какой из двух факторов — temporal modeling (BiLSTM) или quality of features (pretraining) — оказывает большее влияние на итоговое качество? Влияние интерактивно или аддитивно?

RQ5. Способна ли архитектура **Audio Spectrogram Transformer (AST)**, pretrained на AudioSet, превзойти CNN- и PANNs-baseline за счёт глобального self-attention и более богатой инициализации? Какие задачи она улучшает в наибольшей степени, и с какими trade-off?

Первые четыре вопроса (RQ1–RQ4) формируют 2×2 факторный эксперимент с четырьмя конфигурациями (CNN, CNN+BiLSTM, PANNs+Linear, PANNs+BiLSTM). RQ5 расширяет эксперимент пятой архитектурой (AST), вводя transformer-парадигму. Дополнительно проводится ablation post-processing (с/без Viterbi и position priors) для оценки вклада musicological priors.

2.3 Обоснование мульти-задачного подхода

Решение четырёх задач единой моделью обосновывается тремя группами аргументов:

2.3.1 Семантические корреляции между задачами

Музыкальные явления, описываемые четырьмя категориями признаков, статистически коррелируют:

- **Жанр определяет типичную структуру:** рок-композиции имеют чётко выраженную verse—chorus форму, классическая музыка следует sonata-form или rondo, электронная — секциям intro—build-up—drop. Знание жанра помогает модели предсказывать вероятные структурные паттерны.
- **Эмоциональная динамика согласована со структурой:** переход куплет $\rightarrow$ припев типично сопровождается ростом arousal (плотности атак, громкости) и сменой valence (более «светлым» гармоническим окрасом). Predictions emotion и segment должны быть взаимно-консистентны.

- **Жанр коррелирует с эмоцией:** metal статистически чаще тёмный и активный (Q2 квадрант Russell), classical — спокойный и позитивный (Q4), blues — спокойный и тёмный (Q3). Эти статистики дают модели полезный prior.

2.3.2 Регуляризация через shared backbone

Мульти-задачное обучение действует как **форма регуляризации**, особенно ценная при ограниченном объёме данных. Общий backbone вынужден извлекать представления, полезные для всех четырёх задач одновременно — что препятствует переобучению на специфике одной задачи. Это соответствует принципу **representation learning**: универсальные признаки (тембр, ритм, гармония) более робастны, чем task-specific признаки (например, специфические артефакты Harmonix-разметки).

Эмпирически в данной работе MTL-модель показывает better generalization gap (разрыв между train- и val-accuracy) на 3–5 п.п., чем сравнимые single-task baseline (см. ablation в §5.7).

2.3.3 Практическая ценность для пользователя

С точки зрения конечного приложения (визуализатор музыкального анализа, ритм-игра, рекомендательная система), пользователю необходимы **все четыре аспекта одновременно**. Альтернативы — последовательный запуск четырёх независимых моделей — приводит к:

- Четырёхкратному увеличению времени inference ($8 \text{ с} \times 4 = 32 \text{ с}$ на 3-минутный трек вместо 8 с).
- Несогласованности результатов (4 модели не «знают» друг о друге).
- Усложнению развертывания (4 checkpoint вместо одного, 4 запуска пре-процессинга).

Единая мульти-задачная модель выдаёт согласованную разметку за один проход, что критично для интерактивных приложений типа реализованного в работе веб-дашборда (Глава 6).

Резюме главы 2. Сформулирована цель — создание прототипа системы многоаспектного анализа аудио. Поставлены пять исследовательских вопросов, охватывающих 2×2 факторный эксперимент (RQ1–RQ4) и расширение его трансформер-архитектурой (RQ5). Обоснован выбор мульти-задачного подхода через семантические корреляции, регуляризационный эффект shared backbone и практические соображения inference-эффективности.

3 Данные

В работе используются три открытых датасета, каждый специализированный под одну из решаемых задач: DEAM (эмоции), Harmonix Set (структура), GTZAN (жанр). Объединение трёх разнородных корпусов в единое мульти-задачное обучение требует унифицированного пайплайна предобработки и аккуратного формирования сплитов. Настоящая глава описывает каждый датасет, обоснование выбора, схему предобработки признаков и принятый подход к балансировке классов.

3.1 Используемые датасеты

Сводная характеристика трёх датасетов приведена в таблице 3.1.

Таблица 3: Таблица 3.1. Используемые датасеты

Датасет	Размер	Аудио	Аннотации	Задача	Источник
DEAM	1802 фрагмента (45 с каждый)	mp3	Покадровые непрерывные arousal/valence	Эмоции	MediaEval 2013– 2018 [15]
Harmonix Set	912 треков (полная дли- тельность)	mp3 (загру- жено 743)	Структурная разметка с временными метками	Сегментация	Nieto et al 2019 [33]
GTZAN	999 фрагментов (30 с каждый)	wav	Жанровая метка целиком на трек	Жанр	Tzanetaki & Cook, 2002 [19]
Итого	3713 уникальных файлов	≈ 110 ГБ распакованных features		4 задачи	

3.1.1 DEAM (Database for Emotional Analysis of Music)

DEAM — крупнейший открытый датасет для music emotion recognition, подготовленный в рамках серии MediaEval challenges 2013–2018 годов [15]. Содержит 1802 музыкальных фрагмента длительностью 45 секунд, выбранных из Free Music Archive с лицензией Creative Commons. Покадровые аннотации arousal и valence получены через краудсорсинговый эксперимент: каждый фрагмент оценивали в среднем 10 аннотаторов с шагом 500 мс.

Формат аннотаций. Для каждого трека предоставляется:

- `valence_average.csv`, `arousal_average.csv` — усреднённые временные ряды по 60 фреймам (30 секунд $\times$ 2 фрейма/с).
- `valence_std.csv`, `arousal_std.csv` — стандартные отклонения по аннотаторам, индикатор согласия.

- `metadata.csv` — общая информация о треках (длительность, BPM при наличии).

Дискретизация. Непрерывные значения `arousal/valence` в диапазоне $[-1, +1]$ преобразуются в три категории по двум порогам, выбранным на основе анализа распределений в обучающей выборке:

<code>arousal:</code>	<code>[-1.0 .. -0.2] -> Low,</code>	<code>[-0.2 .. +0.2] -> Mid,</code>	<code>[+0.2 .. +1.0] -> High</code>
<code>valence:</code>	<code>[-1.0 .. -0.2] -> Dark,</code>	<code>[-0.2 .. +0.2] -> Neutral,</code>	<code>[+0.2 .. +1.0] -> Bright</code>

Пороги ± 0.2 выбраны как обеспечивающие приблизительно равномерное распределение классов на `train split`: каждый из трёх классов получает 25–40% примеров. Альтернативная схема равных квантилей (по 33% на класс) была отвергнута, поскольку нарушала бы семантическое соответствие («Low» при `arousal=0` нельзя интерпретировать как действительно низкую энергию).

3.1.2 *Harmonix Set*

`Harmonix Set` [33] — единственный крупный открытый датасет со структурной разметкой коммерческой популярной музыки. Включает 912 треков, каждый аннотирован профессиональными музыкантами через специализированный инструмент `Sonic Visualiser`. Аннотации включают:

- **Beat positions** — временные метки долей такта.
- **Section labels** — типы структурных разделов (`intro`, `verse`, `chorus`, `bridge`, `instrumental`, `outro` и более тонкие подкатегории).
- **Downbeats** — сильные доли (начало тактов).

В нашей работе используется только секционная разметка. Из исходной 17-категорийной таксономии `Harmonix` мы свели к 6 классам:

<code>intro, intro_*</code>	-> <code>Intro</code>
<code>verse, verse_*, theme</code>	-> <code>Verse</code>
<code>bridge, transition_*</code>	-> <code>Bridge</code>
<code>chorus, chorus_*, hook</code>	-> <code>Chorus</code>
<code>instrumental, solo, breakdown</code>	-> <code>Instrumental</code>

Доступность аудио. Harmonix Set распространяется только с аннотациями, без аудио, по соображениям авторских прав. Аудио для каждого трека требуется получать самостоятельно. В рамках работы реализован пайплайн скачивания через `yt-dlp` по полю `youtube_id` из метаданных датасета. Из 912 треков успешно загружено 743 (81.5%); остальные удалены с YouTube или недоступны в регионе. Скрипт `scripts/download_harmonix_audio.py` автоматизирует процесс.

3.1.3 GTZAN

GTZAN [19] — исторически первый датасет для жанровой классификации, опубликованный Tzanetakis и Cook в 2002 году. Содержит 1000 30-секундных wav-фрагментов в 10 жанровых категориях по 100 примеров: blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock. Мы получили 999 рабочих файлов (один файл повреждён в оригинальном архиве).

Известные ограничения GTZAN [20]:

1. **Дубликаты** — около 5% треков повторяются под разными именами.
2. **Ошибки маркировки** — особенно в категориях rock/country/blues.
3. **Bias artist effect** — несколько исполнителей доминируют в каждой категории, что искажает оценку обобщения.
4. **Устаревшая таксономия** — 10 жанров 2002 года не покрывают современные направления (electronic, indie, hip-hop subgenres, lo-fi).

Несмотря на эти ограничения, GTZAN сохраняется как референсный датасет: за 23 года накопилась обширная литература сравнений, и переход на альтернативы (FMA, MagnaTagATune) лишил бы возможности прямого сопоставления с baseline-моделями. Обнаруженные в ходе работы ограничения out-of-distribution (поведение модели на современной музыке вне 10 GTZAN-категорий) явно адресуются в UI прототипа через top-3 классификации с предупреждением о низкой уверенности (см. §6.3).

3.2 Извлечение признаков

Все три датасета унифицируются на этапе feature extraction, который выполняется один раз и сохраняет результаты в формат .npz (сжатый numpy archive). Это позволяет последующее обучение использовать готовые признаки без повторного декодирования mp3, что критично для скорости epoch при многозадачном обучении.

3.2.1 Конфигурация спектрограммы

Для каждого аудиофайла вычисляется log-mel спектрограмма со следующими параметрами:

Таблица 4: Параметры log-mel спектрограммы

Параметр	Значение	Обоснование
Sample rate	22050 Гц	Стандарт librosa, покрывает диапазон до 11025 Гц (выше человеческого слухового максимума не требуется для музыки)
n_fft	2048	Размер окна STFT, ≈ 93 мс при $sr=22050$
hop_length	512	Шаг STFT, ≈ 23 мс между фреймами
n_mels	128	Число мел-полос; 128 — стандарт для music classification
fmin	30 Гц	Нижняя граница мел-фильтров
fmax	$sr/2 = 11025$ Гц	Верхняя граница (Найквистова частота)

Логарифмическая компрессия применяется через `librosa.power_to_db(..., ref=np.max)` — нормализация к максимальному значению в треке, что даёт значения в диапазоне примерно $[-80, 0]$ дБ.

3.2.2 Окновая нарезка (windowing)

Каждый трек разбивается на перекрывающиеся окна фиксированной длительности. Параметры:

- `window_seconds = 10.0` — длительность окна (10 секунд = 431 фрейм спектрограммы).
- `hop_seconds = 1.0` — шаг между окнами (1 секунда между началами).

Выбор `window_seconds = 10` обоснован двумя факторами. Во-первых, 10 секунд достаточно для типичного музыкального периода (один-два куплета или припев), что позволяет CNN модели «видеть» полный смысловой фрагмент. Во-вторых, AST-модель (см. §4.5) была предобучена на AudioSet с окнами 10 секунд, и сохранение этого размера позволяет напрямую использовать предобученные веса без интерполяции `positional embeddings`.

Шаг 1 секунда обеспечивает плотное покрытие аудио: за минуту получаем ~ 50 окон, что даёт достаточную плотность для пост-обработки через Viterbi.

3.2.3 Глобальная нормализация

После извлечения признаков по всему обучающему сплиту вычисляются глобальные статистики `mean` и `std` по всем мел-полосам:

```
features_train = np.concatenate([np.load(f)["features"] for f in
    train_files])
mean = features_train.mean(axis=(0, 2), keepdims=True) # (1, n_mels,
    1)
std = features_train.std(axis=(0, 2), keepdims=True) + 1e-6
np.savez("stats.npz", mean=mean, std=std)
```

Эти статистики применяются ко всем трём сплитам (`train/val/test`) перед подачей в модель: $(\text{feat} - \text{mean}) / \text{std}$. Без нормализации модель медленно сходится и выдаёт смещённые предсказания на новых треках. **Критическое требование** для inference: тот же `stats.npz` должен использоваться при обработке пользовательских аудиозагрузок — иначе предсказания будут систематически неверными. В нашем пайплайне `musicml/infer.py:extract_features` автоматически загружает `stats.npz` из стандартных путей.

3.3 Стратегия разбиения train/val/test

Каждый из трёх датасетов независимо разбивается в пропорции **70 / 15 / 15** (train / validation / test). Принципиальные решения:

1. **Разбиение на уровне треков, не окон.** Если бы мы перемешали окна и разделили на сплиты, окна одного трека попадали бы и в train, и в test, что давало бы ложно-завышенные метрики из-за корреляции между соседними окнами. Разбиение на уровне треков гарантирует, что модель не «видит» test-треки при обучении.
2. **Стратификация для GTZAN.** GTZAN строго сбалансирован (по 100 треков на жанр), стратификация выполняется автоматически при последовательном делении $70:15:15 = 70:15:15$ треков на класс.
3. **Стратификация для DEAM невозможна.** Поскольку каждый DEAM-трек имеет покадровые непрерывные аннотации, разные фрагменты одного трека могут принадлежать разным классам arousal/valence. Стратификация на уровне треков по сводной метке трека была бы артефициальна. Используется случайное разбиение с фиксированным seed=42.
4. **Harmonix без стратификации по жанру.** Аннотации Harmonix не содержат явной жанровой информации. Разбиение случайное с тем же seed=42.
5. **Воспроизводимость.** Список треков в каждом сплите сохраняется в splits.json при подготовке датасета, что позволяет воспроизвести точные сплиты в любой момент.

3.4 Дисбаланс классов

Анализ распределения классов в train-сплитах выявил критический дисбаланс по сегментной задаче:

Таблица 5: Таблица 3.2. Распределение классов в train-сплитах

Задача	Класс	Доля окон	Inverse-frequency weight
Segment	Verse	~35%	0.71
	Chorus	~25%	1.00
	Bridge	~12%	2.08
	Intro	~10%	2.50 (capped)
	Instrumental	~10%	2.50 (capped)
	Outro	~8%	2.50 (capped)
Arousal	Low / Mid / High	~33% / 34% / 33%	≈ 1.00 каждый
Valence	Dark / Neutral / Bright	~33% / 33% / 34%	≈ 1.00 каждый
Genre	каждый из 10	~10%	≈ 1.00 каждый

Сегментная задача — единственная сильно несбалансированная: Verse и Chorus совокупно занимают ~60% окон, тогда как Outro — менее 10%. Без специальной обработки модель с высокой вероятностью научится предсказывать только Verse и Chorus, игнорируя редкие классы.

Для устранения дисбаланса применяются три механизма:

1. **Inverse-frequency class weights** — каждый класс получает вес, обратно пропорциональный его частоте, с верхним порогом `max_class_weight=2.5` (выбран эмпирически, чтобы избежать чрезмерного усиления редких классов; см. §4.6).
2. **Focal Loss** [34] — модификация `cross-entropy` с фокусом на сложные примеры через множитель $(1 - p_t)^\gamma$ при $\gamma = 1.5$. Снижает вклад уверенных правильных предсказаний и усиливает сложные.
3. **Per-task loss weight** — суммарный мульти-задачный `loss` балансируется через множитель `segment: 1.5` (остальные задачи: 1.0), компенсируя относительно меньший вклад `structural`-задачи в общую функцию потерь из-за её большей сложности.