

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Тверской государственный университет»

Факультет прикладной математики и кибернетики

Направление 02.04.02 Фундаментальная информатика и информационные
технологии

Профиль «Информационные технологии в управлении и принятии решений»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ)

тема: «Определение структурных сегментов и
эмоциональных характеристик музыкальных
композиций методами машинного обучения»

Автор:

Антонов Михаил Евгеньевич

Подпись _____

ДОПУЩЕН К ЗАЩИТЕ

Руководитель ООП

А. В. Язенин

Научный руководитель:

Кудряшов Максим Юрьевич,
кандидат

физико-математических наук

Подпись _____

« ____ » _____ 20 ____ г.

Abstract

Structural Segmentation and Emotional Characterisation of Musical Compositions by Machine Learning Methods

by

Antonov Mikhail Evgenyevich

This master's thesis presents a software module for automatic multi-task analysis of musical recordings. For an input track the system produces a temporal timeline of structural segments (Intro, Verse, Chorus, Bridge, Instrumental, Outro), arousal/valence curves (Russell circumplex) and a top-3 genre prediction.

Five architectural configurations are developed and compared: a CNN per-window with Squeeze-and-Excitation attention, CNN + BiLSTM, a linear classifier and a BiLSTM over frozen PANNs embeddings, and a partially fine-tuned Audio Spectrogram Transformer (AST) pretrained on AudioSet. All are trained jointly on DEAM, Harmonix Set and GTZAN by a round-robin multi-task scheduler with focal loss and SpecAugment. Four sequential experiments (v1, v2, AST v2 extension and a negative-result CNN v3) yield AST v2 as the best overall configuration with average accuracy 58.5% and a 5.3-point gain on structural segmentation over the strongest CNN baseline. A post-processing pipeline based on Viterbi decoding with a musicological transition matrix, position priors and per-class minimum durations raises the boundary F1 of the structural segmentation by 14 points over the raw argmax baseline.

The work also delivers an interactive web prototype with a synchronised six-panel dashboard and a fullscreen Vibe Mode WebGL2 visualizer reactive to the audio spectrum.

Оглавление

Введение	5
Глава 1. Обзор предметной области	12
§ 1.1. Music Information Retrieval как научная дисциплина	12
§ 1.2. Структурная сегментация музыкальных композиций	13
§ 1.3. Распознавание эмоций в музыке	14
§ 1.4. Классификация жанров	15
§ 1.5. Архитектуры аудио-классификаторов	16
§ 1.6. Multi-task learning в MIR	17
§ 1.7. Предварительное обучение и дообучение	18
Глава 2. Постановка задачи	19
§ 2.1. Цель исследования	19
§ 2.1.1. Формальная постановка	20
§ 2.2. Исследовательские вопросы	20
§ 2.3. Обоснование мультизадачного подхода	21
Глава 3. Данные	23
§ 3.1. Используемые датасеты	23
§ 3.2. Извлечение признаков	25
§ 3.3. Стратегия разбиения на обучающую, валидационную и тестовую выборки	26
§ 3.4. Дисбаланс классов	27
Глава 4. Архитектура и методы	29
§ 4.1. Обзор многоархитектурного эксперимента	29
§ 4.2. Свёрточная сеть (конфигурация 1)	30
§ 4.3. CNN с надстройкой BiLSTM (конфигурация 2)	31
§ 4.4. Конфигурации поверх замороженной PANNs (3 и 4)	31
§ 4.5. Audio Spectrogram Transformer v2 (конфигурация 5, финальная)	32
§ 4.6. Мультизадачные головы и функция потерь	33
§ 4.7. Постобработка предсказаний сегментной головы	34

§ 4.8. Инференс на пользовательских записях	38
Глава 5. Эксперименты	39
§ 5.1. Протокол оценки	39
§ 5.2. Гиперпараметры обучения	40
§ 5.3. Эксперимент v1: исходный 2×2 запуск	41
§ 5.4. Эксперимент v2: улучшенный запуск	42
§ 5.5. Эксперимент AST v2: расширение трансформер-архитектурой	44
§ 5.6. Эксперимент CNN v3: неудачное усиление	46
§ 5.7. Сводное сравнение всех моделей	47
§ 5.8. Ablation: вклад постобработки сегментной головы	48
Глава 6. Прототип системы	50
§ 6.1. Архитектура веб-приложения	50
§ 6.2. Синхронизированный дашборд	51
§ 6.3. Ключевые UX-решения	52
§ 6.4. Технологический стек	53
§ 6.5. Визуальный редизайн и расширения интерфейса	54
Глава 7. Анализ результатов и ограничения	56
§ 7.1. Сводные ответы на исследовательские вопросы	56
§ 7.2. Финальная конфигурация прототипа	58
§ 7.3. Ограничения текущего подхода	59
§ 7.4. Сопоставление с state-of-the-art	60
§ 7.5. Научная новизна и практическая значимость	62
Заключение	63
Список литературы	65
Приложение А. Описание датасетов	69
Приложение Б. Гиперпараметры экспериментов	71
Приложение В. Confusion matrices и графики	72
Приложение Г. JSON-схема timeline	73
Приложение Д. CLI-команды воспроизведения	74

Введение

Актуальность

Промышленные музыкальные сервисы сегодня оперируют каталогами, в которые ежедневно добавляются десятки тысяч новых треков. Только Spotify к 2024 году преодолел отметку в 100 миллионов композиций. Темпы роста каталогов давно превысили физические возможности ручной разметки. В таких условиях возрастает спрос на автоматические инструменты семантической разметки аудио: определение жанра, оценка эмоционального содержания, выделение структурных секций. На рынке такие задачи в большинстве случаев решаются специализированными моделями, каждая под свою задачу, что приводит к избыточному дублированию параметров и не использует общую акустическую природу входных данных. Настоящая работа направлена на проверку гипотезы о том, что объединение четырёх задач (структурной сегментации, классификации возбуждения, валентности и жанра) в единой мультизадачной модели с общим энкодером и независимыми головами позволяет получить качество, сопоставимое с опубликованными однозадачными результатами, и при этом даёт согласованную разметку всех четырёх аспектов за один проход.

Обзор литературы

Предметная область опирается на обзорные работы по MIR [8] и применению глубокого обучения [1], на исследования по структурной сегментации (метод матриц автоподобия, глубокие модели, датасет Harmonix Set), распознаванию эмоций (модель Расселла, датасет DEAM) и жанровой классификации (бенчмарк GTZAN, набор моделей PANNs [27] и архитектура AST [15]). Эти источники служат для формирования гипотез и обоснования сравниваемых архитектур. Полный обзор приведён в Главе 1.

Цель и задачи

Цель работы. Разработка и экспериментальное исследование программного модуля автоматического анализа музыкальных композиций, выполняющего структурную сегментацию, оценку эмоциональных характеристик и жанровую классификацию аудиозаписей на основе мультизадачной модели глубокого обучения.

Задачи

- 1) Провести обзор области Music Information Retrieval и обосновать мультизадачный подход к объединению четырёх задач (сегментация, возбуждение, валентность, жанр).
- 2) Подготовить обучающий корпус на основе трёх открытых датасетов (DEAM, Harmonix Set, GTZAN) с унифицированным пайплайном извлечения признаков.
- 3) Разработать и реализовать пять архитектур мультизадачных моделей — CNN, CNN + BiLSTM, PANNs + Linear, PANNs + BiLSTM, AST — для оценки вклада временного моделирования, предварительного обучения и трансформерной парадигмы.
- 4) Выполнить экспериментальное сравнение пяти архитектур по четырём задачам на едином тестовом корпусе.
- 5) Реализовать постобработку сегментных предсказаний на базе декодера Витерби с музыкологическими априорными распределениями.
- 6) Разработать веб-прототип для интерактивной демонстрации результатов.
- 7) Сформулировать ограничения подхода и направления дальнейшей работы.

Методы и средства

Работа опирается на стандартные для области методы цифровой обработки сигналов (короткое преобразование Фурье, лог-мел-спектрограмма, chroma), машинного обучения (свёрточные сети с SE-блоками, двунаправленные LSTM, самовнимание AST с трансфером весов AudioSet), регуляризации

(SpecAugment, focal loss, label smoothing, MixUp) и динамического программирования (декодер Витерби с позиционными приорами). Реализация выполнена на Python 3.12 с PyTorch, librosa и scikit-learn. Веб-прототип построен на React 19 с Vite на фронтенде, на Elysia с Bun на бэкенде и на FastAPI с PyTorch на стороне инференса. Полноэкранный визуализатор Vibe Mode использует WebGL2.

Основные результаты

- 1) Выполнен обзор 40 источников по трём задачам MIR и пяти семействам аудио-архитектур (Глава 1). По итогам обзора в качестве методологической основы выбрана мультизадачная модель с общим аудио-энкодером и четырьмя независимыми классификационными головами. Аргументы в её пользу (содержательная связь задач, регуляризирующий эффект общего ствола и экономия вычислений при инференсе) собраны в § 2.3.
- 2) Собран объединённый корпус из 3 545 композиций на основе трёх открытых датасетов: DEAM (эмоции), Harmonix Set (структура, с автоматическим скачиванием 743 треков с YouTube через yt-dlp) и GTZAN (жанр). Реализован модуль musicml.features для унифицированного извлечения логарифмических мел-спектрограмм со 128 фильтрами, нарезки на десятисекундные окна с шагом 1 секунда и глобальной нормализации. Итоговый обучающий набор насчитывает 176 127 окон, разбиение на обучающую, валидационную и тестовую выборки 70/15/15 делается на уровне треков, что исключает утечку между сплитами.
- 3) Реализованы и обучены пять архитектур, охватывающих ключевые оси сравнения. В их числе: свёрточная сеть с блоками канального внимания (около 800 тысяч параметров), её надстройка двунаправленной LSTM, линейный классификатор и BiLSTM поверх замороженных эмбеддингов PANNs CNN14, а также частично размороженный Audio Spectrogram Transformer с 14,4 млн обучаемых параметров из 87 млн общих. У всех конфигураций единый интерфейс выхода: четыре классификационные головы плюс две регрессионные для непрерывных значений возбуждения и валентности. Обучение всех пяти проведено на одном тестовом корпусе с единым протоколом, чтобы результаты были напрямую сопоставимы.

- 4) Проведены четыре последовательных эксперимента: базовый запуск v1, улучшенный v2, расширение трансформер-архитектурой AST v2 и неудачный CNN v3 с агрессивным перевзвешиванием классов (документированный negative result). Лучший по среднему результату оказался AST v2: точность 58,5 % усреднённо по четырём задачам, 40,6 % на структурной сегментации (на 5,3 процентных пункта выше CNN v2) и 81,5 % на жанровой классификации. Победители по отдельным задачам распределились между AST v2 (сегментация), PANNs+BiLSTM (возбуждение и валентность) и CNN v2 (жанр). Одной архитектуры, доминирующей сразу по всем четырём задачам, не нашлось.
- 5) Разработан и реализован декодер v2 для постобработки сегментных предсказаний. В нём объединены шесть механизмов: температурное масштабирование логитов, асимметричная матрица переходов 6×6 с музыкологическими априори, позиционные приоры для вступления и концовки, поклассовые ограничения минимальной длительности, привязка границ к локальным максимумам кривой новизны и проверка повторяющихся сегментов на близость представлений. Полный пайплайн повышает Boundary F1 с 0,31 до 0,45 (на 14 процентных пунктов выше базового аргмакса) и сокращает среднее число выдаваемых сегментов с 28 до 7–8 на трёхминутный трек.
- 6) Реализован полнофункциональный веб-прототип с трёхзвенной архитектурой: фронтенд на React 19 с Vite, бэкенд на Elysia поверх Bun, сервис инференса на FastAPI с предобученной AST v2 в памяти. Центральное решение интерфейса — синхронизированный дашборд из шести панелей с общим временным курсором, в который сведены разметка структуры, эмоциональные кривые, жанровое распределение, мел-спектрограмма и сводная панель характеристик. Дополнительно реализован полноэкранный визуализатор Vibe Mode на основе WebGL2-шейдера, реагирующего на семантические выходы модели и спектр аудио, а также автоматическая подгрузка метаданных треков из ID3-тегов и YouTube.
- 7) Систематически проанализированы пять групп ограничений текущего подхода. К ним относятся смещение жанровой головы на современной музыке из-за устаревшей таксономии GTZAN, фундаментальный потолок шестиклассовой сегментации в районе 50 % по причинам данных и разметки, размер AST в 574 МБ с восьмисекундным временем инференса на трек, невозможность мульти-жанровых предсказаний в текущей по-

становке и затруднения с очень длинными треками. Для каждой группы предложены конкретные направления развития: надстройка sequence-level декодера BiLSTM или CRF поверх AST-эмбеддингов, дообучение на современных датасетах FMA-medium или SALAMI, дистилляция знаний из AST в более компактный CNN, потоковый инференс со скользящим окном.

Новизна

Научная новизна работы заключается в следующем. Разработана мультизадачная нейросетевая модель с единым аудио-энкодером и четырьмя классификационными головами, обучаемая одновременно на трёх разнородных датасетах (DEAM, Harmonix Set, GTZAN) по карусельной схеме (англ. round-robin). В рамках проведённого обзора литературы не было обнаружено работ, в которых в едином экспериментальном протоколе сравниваются пять конфигураций (CNN per-window, CNN с надстройкой BiLSTM, PANNs с линейными головами, PANNs с BiLSTM, Audio Spectrogram Transformer с частичной разморозкой) для мультизадачного анализа структуры, эмоций и жанра. Предложен воспроизводимый пайплайн кросс-датасетного обучения с покомпонентным взвешиванием потерь, в том числе для случая, когда метки каждой задачи присутствуют только в одном из источников. Дополнительно предложен и количественно оценён составной постобработчик сегментных предсказаний (декодер Витерби с матрицей переходов, позиционными приорами и поклассовыми ограничениями минимальной длительности), повышающий Boundary F1 на 14 пунктов относительно базового аргмакса и сокращающий среднее число выдаваемых сегментов с 28 до 7–8. Также реализован интерактивный веб-прототип с шестипанельным синхронизированным дашбордом и WebGL2-визуализатором, в котором предусмотрено явное отображение ограничений модели (три наиболее вероятных жанра с предупреждением о низкой уверенности при попадании во входные данные вне обучающего распределения).

Апробация

Результаты исследования прошли апробацию на студенческой научной конференции факультета прикладной математики и кибернетики Тверского государственного университета (2026 год). По теме работы принята к публи-

кации статья «Мультизадачный анализ музыкальных композиций с помощью предобученного аудио-трансформера» в сборнике трудов конференции. В статью включены лучшие по каждой задаче результаты среди исследованных конфигураций. Помимо этого, разработанный прототип был отдельно протестирован на наборе из 41 аудиотрека различных жанров. Для каждого модель сформировала структурную разметку, эмоциональные кривые и распределение жанров. Реализация оформлена в виде открытого репозитория с 128 автоматическими тестами, обеспечивающими воспроизводимость экспериментов.

Структура работы

Работа состоит из введения, семи глав основной части, заключения, списка использованных источников и пяти приложений.

Глава 1 содержит обзор предметной области. В ней разбираются три основные задачи MIR из числа решаемых в работе (структурная сегментация, распознавание эмоций, жанровая классификация), эталонные датасеты по каждой задаче и пять архитектурных семейств для аудио-классификации: свёрточные сети с блоками канального внимания, надстройки двунаправленной LSTM, замороженные эмбединги PANNs CNN14 и Audio Spectrogram Transformer с трансфером с AudioSet. Отдельные параграфы посвящены мультизадачному обучению и техникам аккуратного дообучения предобученных моделей.

Глава 2 содержит формальную постановку задачи. Цель работы и четыре класса выходных предсказаний модели формализованы математически: входной аудиосигнал, последовательность лог-мел окон, четыре распределения вероятностей и постобработка во временные интервалы. На основе этой формализации сформулированы пять исследовательских вопросов RQ1–RQ5, легших в основу экспериментальной программы. Завершает главу содержательное обоснование выбора мультизадачного подхода по трём линиям: семантической, методологической и практической.

Глава 3 описывает данные. Подробно разбираются три открытых датасета (DEAM, Harmonix Set, GTZAN), включая их объёмы, лицензии и процедуру скачивания недостающего аудио для Harmonix через yt-dlp. Описан унифицированный пайплайн извлечения логарифмических мел-спектрограмм, оконная нарезка с шагом одна секунда, глобальная нормализация по обучающему

сплиту и стратегия разбиения на обучающую, валидационную и тестовую выборки на уровне треков. Отдельный раздел посвящён компенсации сильного дисбаланса классов в структурной задаче через сочетание focal loss, весов классов с верхним порогом и поканальных весов потери.

Глава 4 содержит описание методов. Подробно разобраны все пять архитектурных конфигураций (CNN, CNN+BiLSTM, PANNs+Linear, PANNs+BiLSTM, AST v2), общая схема мультизадачных голов и функция потерь на основе focal loss, оптимизатор AdamW с расписанием CosineAnnealingWarmRestarts. Отдельный большой раздел разбирает постобработку сегментных предсказаний на основе декодера Витерби: матрица переходов, позиционные приоры, поклассовые ограничения минимальной длительности, расширенная версия v2 с шестью механизмами. Завершает главу описание пайплайна инференса на пользовательских записях.

Глава 5 представляет результаты экспериментов. Описаны протокол оценки и гиперпараметры обучения, после чего излагаются четыре последовательных эксперимента: базовый запуск v1, улучшенный v2, расширение трансформер-архитектурой AST v2 и неудачный CNN v3. Сводное сравнение всех конфигураций даётся в отдельном разделе вместе с ablation-экспериментом по компонентам постобработки.

Глава 6 описывает реализованный веб-прототип. Разобрана трёхзвенная архитектура (фронтенд, бэкенд, сервис инференса), синхронизированный дашборд из шести панелей, ключевые UX-решения для честной коммуникации ограничений модели и технологический стек. Завершает главу описание визуального редизайна в стилистике glassmorphism и полноэкранного визуализатора Vibe Mode на WebGL2-шейдере.

Глава 7 содержит сводный анализ результатов. Даны ответы на все пять исследовательских вопросов, зафиксирована финальная конфигурация прототипа, систематически проанализированы пять групп ограничений подхода с возможными направлениями развития, проведено сопоставление со state-of-the-art по каждой задаче, сформулирована научная новизна и практическая значимость работы.

Заключение кратко перечисляет основные результаты и направления дальнейшей работы. Список использованных источников содержит 40 наименований. Пять приложений (А–Д) собирают подробные технические сведения: характеристики датасетов, гиперпараметры конфигураций, путеводитель по графическим результатам, JSON-схему выхода модели и команды воспроизведения экспериментов.

Глава 1

Обзор предметной области

§ 1.1. Music Information Retrieval как научная дисциплина

Music Information Retrieval (MIR) сложился как самостоятельная междисциплинарная область к началу 2000-х годов вместе с проведением первой конференции ISMIR в 2000 [8]. К задачам MIR принято относить классификацию трека целиком (жанр, настроение), покадровую разметку отдельных событий (моменты начала нот, темп, аккорды), сегментацию по смысловым фрагментам или эмоциям и регрессию непрерывных характеристик (возбуждение и валентность). В данной работе три из этих задач решаются на уровне отдельных кадров, а четвёртая, жанр, на уровне трека целиком. Все четыре сведены в одну мультизадачную модель.

Базовое признаковое представление, на котором работают практически все современные модели, это логарифмическая мел-спектрограмма [31]: 128 мел-полос в диапазоне примерно от 30 Гц до 11 кГц (при частоте дискретизации 22050 Гц), полученная по короткому преобразованию Фурье с окном 2048 отсчётов и шагом 512 (≈ 23 мс) [1; 27]. Альтернативные представления (chroma, MFCC, CQT) рассматривались при проведении предварительных экспериментов, но в финальную модель не вошли: их вклад поверх мел-спектрограммы оказался в пределах одного процентного пункта.

§ 1.2. Структурная сегментация музыкальных композиций

Под структурной сегментацией (Music Structure Analysis, MSA) понимают разбиение записи на смысловые фрагменты: вступление, куплет, припев, бридж, инструментал и концовку. Задача распадается на две подзадачи. Первая, детекция границ, требует найти моменты перехода от одного фрагмента к другому. Вторая, разметка секций, приписывает каждому отрезку метку из шести классов. Именно шестиклассовая разметка считается одной из сложнейших задач MIR: различить куплет и припев чисто по звуковому содержанию невозможно, нужен контекст всей композиции (повторяемость, динамика, развитие гармонии).

Классические алгоритмы строятся вокруг матрицы автоподобия (self-similarity matrix, SSM), вычисляемой по поккадровым признакам [13]. На её основе строят кривую новизны Фута [13], методы выпуклой оболочки [38] и спектральной кластеризации [24]. Подобные подходы достигают F1 порядка 0,6–0,7 на SALAMI в задаче детекции границ, но почти не решают задачу разметки секций: для последней нужно различение паттернов более высокого уровня.

Начиная с 2014 года в области доминирует глубокое обучение. Ullrich и соавторы [37] применили свёрточную сеть к задаче детекции границ и получили F1 около 0.46 на SALAMI с допуском ± 3 секунды. Serrà и соавторы [26] надстроили скрытую марковскую модель над свёрточной сетью, показав важность временного сглаживания. Wang и соавторы [39] подняли F1 до 0.55, добавив над свёрткой трансформер. Gong и Glass [16] в 2023 году довели результат до F1 около 0.62 на датасете Harmonix, заменив свёртку на AST.

Достигнутая на сегодня точность шестиклассовой разметки секций редко превышает 40–45 % [16; 39]. Этому есть сразу несколько причин. Классы сильно несбалансированы: куплет и припев занимают большую часть трека, тогда как бридж и инструментал встречаются реже. Сами аннотаторы между собой тоже расходятся: согласие при разметке границ оценивается примерно в 85%, при разметке меток секций около 75% [7]. Вступление и концовка часто акустически неразличимы, особенно при затухающем финале. Наконец, в реальных записях встречается заметный сдвиг распределения относительно учебных датасетов. Чтобы частично компенсировать эти проблемы, поверх предсказаний сети обычно ставят постобработку: НММ или декодер Витерби

с музыкологически осмысленными априорными распределениями [16; 26]. В данной работе используется именно такая схема, она подробно разбирается в §4.7.

§ 1.3. Распознавание эмоций в музыке

Распознавание эмоций в музыке (Music Emotion Recognition, MER) обычно формализуется одним из двух способов. Первый, классификация по дискретным категориям [17], восходит к работам по психологии музыкального восприятия 1930-х годов. Второй, более распространённый сегодня, опирается на двумерную модель Расселла [28]: эмоция задаётся парой чисел в квадрате $[-1, +1]^2$, где одна ось отвечает за валентность (приятность звучания), а вторая за уровень возбуждения. Семантика квадрантов модели сведена в табл. 1.1.

Таблица 1.1. Семантика квадрантов модели Расселла

Квадрант	Valence	Arousal	Семантика
Q1	+	+	Радостное (joyful, exhilarating)
Q2	−	+	Злое, тревожное (angry, anxious)
Q3	−	−	Грустное (sad, melancholic)
Q4	+	−	Умиротворённое (peaceful, calm)

Эталонным датасетом для непрерывного MER служит DEAM [2]: 1802 музыкальных фрагмента с покадровой разметкой обеих координат. При этом согласие между аннотаторами относительно невысокое, корреляция Пирсона между разметками разных людей колеблется в районе 0,55–0,65. В данной работе непрерывные значения квантуются в три класса (low, mid, high для возбуждения и аналогично для валентности): это снижает влияние шума разметки и согласуется по гранулярности с задачей структурной сегментации. Сами непрерывные оценки при этом не выбрасываются и используются для двумерной визуализации в прототипе (§6.2).

Среди архитектур, применявшихся к MER, наиболее распространены свёрточные сети [6], гибриды свёртки и рекуррентного слоя [35] и трансформеры [40]. Лучшие результаты на трёхклассовой задаче DEAM сегодня находятся в районе 65–70 % точности по возбуждению и 55–60 % по валентности. Этот разрыв давно отмечен в литературе: возбуждение хорошо предсказывается по

спектральным признакам (громкость, плотность спектра, ритмическая активность), тогда как валентность требует понимания гармонического контекста, который акустическими признаками передаётся хуже.

§ 1.4. Классификация жанров

Классификация музыкальных жанров как задача машинного обучения берёт начало в работе Tzanetakis и Cook 2002 года [36], где вместе с самой постановкой был предложен и датасет GTZAN: 1000 фрагментов длительностью 30 секунд, по 100 на каждый из десяти жанров. Несмотря на известные методологические претензии к нему (повторяющиеся артисты, размытость отдельных стилей) [32], GTZAN до сих пор используется как референсная точка сопоставимости, поэтому он был выбран и в данной работе в качестве основного датасета жанровой задачи. Среди альтернатив можно назвать FMA [11], MagnaTagATune [10] и Million Song Dataset [34]. С известным ограничением (любая обученная на GTZAN модель будет плохо работать на современной музыке) в прототипе применяется мягкая стратегия: пользователю показывается распределение вероятностей по топ-3 жанрам, а не один жёсткий вердикт (см. §6.3).

Эволюцию точности на GTZAN можно проследить по табл. 1.2: от 61% у первоначальной модели MFCC+SVM до 89% у современного AST. Наша лучшая модель (CNN v2) достигает 83.9%, AST v2 чуть ниже, на 81.5%. Обе цифры находятся внутри коридора однозадачных систем, что для мультизадачной модели можно считать удачным результатом.

Таблица 1.2. Эволюция точности на GTZAN

Архитектура	Год	Accuracy	Источник
MFCC + SVM	2002	61%	Tzanetakis [36]
CNN baseline	2015	75%	Sigtia [29]
CRNN	2017	79%	Choi [6]
Multi-DNN ensemble	2018	82%	Sturm [32]
PANNs (CNN14)	2020	87%	Kong [27]
AST	2021	89%	Gong [15]

§ 1.5. Архитектуры аудио-классификаторов

Среди архитектур, конкурирующих сейчас в задачах аудио-классификации, выделяются несколько семейств. Старшее по возрасту и самое массовое из них образуют свёрточные нейронные сети. Типовая модель состоит из нескольких последовательных свёрточных блоков, в каждом из которых стоит двумерная свёртка с ядром 3×3 , пакетная нормализация (batch normalization, BN), функция активации ReLU и слой подвыборки по максимуму с окном 2×2 . После всех блоков делается глобальное усреднение по пространственным размерностям, превращающее карту признаков в один вектор фиксированной длины. Модели подобного класса обычно содержат порядка миллиона параметров и обучаются за 3–5 часов на одной видеокарте. У них два главных недостатка: узкое рецептивное поле (около 5–10 секунд звукового материала) и отсутствие предобучения на больших корпусах. В данной работе свёрточная сеть из пяти блоков с числом каналов от 32 до 512 используется как базовый вариант, её устройство подробно разобрано в §4.2.

Поверх такой базовой свёртки нередко надстраивают дополнительные модули. Один из самых полезных в практике, особенно для аудио, это блок канального внимания «сжатие-возбуждение» (Squeeze-and-Excitation, SE) [20]. Идея простая: после каждого свёрточного блока сеть смотрит на собственные активации, сворачивает их по пространству глобальным усреднением, пропускает через маленькую двухслойную сеть с сигмоидой и получает вектор весов по каналам, на который активации затем поэлементно домножаются. Прирост качества от SE-модулей в среднем составляет 1–3 процентных пункта при увеличении числа параметров на 5–10 %.

Чтобы учесть долгосрочный временной контекст, поверх покадровых эмбеддингов свёрточной сети ставят рекуррентный слой. Чаще всего это двунаправленная LSTM (BiLSTM) [18]: она проходит по последовательности эмбеддингов вперёд и назад, сохраняя информацию обо всём треке. Расплата за это, однако, серьёзная: вместо обучающих примеров по отдельным окнам сеть видит уже всю композицию целиком, что сокращает эффективный размер выборки в десятки раз и резко повышает риск переобучения. В данной работе BiLSTM используется в двух конфигурациях (CNN+BiLSTM и PANNs+BiLSTM, см. §5.4), и обе они проявляют именно эту проблему.

Другой рассмотренный в работе путь состоит в использовании предобученного аудио-энкодера. Набор моделей PANNs (Pretrained Audio Neural Networks) [27] объединяет несколько свёрточных сетей, обученных на датасете

AudioSet (около 2 миллионов фрагментов с разметкой по 527 категориям звуковых событий). Самая известная модель из серии, CNN14, по 1-секундному окну возвращает эмбединг размерности 2048, который можно использовать как готовое представление, не дообучая сам энкодер. Это резко удешевляет эксперименты: один раз посчитав эмбединги для всех треков, обучать поверх них голову уже можно за минуты.

Audio Spectrogram Transformer (AST) [15] появился последним из всех рассмотренных подходов и оказался наиболее перспективным для задач, требующих глобального восприятия трека. Идея AST состоит в чистом переносе подхода Vision Transformer [3] с изображений на спектрограммы. Матрица $\log\text{-mel}$ размером $128 \times T$ разрезается на патчи 16×16 (с перекрытием в 6 точек), каждый патч проецируется линейным слоем в 768-мерный токен. К последовательности добавляются обучаемый служебный токен CLS и позиционные эмбединги, после чего всё это пропускается через 12 слоёв трансформера с 12 головами внимания в каждом. Финальная классификация ведётся по CLS-токену с выхода последнего слоя. Общее число параметров составляет около 87 миллионов, чекпоинт занимает 574 МБ против 21 МБ у используемой в работе CNN, время инференса на одном треке порядка 8 секунд против 2. Зато AST предобучен на AudioSet (в работе используется версия MIT/ast-finetuned-audioset-10-10-0.4593) и обладает глобальным рецептивным полем по всему треку, что особенно ценно именно для структурной сегментации. В данной работе AST применяется с заморозкой первых 8 слоёв из 12, подробное описание схемы дообучения дано в §4.5.

§ 1.6. Multi-task learning в MIR

Идея мультизадачного обучения (multi-task learning, MTL) [5] состоит в том, чтобы одна модель решала сразу несколько связанных задач через общий ствол. Применительно к MIR такая постановка естественна: задачи структуры, эмоций и жанра содержательно связаны между собой. Жанр во многом определяет типичные структурные паттерны (классический рок строится из куплета и припева, классическая симфония разворачивается по совсем другой схеме). Эмоциональная динамика обычно согласована со структурой: припев чаще всего громче и активнее куплета. Общий ствол при этом работает на каждую из задач и одновременно регулирует сам себя, поскольку градиенты от одной задачи мешают модели слишком сильно подстраиваться под другую.

На уровне реализации мультизадачное обучение можно организовать по-разному. Самый простой способ это объединять потери всех задач в одну взвешенную сумму $L = \sum w_i L_i$ и обновлять параметры по этой сумме. Другой популярный приём, особенно при разнородных датасетах, это карусельная схема (англ. round-robin batching): на каждом шаге батч берётся из одного датасета по очереди, а градиент течёт только через те головы, к которым в этом батче есть метки. Более сложные подходы (вроде gradient surgery) пытаются разрешать конфликты между градиентами разных задач явно. В данной работе выбрана именно карусельная схема: используемые датасеты не пересекаются по разметке (трек DEAM не размечен жанром, трек GTZAN не размечен по структуре и так далее). Веса задач в общей потере подобраны по валидации, для сегментации они равны 1.5, для всех остальных голов 1.0.

§ 1.7. Предварительное обучение и дообучение

При работе с предобученной моделью вроде AST приходится аккуратно подбирать процедуру дообучения, иначе можно либо переобучиться под небольшой целевой датасет, либо потерять знания, накопленные на этапе предварительного обучения. Это явление получило в литературе название катастрофического забывания (англ. catastrophic forgetting). На практике хорошо работают три приёма. Дифференциальная скорость обучения, при которой параметры ствола обновляются с очень маленьким темпом (порядка 10^{-5}), а параметры голов на пару порядков быстрее, защищает от резких изменений общих признаков. Заморозка нижних слоёв, в которых обычно закодированы наиболее общие признаки, дополнительно стабилизирует обучение и заметно сокращает число обучаемых параметров. Накопление градиента по нескольким батчам позволяет работать с большими эффективными батчами даже на скромной видеокарте: AST обучается с физическим батчем 16 и накоплением за 4 шага, что даёт эффективные 64 примера на шаг.

Все три приёма вместе дают нетривиальный эффект. AST с заморозкой 8 из 12 слоёв и дифференциальной скоростью обучения за 3 часа на одной видеокарте обходит базовую свёрточную модель по точности структурной сегментации на 5,3 процентных пункта (детальное сравнение приведено в §5.4).

Глава 2

Постановка задачи

§ 2.1. Цель исследования

Цель работы — создать прототип программно-аналитической системы автоматического анализа музыкальных композиций, которая по входному аудиотреку формирует многоаспектную временную разметку (англ. timeline) сразу по четырём категориям признаков. Структурная сегментация выделяет шесть классов музыкальной формы (Intro, Verse, Bridge, Chorus, Instrumental, Outro). Возбуждение (arousal) представлено тремя категориями уровня энергии (Low, Mid, High). Валентность (valence) аналогично имеет три класса эмоциональной окраски (Dark, Neutral, Bright). Жанр выбирается из десяти стандартных категорий GTZAN: blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock.

В отличие от специализированных решений вроде Madmom, Essentia или MIRtoolbox [9; 21; 23], которые решают каждую задачу отдельной моделью, в данной работе все четыре задачи решаются одной мультизадачной моделью. У такого подхода несколько содержательных преимуществ. Структурные границы вычисляются на тех же признаках, что и эмоциональные переходы, поэтому смена секции и смена эмоции не смещаются друг относительно друга. За один проход модели формируются все четыре разметки сразу, без четырёхкратного перерасчёта эмбедингов. Наконец, единая модель открывает возможность согласованной интерпретации результатов в прототипе (§6.2).

§ 2.1.1. Формальная постановка

Пусть $x \in \mathbb{R}^{T_{\text{audio}}}$ моноаудиосигнал с частотой дискретизации $sr = 22050$ Гц. Извлечение признаков переводит его в последовательность лог-мел окон $X = \{X_1, \dots, X_N\}$, $X_i \in \mathbb{R}^{F \times W}$, где $F = 128$ — число мел-фильтров, а W — число STFT-фреймов в окне длительностью $\tau = 10$ с. Для конфигурации librosa с центрированием окон (`center=True`) и шагом $h = 512$ число фреймов определяется как

$$W = 1 + \left\lfloor \frac{sr \cdot \tau}{h} \right\rfloor = 1 + \left\lfloor \frac{22050 \cdot 10}{512} \right\rfloor = 431.$$

Модель f_θ выдаёт для каждого окна четыре распределения вероятностей:

$$f_\theta(X_i) = (p_i^{\text{seg}}, p_i^{\text{aro}}, p_i^{\text{val}}, p_i^{\text{gen}}),$$

где $p_i^{\text{seg}} \in \Delta^5$, $p_i^{\text{aro}}, p_i^{\text{val}} \in \Delta^2$, $p_i^{\text{gen}} \in \Delta^9$. Здесь $\Delta^k = \{y \in \mathbb{R}_+^{k+1} : \sum_j y_j = 1\}$ — стандартный k -мерный вероятностный симплекс, то есть распределение по $k + 1$ классам. Соответственно Δ^5 задаёт распределение по 6 классам сегментации, Δ^2 — по 3 классам возбуждения и валентности, Δ^9 — по 10 жанрам. Постобработка g далее преобразует покадровые предсказания в непрерывные интервалы:

$$g(\{p_i\}_{i=1}^N) \mapsto \{(t_j^{\text{start}}, t_j^{\text{end}}, c_j, \kappa_j)\}_{j=1}^M,$$

где c_j — класс сегмента, κ_j — степень уверенности модели, M — итоговое число сегментов после слияния. Конкретная реализация g (декодирование Витерби с позиционными априорными распределениями и слиянием коротких сегментов по минимальной длительности) описывается в §4.7.

§ 2.2. Исследовательские вопросы

Исследование строилось вокруг пяти вопросов.

Прежде всего, исследовалась жизнеспособность самого мультизадачного подхода: насколько эффективна мультизадачная свёрточная сеть для одновременного решения четырёх задач на относительно небольшом объёме данных (около 2,5 тысяч треков) и сопоставимо ли её качество с однозадачными моделями из литературы?

Далее изучался вклад двух независимых факторов в качество модели. Один из них это временное моделирование с помощью BiLSTM поверх покадровых эмбеддингов свёрточной сети: насколько такое усложнение архитектуры оправдано, особенно для структурной сегментации, которая по природе своей требует учёта длинного контекста. Другой фактор это качество входных признаков: даёт ли использование предобученных эмбеддингов PANNs CNN14 (обученных на AudioSet) преимущество перед свёрточной сетью, обученной с нуля на тех же целевых данных.

Следующий вопрос обобщал предыдущие и спрашивал, какой из этих двух факторов важнее и являются ли их эффекты аддитивными или интерактивными.

Наконец, отдельный вопрос был сформулирован уже после первых экспериментов: способна ли архитектура AST, тоже предобученная на AudioSet, но устроенная принципиально иначе (трансформер с самовниманием вместо свёрток), превзойти оба ранее рассмотренных семейства? И если да, то на каких именно задачах преимущество максимально?

Первые четыре вопроса формируют классический 2×2 факторный эксперимент с четырьмя конфигурациями: CNN per-window, CNN+BiLSTM, PANNs+Linear, PANNs+BiLSTM. Последний вопрос расширяет схему пятой архитектурой (AST). Дополнительно в работу включён ablation-эксперимент по постобработке предсказаний (с декодером Витерби и без, с позиционными априорными распределениями и без).

§ 2.3. Обоснование мультизадачного подхода

Выбор единой мультизадачной модели обусловлен содержательными, методологическими и практическими факторами, каждый из которых сам по себе является достаточным основанием для отказа от схемы из четырёх независимых моделей.

Прежде всего, выбранные задачи в музыке тесно связаны содержательно. Жанр во многом определяет типичную структуру композиции: рок строится из чередования куплета и припева, симфония подчинена сонатной форме, электронная музыка опирается на схему build-up и drop. Эмоциональная динамика обычно согласована со структурой: переход от куплета к припеву чаще всего сопровождается ростом возбуждения и сменой валентности. Жанр коррелирует и с типичной эмоциональной окраской: металл чаще оказывается

в квадранте «злобное-активное», классика в «умиротворённое-спокойное», блюз в «грустное-спокойное». Эти связи модели проще выучивать совместно, чем порознь.

Второй довод методологический. Общий ствол сети при мультизадачном обучении вынужден извлекать максимально универсальные признаки (тембр, ритм, гармония), полезные сразу для всех голов. Это работает как регуляризатор и снижает риск переобучения на признаки, специфические для какой-то одной задачи. Полученные метрики качества в целом сопоставимы с диапазоном опубликованных однозадачных результатов для GTZAN, DEAM и Harmonix Set (см. сопоставление со state-of-the-art в §7.4).

К ним добавляется и чисто практическая сторона дела. Если запускать четыре отдельные модели последовательно на одном треке, время инференса вырастает в четыре раза (порядка 32 секунд против 8 на трёхминутный трек на использованной видеокарте). Четыре независимые модели могут давать и несогласованные предсказания: граница секции от одной модели не совпадает с моментом эмоционального перехода от другой. Развёртывание приходится поддерживать сразу для четырёх чекпоинтов. Единая мультизадачная модель эти проблемы снимает, что особенно важно для интерактивного веб-прототипа (Глава 6).

Глава 3

Данные

В работе используются три открытых датасета, каждый из которых исторически специализировался под одну из решаемых задач: DEAM для эмоций, Harmonix Set для структурной разметки и GTZAN для жанровой классификации. Объединение трёх таких разнородных корпусов в общем мультизадачном пайплайне требует унифицированной предобработки и аккуратных сплитов. Оба вопроса разбираются в этой главе.

§ 3.1. Используемые датасеты

Сводная информация о датасетах приведена в табл. 3.1.

Таблица 3.1. Используемые датасеты

Датасет	Размер	Аудио	Аннотации	Задача	Источник
DEAM	1802 фрагмента (45 с каждый)	mp3	Покадровые непрерывные arousal/valence	Эмоции	MediaEval 2013–2018 [2]
Harmonix Set	912 треков (полная длительность)	mp3 (за- гружено 743)	Структурная разметка с временными метками	Сегментация	Nieto и соавт., 2019 [33]
GTZAN	999 фрагментов (30 с каждый)	wav	Жанровая метка целиком на трек	Жанр	Tzanetakis & Cook, 2002 [36]
Итого	3713 уникальных файлов	≈ 110 ГБ	извлечённых признаков	4 задачи	

DEAM [2] это один из крупнейших открытых датасетов для распознавания музыкальных эмоций, собранный в рамках конкурсов MediaEval с 2013 по

2018 годы. Корпус включает 1802 фрагмента по 45 секунд из коллекции Free Music Archive (лицензия Creative Commons). Для каждого фрагмента собрана непрерывная покадровая разметка возбуждения и валентности по краудсорсингу: около десяти аннотаторов на трек с шагом 500 миллисекунд. Поставляется он в виде нескольких CSV: усреднённые ряды по 60 фреймам, стандартные отклонения как оценка согласия аннотаторов и общие метаданные. В данной работе непрерывные значения дискретизируются в три категории по порогам ± 0.2 : значения ниже -0.2 относятся к классу Low (или Dark для валентности), от -0.2 до $+0.2$ к классу Mid (Neutral), выше $+0.2$ к High (Bright). Пороги выбирались так, чтобы получить приблизительно равномерное распределение классов (25–40 % на класс) и при этом сохранить семантическую осмысленность границ; разбиение по квантилям такой осмысленности не давало.

Harmonix Set [33] это единственный крупный открытый корпус со структурной разметкой коммерческой популярной музыки. Всего в нём 912 треков, для которых вручную в Sonic Visualiser размечены позиции долей, сильных долей и границы секций. На этапе планирования рассматривались также SALAMI и Beatles, но первый смещён в сторону классики и джаза (что плохо согласовалось с двумя другими задачами работы, ориентированными на поп-сцену), а второй слишком мал по объёму. Из всей разметки Harmonix используются только секции. Авторская таксономия включает 17 категорий, что для шестиклассовой постановки избыточно: они сведены к шести базовым меткам. Все вступления (intro, intro_a, intro_b) сливаются в Intro; куплеты и темы (verse, verse_a, verse_b, theme) в Verse; переходы и переходные секции (bridge, transition, transition_a) в Bridge; припевы и хуки (chorus, chorus_a, hook) в Chorus; инструменталы, соло и брейкдауны в Instrumental; концовки и затухания в Outro. Сами аудиозаписи Harmonix Set по понятным причинам не распространяет. Для их скачивания в рамках работы реализован отдельный скрипт (scripts/download_harmonix_audio.py), который по полю youtube_id из аннотации загружает аудио через yt-dlp. Из 912 треков успешно загрузилось 743 (около 81.5%). Остальные за прошедшие годы удалены с YouTube правообладателями.

GTZAN [36] в работе используется в стандартном виде: 999 рабочих файлов (один оригинальный wav оказался повреждён) разбиты на десять жанров по сто примеров в каждом, длительность одного фрагмента 30 секунд. Жанры стандартные для бенчмарка: blues, classical, country, disco, hip-hop, jazz, metal, pop, reggae, rock. Известные проблемы GTZAN не игнорируются [32]: около 5 %

файлов представляют собой дубликаты или near-duplicates, у части примеров спорная разметка, есть выраженный artist bias и общая устаревшая таксономия. Несмотря на это, GTZAN сохранён как основной датасет жанровой задачи, поскольку он остаётся единственным практическим способом сопоставимости с двадцатилетней литературой по теме. Поведение модели на современной музыке дополнительно смягчается стратегией top-3 в прототипе (§6.3).

§ 3.2. Извлечение признаков

Все три датасета унифицируются на этапе извлечения признаков. Из mp3 или wav librosa загружает моноаудио с частотой дискретизации 22050 Гц, после чего считается логарифмическая мел-спектрограмма со стандартными для задач классификации музыки параметрами: 128 мел-фильтров в диапазоне от 30 Гц до частоты Найквиста (11025 Гц), окно STFT в 2048 отсчётов (около 93 миллисекунд) и шаг между фреймами 512 отсчётов (около 23 миллисекунд). Полученные значения мощности логарифмируются через librosa.power_to_db(ref=np.max), что переводит спектрограмму в шкалу примерно от −80 до 0 децибел.

Полученные спектрограммы сохраняются в файлах формата prz и далее уже не пересчитываются: при каждой эпохе обучения готовые массивы просто читаются с диска. Для скорости это критично. Без такого кэша из-за стоимости декодирования mp3 каждая эпоха стоила быкратно дороже.

Параметры подытожены в табл. 3.2.

Таблица 3.2. Параметры логарифмической мел-спектрограммы

Параметр	Значение	Обоснование
Sample rate	22050 Гц	Стандарт librosa, покрывает до 11025 Гц
n_fft	2048	STFT окно около 93 мс
hop_length	512	Шаг между фреймами около 23 мс
n_mels	128	Стандарт для классификации музыки
fmin	30 Гц	Нижняя граница мел-фильтров
fmax	11025 Гц	Частота Найквиста

Затем спектрограмма каждого трека режется на окна одинаковой длитель-

ности. В работе используются окна по 10 секунд (431 спектральный фрейм при выбранных параметрах) с шагом 1 секунда между соседними окнами. Длительность 10 секунд выбрана по двум причинам. Первая: этого хватает на типичный музыкальный период (куплет или припев целиком), что критично для структурной задачи. Вторая: AST предобучен ровно на десятисекундных окнах AudioSet, и сохранение этой длительности позволяет использовать предобученные позиционные эмбединги без интерполяции. Шаг в одну секунду даёт около пятидесяти окон на минуту записи, чего более чем достаточно для последующего декодирования Витерби.

Сразу после нарезки выполняется глобальная нормализация. По обучающему сплиту вычисляются средние значения и стандартные отклонения отдельно по каждой мел-полосе, сохраняются в `stats.npz`, а далее применяются ко всем сплитам: на каждом окне из каждого мел-фильтра вычитается соответствующее среднее и делится на стандартное отклонение. Тот же `stats.npz` используется и при инференсе пользовательских аудиозаписей: `musicml/infer.py` загружает его автоматически. Без этого шага на инференсе наблюдался характерный сбой: блюзовая запись с высокой долей низких частот ошибочно распознавалась как `hip-hop` из-за того, что её распределение энергии по фильтрам оказывалось сдвинуто относительно нормализованного обучающего распределения.

§ 3.3. Стратегия разбиения на обучающую, валидационную и тестовую выборки

Каждый из трёх датасетов разбивается независимо в соотношении 70/15/15 с фиксированным сидом 42. Главное принципиальное решение здесь, ради которого пришлось аккуратно реализовать сплитер, состоит в том, что разбиение делается на уровне треков, а не на уровне окон. Если резать окна и распределять их случайно, окна одного и того же трека неизбежно попадают и в обучающую, и в тестовую выборки, что искусственно завышает метрики обобщения.

Для GTZAN стратификация по жанрам делается автоматически (по сто треков на каждый из десяти классов). Для DEAM стратификация по эмоциональным классам невозможна в принципе: метки покадровые и непрерывные, а разные фрагменты одного трека вполне могут оказаться в разных классах

после квантизации, поэтому используется случайное разбиение. Harmonix тоже разбивается случайно: жанровая информация в нём отсутствует, а стратифицировать по структуре бессмысленно, поскольку все треки покрывают все секции. Списки треков каждого сплита сохраняются в splits.json для воспроизводимости любого запуска.

§ 3.4. Дисбаланс классов

Из четырёх рассматриваемых задач три (возбуждение, валентность, жанр) сбалансированы практически по построению или близки к этому, и для них специальной обработки не требуется. Иначе обстоит дело со структурной сегментацией, где классы распределены сильно неравномерно: куплет и припев в сумме занимают около 60% общего времени обучающих треков, тогда как на концовку приходится меньше 10%. Распределение классов сведено в табл. 3.3.

Таблица 3.3. Распределение классов в обучающих сплитах

Задача	Класс	Доля окон	Вес inverse-frequency
Segment	Verse	~35%	0.71
	Chorus	~25%	1.00
	Bridge	~12%	2.08
	Intro	~10%	2.50 (обрезан)
	Instrumental	~10%	2.50 (обрезан)
	Outro	~8%	2.50 (обрезан)
Arousal	Low / Mid /	~33% / 34% /	≈ 1.00 каждый
	High	33%	
Valence	Dark /	~33% / 33% /	≈ 1.00 каждый
	Neutral /	34%	
	Bright		
Genre	любой из 10	~10%	≈ 1.00 каждый
	жанров	каждый	

Без специальной обработки дисбаланса модель склонна к вырожденному решению с преимущественным предсказанием доминирующих классов. Чтобы этого избежать, в работе применяются сразу три механизма, действующие

на разных уровнях. На уровне функции потерь применяется focal loss [12] с показателем $\gamma = 1.5$: множитель $(1 - p_t)^\gamma$ уменьшает вклад тех примеров, по которым модель уже уверена и обычно права, перенаправляя градиент на трудные случаи. На уровне отдельных классов используются веса, обратно пропорциональные частотам, но с верхним порогом 2.5. Без такого порога редкие классы получали бы слишком большой вес и провоцировали обратную проблему. Наконец, на уровне общей мультizaдачной потери головам сегментации присваивается дополнительный вес 1.5, тогда как остальным задачам по 1.0.

Эмпирически эти три ограничения находятся в довольно узком оптимуме. В одном из экспериментов (CNN v3, см. §5.5) была проверена гипотеза об одновременном усилении всех трёх механизмов: вес головы сегментации до 3.5, γ до 2.5, верхний порог весов классов до 3.5. Модель в результате переобучилась на редкие классы и потеряла около 13 процентных пунктов на сегментной задаче. Эта неудача стала одним из главных аргументов в пользу того, что в задаче компенсации дисбаланса дальнейшее усиление веса редких классов приводит к обратному переобучению.

Глава 4

Архитектура и методы

В работе исследуется пять архитектур мультизадачного анализа аудио, различающихся по трём осям: способу извлечения покадровых признаков (свёрточная сеть, обученная с нуля, против предобученной PANNs CNN14 против AST), способу учёта временного контекста (по отдельному окну против рекуррентного слоя поверх последовательности окон) и парадигме переноса (без предобучения, замороженный энкодер, частичное дообучение). Все пять архитектур имеют одинаковый интерфейс выхода: четыре классификационные головы (сегментация, возбуждение, валентность, жанр) и две регрессионные головы для непрерывных значений возбуждения и валентности. В качестве финальной модели прототипа выбрана AST v2 с декодированием Витерби поверх предсказаний сегментной головы.

§ 4.1. Обзор многоархитектурного эксперимента

Сводное сравнение пяти архитектур приведено в табл. [4.1](#).

Первые четыре конфигурации образуют классический 2×2 факторный план для ответа на RQ1-RQ4, заданные в §2.2. Пятая конфигурация (AST) была добавлена позднее, после первой серии экспериментов, в качестве ответа на RQ5 и в итоге дала лучший средний результат, поэтому именно она оказалась развёрнута в прототипе.

Таблица 4.1. Сравнение пяти исследованных архитектур

#	Конфиг.	Backbone	Temporal	Pretraining	Парам.	Trainable
1	CNN	5-блочная CNN с SE	per-window	нет	~800K	~800K
2	CNN+BiLSTM	CNN → BiLSTM(128)	sequence	нет	~1.2M	~1.2M
3	PANNs+Linear	PANNs CNN14	per-window	AudioSet (frozen)	~80M	~210K
4	PANNs+BiLSTM	PANNs → Proj → BiLSTM(256)	sequence	AudioSet (frozen)	~81M	~750K
5	AST v2	ViT	per-window (global attn)	AudioSet (с дообучением)	~87M	~14M

§ 4.2. Свёрточная сеть (конфигурация 1)

Базовая свёрточная сеть принимает на вход тензор формы $(B, 1, 128, T)$, где B размер батча, 128 число мел-полос, T временная размерность окна. Внутри стоят пять последовательных свёрточных блоков с увеличивающимся числом каналов 32, 64, 128, 256, 512. Каждый блок устроен одинаково: двумерная свёртка с ядром 3×3 , пакетная нормализация, активация ReLU, модуль канального внимания «сжатие-возбуждение» и слой подвыборки по максимуму с окном 2×2 . После всех пяти блоков следует глобальное усреднение по пространственным размерностям, дающее 512-мерный вектор. На него надстраивается общий полносвязный слой $512 \rightarrow 256$ с пакетной нормализацией, активацией ReLU и дропаутом 0.4, после чего идут четыре независимые классификационные головы (на 6, 3, 3 и 10 классов соответственно). Всего в модели около 800 тысяч параметров.

Модуль канального внимания [20] устроен совсем просто. Он берёт на вход карту признаков размерности (C, H, W) , сворачивает её по пространственным размерностям глобальным усреднением до вектора длины C , пропускает этот вектор через двухслойную сеть с понижением размерности в 16 раз посередине и сигмодой на выходе, получает вектор «весов» каналов и поэлементно умножает на него исходную карту. Семантически это позволяет сети для каждой задачи выделять разные каналы как более или менее важные. Для аудио такой механизм особенно ценен, поскольку разные задачи (структура, эмоции, жанр) ожидают разную важность от низкочастотного и высокочастотного содержимого.

Общий полносвязный слой $512 \rightarrow 256$ перед головами заметно улучшил

обобщение, в первую очередь за счёт того, что он создаёт согласованное 256-мерное представление, к которому могут «обращаться» сразу все головы. Без него каждая голова работала бы напрямую с 512-мерным выходом GAP, что вело к более жёсткой специализации каналов под одну задачу и худшей трансферабельности.

§ 4.3. CNN с надстройкой BiLSTM (конфигурация 2)

Над покадровыми эмбедингами свёрточной сети надстраивается рекуррентный слой. Трёхминутный трек, нарезанный окнами 10 с с шагом 1 с, даёт примерно 180 эмбедингов по 512 чисел каждый. Эта последовательность подаётся в двунаправленную LSTM с 128 скрытыми единицами и двумя слоями, затем выходы концов проходят через полносвязный слой на 256 и попадают в те же четыре головы. Дополнительных параметров получается порядка 400 тысяч.

Выбор именно BiLSTM, а не трансформера, объясняется размерами обучающей выборки: после агрегации по трекам Harmonix даёт всего 522 последовательности на обучение, чего трансформеру попросту мало. LSTM в таких условиях оказывается более устойчивой, хотя, как видно из §5.4, и она склонна к переобучению на этом объёме данных.

§ 4.4. Конфигурации поверх замороженной PANNs (3 и 4)

Третья и четвёртая конфигурации используют предобученную PANNs CNN14 [27] как замороженный экстрактор признаков. На одно секундное окно аудио модель возвращает 2048-мерный эмбединг. Эти эмбединги один раз вычисляются для всех треков и кэшируются, после чего обучение голов сводится к довольно быстрой работе (порядка восьми–двенадцати минут на полную эпоху).

В простой конфигурации (PANNs+Linear) каждый 2048-мерный вектор сразу подаётся в четыре линейные головы. Число обучаемых параметров при этом около 210 тысяч. В более сложной (PANNs+BiLSTM) перед головами сто-

ит линейная проекция $2048 \rightarrow 512$ и двунаправленная LSTM на 256 скрытых единиц, что добавляет около 540 тысяч обучаемых параметров.

Заморозка свёрточного ствола выбрана сознательно. Полное размораживание PANNs угрожает катастрофическим забыванием признаков, выученных на AudioSet. Промежуточные варианты с разморозкой только верхних блоков на используемых в работе данных не давали заметного выигрыша, зато существенно усложняли пайплайн и не позволяли кэшировать эмбединги один раз.

§ 4.5. Audio Spectrogram Transformer v2 (конфигурация 5, финальная)

В качестве финальной модели в работе используется дообученный AST [15] на основе чекпоинта MIT/ast-finetuned-audioset-10-10-0.4593. Эта конфигурация показала лучший средний результат среди всех пяти (§5.5) и развёрнута в прототипе.

Базовое устройство AST повторяет идею Vision Transformer [3]. Лог-мел спектрограмма размера $128 \times T$ режется на патчи 16×16 со сдвигом в 10 точек (что даёт перекрытие в 6 точек по каждой оси), и каждый патч линейным слоем проецируется в 768-мерный токен. К полученной последовательности добавляется обучаемый классификационный токен CLS и обучаемые позиционные эмбединги. Полученная последовательность токенов проходит через 12 слоёв трансформера, в каждом из которых стоит многоголовое самовнимание с 12 головами и размером головы 64, а также классический полносвязный блок с расширением $768 \rightarrow 3072 \rightarrow 768$ и нелинейностью GELU. С выхода последнего слоя берётся итоговое представление токена CLS, которое и подаётся в четыре наши головы. Всего в модели около 87 миллионов параметров.

Чекпоинт предобучен на AudioSet [4]: около 2 миллионов десятисекундных фрагментов с YouTube, размеченных по 527 категориям звуковых событий. Опубликованный mean average precision на этом датасете 45.9%, сам файл весов занимает 574 МБ.

Стратегия дообучения построена следующим образом. Полностью замораживаются эмбедрер патчей, позиционные эмбединги и первые восемь из двенадцати трансформерных слоёв. Дообучаются только верхние четыре слоя вместе с относящимися к ним LayerNorm, токен CLS и все четыре головы.

Это даёт около 14 миллионов обучаемых параметров. Граница в четыре верхних слоя выбрана не из теоретических соображений, а эмпирически: были проверены оба крайних случая. При полной заморозке всех двенадцати слоёв модель работает не лучше, чем PANNs+Linear (то есть трансфер работает только до уровня feature extractor); при разморозке сразу всех слоёв модель переобучается уже за 2–3 эпохи, поскольку AudioSet и используемые в работе данные различаются по распределению. После нескольких промежуточных запусков (две, четыре и шесть размороженных слоёв) оптимум оказался ровно на четырёх.

Скорости обучения для разных частей сети сделаны разными. Параметры размороженных трансформерных слоёв обновляются с темпом $5 \cdot 10^{-5}$, тогда как параметры голов и токена CLS с темпом 10^{-3} , в двадцать раз быстрее. Эта схема соответствует подходу ULMFiT [19] и защищает уже накопленные веса AudioSet от слишком резких изменений на целевых данных, одновременно позволяя головам быстро подстроиться под новые задачи.

Чтобы вместить AST в память 12-гигабайтной видеокарты, применяется накопление градиента: физический батч равен 16, обновление параметров делается раз в 4 шага, что даёт эффективный батч 64. Полное обучение AST на объединённой обучающей выборке занимает около трёх часов.

§ 4.6. Мультизадачные головы и функция потерь

Все классификационные головы устроены одинаково: один линейный слой из D -мерного представления в K -мерные логиты с последующим softmax, где $D = 256$ для свёрточных конфигураций и $D = 768$ для AST, а K это число классов конкретной задачи. Дополнительно к двум классификационным головам для возбуждения и валентности добавлены регрессионные головы вида $\text{Linear}(D \rightarrow 1) \rightarrow \text{sigmoid}$, дающие непрерывную оценку в $[0, 1]$. Регрессионные оценки в прототипе используются только для визуализации кривых. Основной вклад этих задач в потерю идёт через классификационные головы.

В качестве функции потерь для каждой классификационной задачи используется focal loss [12]:

$$\mathcal{L}_{\text{FL}}(p_t) = -\alpha_t \cdot (1 - p_t)^\gamma \cdot \log(p_t),$$

где p_t предсказанная вероятность правильного класса, α_t вес класса, γ по-

казатель «фокуса». Значение $\gamma = 1.5$ оказалось эмпирически оптимальным. Первая версия с $\gamma = 2.0$ давала катастрофический recall куплета (около 10%) из-за слишком агрессивного фокуса.

Веса классов считаются как $w_c = \min(N_{\text{total}}/(K \cdot N_c), w_{\text{max}})$ с порогом $w_{\text{max}} = 2.5$. Без верхнего порога редкие классы получали бы веса до 6–7 и провоцировали обратное переобучение. Значение 2.5 близко к эмпирическому ориентиру $\sqrt{\text{ratio}_{\text{max}}/\text{ratio}_{\text{min}}} \approx 2.2$.

Общая мультизадачная потеря складывается с разными весами для разных задач:

$$\mathcal{L}_{\text{total}} = 1.5 \cdot \mathcal{L}_{\text{seg}} + \mathcal{L}_{\text{aro}} + \mathcal{L}_{\text{val}} + \mathcal{L}_{\text{gen}} + 0.5 \cdot (\mathcal{L}_{\text{aro_reg}} + \mathcal{L}_{\text{val_reg}}).$$

Дополнительный вес 1.5 для сегментации компенсирует её малый вклад в общий градиент: она и так одна из четырёх классификационных задач, причём самая сложная. Половинный вес для регрессионных голов не даёт MSE задавить более информативные классификационные сигналы.

В качестве оптимизатора используется AdamW [22] с базовой скоростью обучения 10^{-3} и весовым штрафом $5 \cdot 10^{-4}$. Расписание скорости обучения это CosineAnnealingWarmRestarts с начальным циклом 10 эпох и удвоением длины цикла на каждом следующем рестарте. Для AST расписание то же, но с двумя различающимися базовыми скоростями (см. §4.5).

Для регуляризации в обучение добавлены две стандартные техники. SpecAugment [30] случайно маскирует фрагменты лог-мел спектрограммы по частоте (полосы шириной до 27 мел-фильтров) и по времени (полосы шириной до 60 фреймов), что заставляет модель не опираться на конкретные узкие частотные полосы. MixUp [25] с вероятностью 0.5 и параметром распределения Beta(0.2, 0.2) смешивает пары обучающих примеров вместе с их метками, что улучшает калибровку и устойчивость к шуму в разметке.

§ 4.7. Постобработка предсказаний сегментной ГОЛОВЫ

Сырые покадровые предсказания сегментной головы содержат локальные всплески (одионые кадры, выбившиеся из общего сегмента) и нарушают типичные музыкальные априорные ограничения (вступление в середине трека, две концовки подряд и тому подобное). Чтобы получить из них пригодный

для интерфейса timeline, применяется постобработка из нескольких этапов. Первая версия декодера состояла из трёх ступеней: декодирование Витерби с штрафом за смену метки, добавление позиционных priоров и слияние коротких сегментов. Вторая версия (декодер v2) расширила эту схему до шести механизмов, и именно она используется в прототипе.

В классической формулировке Витерби [14] ищется последовательность меток, максимизирующая сумму логарифмов вероятностей под штрафом за каждую смену метки:

$$\hat{c}_{1:T} = \arg \max_{c_{1:T}} \sum_{t=1}^T [\log P(c_t | X_t) + \pi_t(c_t)] - \lambda \sum_{t=2}^T \mathbb{I}[c_t \neq c_{t-1}],$$

где $\pi_t(c)$ позиционный prior (вклад того, насколько метка c вообще ожидается в позиции t), а λ скалярный штраф за смену метки. Эмпирически оптимальным оказалось $\lambda = 1.0$: при $\lambda = 0.5$ остаются всплески в одиночные кадры, при $\lambda = 2.5$ соседние сегменты склеиваются вопреки явным акустическим различиям.

Позиционные priоры устроены просто. Мы знаем, что почти все вступления в Harmonix Set приходятся на первые 22% длительности трека, а концовки на последние. Отсюда разумная эвристика: штрафовать предсказание Intro за пределами первой границы и Outro за пределами последней. В первой версии декодера это делалось через жёсткий штраф -10 для меток в запрещённых зонах. Граница 22% и величина штрафа 10 находятся в литературном диапазоне (5–15 у разных авторов) [16; 26; 37].

Итеративное слияние коротких сегментов работает в самом конце: каждый сегмент короче шести секунд (для первой версии декодера) сливается с соседом по большей частоте, и процедура повторяется до стабильности.

Декодер v2 (decode_segment_head_v2) родился из наблюдений за тем, как ведёт себя первая версия на реальных пользовательских треках. Самые частые претензии были две: на длинных блюзовых треках получалось до 22 сегментов, потому что модель путалась между Verse и Instrumental, а в середине трека периодически возникал «фантомный» Intro. Шесть механизмов второй версии устроены так. Temperature scaling с температурой $T = 1.4$ применяется к логитам сегментной головы до softmax, что слегка расширяет динамический диапазон распределения и даёт позиционным priорам реальный вес (в первой версии распределение было слишком резкое, и priоры почти не работали). Скалярный штраф λ за смену метки заменён несимметричной матрицей переходов $K \times K$ (табл. 4.2), которая отражает реальные музыкальные ограничения: переход вступления в куплет почти бесплатный, обратный

переход куплета во вступление крайне маловероятный, переход концовки в куплет фактически запрещён.

Таблица 4.2. Несимметричная матрица переходов декодера v2 (стоимость в логарифмическом масштабе)

Переход	Стоимость	Обоснование
Intro → Verse	0.0	Стандартный ход формы
Chorus → Verse	0.0	Типичная фигура «припев-куплет»
Verse → Intro	4.0	Музыкально неестественно
Bridge → Intro	5.0	Практически не встречается
Outro → Verse	8.0	Запрещено
Все остальные	2.0	Базовый штраф за смену

Позиционные приоры в v2 усилены: штраф увеличен до 14, граничная доля сужена до 12%, а в разрешённых зонах для Intro и Outro добавлен лёгкий положительный бонус +1.0 (boost). Минимальная длительность сегмента теперь задаётся отдельно для каждого класса (табл. 4.3): куплет и припев не могут быть короче 12–15 секунд (минимальная длительность двенадцатитактного блюза порядка 24 секунд), концовка и вступление допустимы и в пять секунд. После окончания основной декодирующей процедуры дополнительно выполняется novelty snapping: каждая найденная граница сдвигается к ближайшему локальному максимуму кривой новизны (вычисленной как L_2 -норма разности соседних кадров) в радиусе двух секунд, что даёт акустически более осмысленные границы. Наконец, repetition consistency проверяет схожесть представлений между сегментами: если центроиды двух фрагментов с разными метками имеют косинусную близость выше 0.82, они перемаркируются в одну общую метку (предпочтительно Chorus, как более частую).

Таблица 4.3. Минимальные длительности сегментов в декодере v2

Класс	Min duration	Обоснование
Intro	5 с	Может быть коротким
Verse	15 с	Куплет не меньше 12-тактного блюза (≈ 24 с)
Bridge	8 с	Пре-хорус бывает коротким
Chorus	12 с	Припев обычно длинный
Instrumental	15 с	Соло и проигрыш длинные
Outro	5 с	Может быть и затухание

На референсном треке The Thrill Is Gone (медленный блюз длительностью около семи минут) число выдаваемых сегментов после перехода к декодеру v2 упало с 22 до 5, при этом ни одного сегмента короче четырёх секунд, а граница между куплетом и финальным проигрышем заметно ближе к реальной. Количественное сравнение приведено в табл. 4.4, полный ablation отдельных механизмов декодера разбирается в §5.8.

Таблица 4.4. Эффект отдельных этапов постобработки (Harmonix Set, тестовая выборка)

Метод	Сегментов Boundary F1		Section F1
Argmax (без постобработки)	28.4	0.31	0.32
+ Median filter (kernel=5)	14.2	0.36	0.34
+ Viterbi ($\lambda = 1.0$)	9.8	0.42	0.37
+ Position priors (penalty = 10)	8.7	0.43	0.38
+ Min-duration merge (6 с)	7.5	0.45	0.39

§ 4.8. Инференс на пользовательских записях

Пайплайн инференса на произвольной пользовательской записи устроен типично. Сначала librosa загружает аудио и приводит его к моно с частотой дискретизации 22050 Гц. Затем считается логарифмическая мел-спектрограмма с теми же параметрами, что и при обучении (128 фильтров, 30–11025 Гц). После этого подгружается stats.npz с обучающими средними и стандартными отклонениями, и спектрограмма нормализуется. Нормализованная спектрограмма режется на десятисекундные окна с шагом одна секунда, по каждому окну модель выдаёт четыре распределения, и пакет всех окон передаётся в постобработку (для сегментной задачи декодер Витерби v2, для эмоций и жанра просто сглаживание медианным фильтром). Итоговая разметка сохраняется в JSON и отдаётся на веб-фронтенд.

Один момент в этом пайплайне потребовал отдельного внимания. На раннем этапе разработки наблюдался характерный эффект: пользовательский блюзовый трек, на котором CNN при обучении показывала отличный результат, на инференсе классифицировался как hip-hop с уверенностью 80 %. Причина оказалась в нормализации: stats.npz забывал подгружаться в musicml/infer.py:extract_features(), и спектрограммы шли в модель в исходной шкале, чьё распределение энергии по фильтрам отличается от обучающего настолько, что для модели это был фактически другой домен. После того как загрузка stats.npz стала автоматической, поведение модели восстановилось.

Глава 5

Эксперименты

В работе проведено четыре последовательных эксперимента. Первый служил базовой проверкой работоспособности 2×2 факторного плана из §2.2 на исходных гиперпараметрах (v1). Второй уже учитывал диагностические выводы первого и был выполнен с усовершенствованной конфигурацией (v2). Третий расширил линейку пятой архитектурой (AST v2). Четвёртый эксперимент задумывался как ещё одно усиление CNN, но оказался неудачным и в работу включён как академически ценный negative result. Сверх этого выполнен отдельный ablation по постобработке предсказаний сегментной головы (§5.8).

§ 5.1. Протокол оценки

Качество модели оценивается стандартными для классификации метриками: accuracy, macro-F1 и поклассовые precision, recall, F1. Для структурной сегментации дополнительно считается Boundary F1 с допуском ± 3 секунды. Это стандартная MIR-метрика, оценивающая, насколько правильно модель находит сами моменты переходов между секциями, безотносительно того, как она их маркирует.

Все три датасета разбиты на 70/15/15 (обучающую, валидационную и тестовую выборки) с зафиксированным сидом 42 (см. §3.3). Размеры тестовых сплитов после нарезки окон: примерно 11.6 тысяч окон у DEAM, 23.4 тысяч у Harmonix и 3.2 тысяч у GTZAN. Оценка делается один раз по чекпоинту с лучшей валидационной потерей, без подгонки порогов под тест.

В качестве точки отсчёта используется случайная базовая модель, выдающая равномерное распределение по классам. Для рассматриваемых задач это

даёт 16,7 % по сегментной шестиклассовой задаче, 33,3 % для возбуждения и валентности и 10 % по жанру.

Все метрики приводятся по одному запуску с фиксированным сидом 42. Из-за стоимости полного обучения (около трёх часов на AST v2 и порядка часа на каждую из остальных конфигураций) в рамках данной работы не проводилась оценка статистической значимости различий между моделями: не вычислялись доверительные интервалы методом bootstrap по трекам, не проводилось повторных запусков с разными начальными сидами, не рассчитывалось стандартное отклонение метрик. В связи с этим небольшие различия в метриках (порядка 1–2 процентных пункта) следует интерпретировать с осторожностью, а полноценная количественная проверка значимости различий вынесена в направления дальнейшей работы (см. §7.3).

§ 5.2. Гиперпараметры обучения

Базовая конфигурация v2 для всех архитектур, кроме AST, сведена в табл. 5.1. Конфигурация AST отличается дифференциальными скоростями обучения и накоплением градиента и подробно описана в §4.5.

Таблица 5.1. Гиперпараметры обучения (v2)

Параметр	Значение
Оптимизатор	AdamW, lr=1.0e-3, weight_decay=5.0e-4
Размер батча / эпохи / patience	64 / 50 / 15
Расписание скорости обучения	CosineAnnealingWarmRestarts (T_0=10, T_mult=2)
Функция потерь	Focal Loss, $\gamma = 1.5$, max_class_weight=2.5
MixUp α	0.2 (per-window), 0.0 (BiLSTM)
Длина окна / шаг	10.0 c / 1.0 c
SpecAugment	freq_mask=27, time_mask=60, n_masks=2
Dropout	0.4
Весы задач в общей потере	seg:1.5, aro_cls:1.0, val_cls:1.0, gen:1.0, *_reg:0.5

§ 5.3. Эксперимент v1: исходный 2×2 запуск

Первая серия экспериментов прошла с базовой конфигурацией: четыре свёрточных блока (без пятого), 30 эпох обучения, расписание OneCycleLR, focal loss с $\gamma = 2.0$, верхний порог весов классов 4.0 и окно длиной 8 секунд. Результаты приведены в табл. 5.2.

Таблица 5.2. Результаты 2×2 эксперимента в конфигурации v1

Конфигурация	Segment acc/F1	Arousal acc/F1	Valence acc/F1	Genre acc/F1
CNN	24.3 / 23.1	65.9 / 65.3	55.8 / 53.4	82.7 / 81.9
per-window				
CNN+BiLSTM	25.9 / 26.8	53.0 / 51.8	49.5 / 48.4	45.5 / 42.5
PANNs+Linear	23.2 / 20.5	60.9 / 61.4	54.3 / 52.7	81.6 / 81.2
PANNs+BiLSTM	31.4 / 31.5	62.8 / 62.9	55.9 / 56.0	81.0 / 80.5

Первое же сравнение с базовой случайной линией показало, что все четыре конфигурации существенно выше случайного выбора, а самым слабым звеном везде оказалась структурная сегментация. Чтобы понять источник плохого качества, были рассмотрены поклассовые метрики CNN, на которой сегментная задача показала наихудшие результаты; распределение precision и recall по шести классам оказалось типичным для агрессивной компенсации дисбаланса. Самые частые классы Verse и Chorus имели высокую precision (порядка 70%), но катастрофически низкий recall (10% и 18% соответственно). Редкие классы Intro, Bridge и Instrumental, наоборот, оказались сильно переопределены: модель ставила их везде, где сомневалась, что давало им recall выше 50% при precision ниже 30%. Концовка проседала по обеим осям (precision 4%, recall 14%). Поклассовое сравнение v1 и v2 на сегментной задаче приведено ниже в табл. 5.4. Для краткости отдельная таблица только для v1 опущена.

Главным виновником был выбран чрезмерно высокий верхний порог весов классов `max_class_weight=4.0`, давший редким классам слишком большое влияние. Отдельно бросилось в глаза катастрофическое падение жанра у CNN+BiLSTM до 45.5% (явное переобучение на 699 трёхминутных треках GTZAN, которые после агрегации по последовательностям дают слишком мало обучающих примеров для BiLSTM).

Тепловая карта факторного дизайна (рис. 5.1) наглядно показывает, как два фактора плана (временное моделирование и качество признаков) проявились на v1.




Рис. 5.1. Тепловая карта 2×2 факторного дизайна v1: временное моделирование по горизонтали, качество признаков по вертикали.

§ 5.4. Эксперимент v2: улучшенный запуск

На основе диагностики v1 в конфигурацию v2 была внесена серия изменений. Главные из них: добавлен пятый свёрточный блок с SE-модулем (для увеличения ёмкости), окно увеличено с 8 до 10 секунд, focal γ снижен с 2.0 до 1.5, верхний порог весов классов уменьшен с 4.0 до 2.5, вес сегментной задачи в общей потере поднят с 1.0 до 1.5, обучение продлено до 50 эпох с patience 15, расписание скорости заменено с OneCycleLR на CosineAnnealingWarmRestarts, дополнительно введён временной джиттер ± 1.0 с для устойчивости к границам сегментов. Запуск проводился единым прогоном, без отдельного анализа эффекта каждого изменения; общая ablation отдельных компонентов потери в работу не вошла из-за стоимости полного обучения. Полные результаты v2 приведены в табл. 5.3.

Таблица 5.3. Результаты 2×2 эксперимента в конфигурации v2

Конфигурация	Segment acc/F1	Arousal acc/F1	Valence acc/F1	Genre acc/F1
CNN	35.3 / 29.5	62.0 / 61.0	51.7 / 51.1	83.9 / 83.3
per-window				
CNN+BiLSTM	32.2 / 31.6	62.3 / 62.4	54.2 / 53.3	60.9 / 62.0
PANNs+Linear	24.0 / 21.7	61.2 / 61.6	53.8 / 53.3	81.9 / 81.4
PANNs+BiLSTM	32.9 / 32.7	64.9 / 64.0	55.0 / 53.0	77.7 / 77.9

Дельты относительно v1 распределились по архитектурам по-разному. CNN per-window получил +11.0/+6.4 п.п. на сегменте, заплатив за это −3.9

на возбуждении и -4.1 на валентности. CNN+BiLSTM прибавил $+6.3$ на сегменте, $+9.3$ на возбуждении и заметные $+15.4$ на жанре (то есть наконец оправился от переобучения v1). PANNs+Linear практически не сдвинулся, все дельты в пределах ± 1.5 п.п. PANNs+BiLSTM прибавил $+1.5$ на сегменте и $+2.1$ на возбуждении, но потерял -3.3 на жанре.

Главное улучшение, ради которого и затевался переход к v2, действительно случилось: CNN прибавила 11 процентных пунктов по точности сегментной задачи, recall куплета вырос с 10 до 28%, припева с 18 до 40%. Конфигурация CNN+BiLSTM выровнялась и стала более конкурентной: рост на жанре $+15$ процентных пунктов означает, что переобучение на 699 треках GTZAN частично снято за счёт более жёсткого расписания обучения и более мягкой схемы взвешивания классов. Цена за приоритизацию сегмента просматривается тоже отчётливо: CNN потеряла около четырёх процентных пунктов на эмоциях, потому что её градиенты теперь сильнее тянуло в сторону структурной задачи.

Сводное поклассовое сравнение для CNN v1 против v2 на сегментной задаче приведено в табл. 5.4. Главный сдвиг здесь приходится на куплет и припев: распознавание самых частых и практически важных классов восстановилось.

Таблица 5.4. Поклассовое сравнение сегментной задачи для CNN v1 и v2

Класс	v1 P/R/F1	v2 P/R/F1	Δ Recall
Intro	28.9 / 64.2 / 39.8	34.1 / 59.8 / 43.4	-4.4
Verse	68.9 / 10.1 / 17.6	52.1 / 27.9 / 36.4	$+17.8$
Bridge	19.2 / 51.5 / 28.0	17.3 / 39.8 / 24.1	-11.7
Chorus	70.9 / 18.4 / 29.2	53.5 / 40.3 / 46.0	$+21.9$
Instrumental	10.0 / 62.5 / 17.3	16.5 / 29.4 / 21.1	-33.1
Outro	4.1 / 14.4 / 6.4	6.2 / 5.9 / 6.0	-8.5

Результаты v2 позволяют дать предварительные ответы на первые четыре исследовательских вопроса. Одна модель действительно справляется со всеми четырьмя задачами одновременно: жанр у CNN v2 достиг 83.9%, что

укладывается в диапазон современных однозадачных моделей для GTZAN. Вклад BiLSTM на мультизадачной модели оказался неоднозначным: эмоции он действительно улучшает, но жанровую задачу у CNN+BiLSTM серьёзно подкашивает за счёт критически малой обучающей выборки в последовательностной формулировке. Замороженные PANNs не дают принципиального преимущества перед свёрткой, обученной с нуля, и это, в общем-то, ожидаемо: AudioSet ориентирован на разметку звуковых событий, а не музыкальной формы. И, наконец, ни временное моделирование, ни качество входных признаков по отдельности не оказались решающим фактором. Реальный прорыв принесла совершенно другая ось — переход на трансформерную архитектуру.

§ 5.5. Эксперимент AST v2: расширение трансформер-архитектурой

После того как стало понятно, что в рамках 2×2 факторного плана дальнейшие улучшения ограничены, эксперимент был расширен пятой архитектурой. AST [15] был выбран потому, что одновременно даёт глобальное рецептивное поле (важно для структурной задачи) и богатую инициализацию весов от AudioSet (важно для общего качества). Конфигурация AST v2 описана в §4.5 и кратко повторяется тут: чекпоинт MIT/ast-finetuned-audioset-10-10-0.4593, около 87 миллионов параметров, из которых обучается порядка 14 миллионов (верхние 4 трансформерных слоя, LayerNorm, CLS, головы), дифференциальная скорость обучения и накопление градиента. Обучение заняло порядка трёх часов на 12-гигабайтной видеокарте.

Сводные метрики AST v2 на тестовых сплитах и сравнение с лучшей не-трансформерной моделью (CNN v2) приведены в табл. 5.5.

Таблица 5.5. Результаты AST v2 на тестовых выборках

Задача	Accuracy	Macro-F1	Δ к CNN v2 (по accuracy)
Segment	40.6	30.8	+5.3 п.п.
Arousal	60.6	60.4	−1.4 п.п.
Valence	51.1	50.4	−0.6 п.п.
Genre	81.5	80.8	−2.4 п.п.
Среднее	58.5	55.6	+0.3 п.п.

Таблица 5.6. Поклассовые метрики сегментной задачи для AST v2

Класс	Precision	Recall	F1
Intro	31.0	50.0	38.3
Verse	51.0	45.7	48.2
Bridge	20.1	22.9	21.4
Chorus	48.2	45.6	46.9
Instrumental	26.6	23.4	24.9
Outro	4.5	6.1	5.2

Ответ на пятый исследовательский вопрос получился содержательным. AST действительно превзошёл лучшую свёрточную модель именно там, где это было важнее всего: структурная сегментация улучшилась на 5,3 процентных пункта. Главный источник прироста виден из поклассовых метрик AST v2 (табл. 5.6). Recall на куплете и припеве у AST сбалансированы заметно лучше: 45,7 % против 27,9 % у CNN на куплете, 45,6 % против 40,3 % на припеве. Глобальное рецептивное поле помогает модели увидеть всю композицию целиком, а предобучение на AudioSet даёт стартовое представление о низкоуровневых акустических признаках, которое сложно выучить с нуля на 522 структурных треках.

Качество остаётся существенно неравномерным по классам. AST v2 уверенно различает крупные и частые секции (Verse F1 = 48,2, Chorus F1 = 46,9), но плохо справляется с редкими и акустически размытыми классами: Bridge F1 = 21,4, Instrumental F1 = 24,9, Outro F1 = 5,2. Концовка по-прежнему распознаётся хуже всего и фактически на уровне случайной модели, что отражает сочетание малой представленности класса в обучающих данных и

его акустической близости к Verse и Instrumental. На задаче жанра AST уступает CNN v2 на 2.4 процентных пункта. Скорее всего, для десятиклассовой классификации на коротких 30-секундных фрагментах GTZAN inductive bias свёртки оказался эффективнее. С точки зрения практической развёртки за это улучшение приходится заплатить: AST занимает в памяти около 574 МБ против 21 МБ у CNN, а инференс на одном треке требует примерно в четыре раза больше времени.

§ 5.6. Эксперимент CNN v3: неудачное усиление

После того как стало понятно, что AST v2 выигрывает на сегментной задаче за счёт глобального контекста, была проверена гипотеза: возможно, CNN v2 также можно немного улучшить на сегментной задаче за счёт тройного усиления компенсаций дисбаланса. Вес головы сегментации был повышен с 1.5 до 3.5, показатель focal loss с 1.5 до 2.5, верхний порог весов классов с 2.5 до 3.5. Результаты получились прямо противоположные ожиданиям: на сегменте ассигасу обвалилась на 13.2 процентных пункта (с 35.3 до 22.1), жанр упал на 4.8 пункта (с 83.9 до 79.1), и только эмоциональные задачи получили скромный прирост +2.5/+2.4. Среднее по четырём задачам ушло вниз на 3.3 процентных пункта (полные числа CNN v3 включены в сводную табл. 5.7 строкой 7).

Разбор поведения модели показал быстрое переобучение: лучший валидационный лосс достигнут уже на четвёртой эпохе, early stopping сработал на девятнадцатой. После применения верхнего порога 3.5 веса классов сегментной задачи приняли вид [Intro:3.05, Verse:0.44, Chorus:0.62, Bridge:3.5, Instrumental:3.5, Outro:3.5], то есть редкие классы получили в шесть-восемь раз больший вклад в потерю, чем доминирующие. В результате модель сместилась в сторону чрезмерного предсказания редких классов настолько, что метрики по самым частым (Verse, Chorus) ухудшились вместе с общей точностью примерно на 13 процентных пунктов.

Этот эксперимент включён в работу сознательно как аккуратный поставленный отрицательный результат (negative result), демонстрирующий следующее: для свёрточной архитектуры рассматриваемых размеров на используемых данных конфигурация v2 уже находится близко к локальному оптимуму компенсаций дисбаланса, и дальнейшее усиление приводит к ухудшению.

Принципиальное улучшение сегментной задачи на этом этапе оказывается достижимо не за счёт тонкой настройки потери, а за счёт смены архитектуры (что и сделано в AST v2).

§ 5.7. Сводное сравнение всех моделей

Итоговое сравнение всех семи экспериментальных конфигураций приведено в табл. 5.7. Колонка «Параметров» для предобученных моделей (3–6) указывает только обучаемую часть.

Таблица 5.7. Финальное сравнение всех конфигураций по тестовым метрикам, ассигасу в %

#	Модель	Параметров	Segment	Arousal	Valence	Genre	Среднее
1	CNN v1	~400K	24.3	65.9	55.8	82.7	57.2
2	CNN v2	~800K	35.3	62.0	51.7	83.9	58.2
3	CNN+BiLSTM v2	~1.2M	32.2	62.3	54.2	60.9	52.4
4	PANNs+Linear v2	~210K	24.0	61.2	53.8	81.9	55.2
5	PANNs+BiLSTM v2	~750K	32.9	64.9	55.0	77.7	57.6
6	AST v2	~14M	40.6	60.6	51.1	81.5	58.5
7	CNN v3 (failed)	~800K	22.1	64.5	54.1	79.1	54.9

Победители по задачам распределились следующим образом. На структурной сегментации лидирует AST v2 с 40.6% точности. По эмоциональным задачам максимальные числа показывает PANNs+BiLSTM (arousal 64.9%, valence 55.0%). Это совпадает с известным наблюдением, что для предсказания эмоции хорошо работает сочетание сильных аудио-признаков AudioSet с временным контекстом всей композиции. По жанру лидирует CNN v2 (83.9%). На коротких 30-секундных фрагментах GTZAN inductive bias свёртки оказывается эффективнее самовнимания. По среднему результату по всем четырём задачам AST v2 опережает CNN v2 минимально, на 0,3 процентных пункта (58,5 % против 58,2 %), что находится в пределах статистической погрешности. Выбор AST v2 как финальной модели прототипа оправдан прежде всего наибольшим качеством по структурной сегментации, которая является приоритетной задачей системы; для сценариев с приоритетом жанровой или эмоциональной классификации более уместными выбраны бы CNN v2 или PANNs+BiLSTM соответственно.




Рис. 5.2. Сравнение пяти архитектур по четырём задачам (v2 + AST v2).

§ 5.8. Ablation: вклад постобработки
сегментной головы

Для оценки вклада постобработки выполнен отдельный ablation на тестовом сплите Harmonix Set с предсказаниями AST v2 (табл. 5.8). Каждая строка добавляет один механизм поверх предыдущей.

Таблица 5.8. Ablation постобработки на тестовой выборке Harmonix Set

Метод	Сегментов (в среднем)	Boundary F1 ±3 с	Section F1
Argmax (без постобработки)	28.4	0.31	0.32
+ Median filter (kernel=5)	14.2	0.36	0.34
+ Viterbi ($\lambda = 1.0$)	9.8	0.42	0.37
+ Position priors (penalty=10)	8.7	0.43	0.38
+ Min-duration merge (6 с)	7.5	0.45	0.39

Видно, что самый большой вклад даёт переход от медианного фильтра к декодеру Витерби, что добавляет сразу 6 процентных пунктов к Boundary F1. Это и понятно: первичное сглаживание убирает только локальный шум, а Витерби уже учитывает глобальную последовательность меток с штрафом за

переходы. Полный пайплайн (Витерби с позиционными приорами и слиянием коротких сегментов по минимальной длительности) даёт суммарный прирост 14 процентных пунктов к Boundary F1 и 7 процентных пунктов к Section F1 относительно сырого `argmax`. Среднее число сегментов в трёхминутном треке снижается с 28 до 7–8, что уже укладывается в диапазон реальной разметки в Harmonix Set (среднее по корпусу 8–12 сегментов).

Глава 6

Прототип системы

Для интерактивной демонстрации возможностей разработанной мультизадачной модели реализован веб-прототип. Пользователь загружает аудиофайл (MP3, WAV, FLAC или OGG), система пропускает его через AST v2 с постобработкой v2 и отображает результат в синхронизированной информационной панели (англ. dashboard, далее также дашборд) из шести областей. На уровне развёртывания прототип устроен как трёхзвенная система: Python-сервис инференса с моделью в памяти, TypeScript-бэкенд для управления треками и метаданными и React-фронтенд.

Следует подчеркнуть статус разработанной системы. Прототип предназначен для демонстрации результатов модели и проверки сценариев взаимодействия с пользователем, а также для качественной оценки предсказаний на произвольных пользовательских треках. Промышленно готовой системой автоматической музыкальной разметки при достигнутых метриках (40,6 % по сегментации и слабое качество для редких классов) он не является; для её построения потребовались бы дальнейшее обучение на более крупных и современных датасетах, статистическая валидация качества и значительное снижение размера модели (см. §7.3).

§ 6.1. Архитектура веб-приложения

Прототип собран из трёх сервисов, связанных стандартным REST-API. Сервис инференса (FastAPI, порт 8000) держит в памяти веса AST v2 размером 574 МБ и предоставляет три endpoint: POST /analyze для полного анализа аудиофайла, POST /spectrogram для отдельного запроса мел-спектрограммы и GET /health для проверки готовности. Бэкенд (Elysia на Bun, порт 3000)

принимает запросы фронтенда, кэширует результаты анализа в JSON-файлы внутри `web/backend/data/`, хранит загруженные аудиозаписи в `uploads/` и предоставляет CRUD-эндпойнты для работы с коллекцией треков. Фронтенд (React 19 + Vite, порт 5173) реализует одностраничное приложение с двумя маршрутами: `/` для галереи треков и `/tracks/:id` для дашборда конкретного трека. Для удобства разработки все три сервиса поднимаются параллельно через Bun-скрипт `scripts/dev-all.ts`.

§ 6.2. Синхронизированный дашборд

Центральное решение прототипа на стороне интерфейса это синхронизированный дашборд из шести панелей с общим временным курсором (playhead). На раннем этапе рассматривалась более привычная раскладка «один график на страницу», однако при таком виде сравнивать структурный сегмент с эмоциональной кривой и спектрограммой можно было только мысленно, что обесценивало половину выводов мультизадачной модели. В итоге была выбрана синхронизированная сетка. При движении плеера курсор едет по всем панелям одновременно. При наведении мыши на любую из панелей курсор подсвечивается и на остальных, а клик ставит «булавку» (pinned-закладку), на которую можно вернуться.

Синхронизация реализована через React Context (DashboardContext), который хранит текущее положение playhead, hover-курсора и pinned-метки, а также флаг проигрывания. Каждая панель подписана на этот контекст и обновляется в едином цикле requestAnimationFrame на 60 кадров в секунду. Для перевода времени в пиксели и обратно используется хук useTimeScale, обёрнутый вокруг scaleLinear из d3-scale и подписанный на ResizeObserver, что позволяет панелям корректно перерисовываться при изменении ширины окна.

Шесть панелей дашборда покрывают разные аспекты анализа. Структурная панель показывает горизонтальную цветовую полосу с разметкой секций и список с временами и уверенностью предсказаний. Клик по любому сегменту перематывает плеер к его началу. Эмоциональная панель совмещает классификационные временные ряды для возбуждения и валентности с непрерывными регрессионными кривыми. Панель мел-спектрограммы рисует ту же самую матрицу 128 на T с цветовой схемой viridis, которую модель использует на входе, что помогает интерпретировать её решения. Сводная

панель агрегирует общие характеристики (круговая диаграмма сегментов, доминирующий жанр, темп и тональность через *librosa*, число структурных переходов).

Жанровая панель ориентирована на явное отображение неопределённости предсказания: распределение по трём наиболее вероятным жанрам с прогресс-барами, предупреждение при уверенности первого варианта ниже 45 % (актуально для современной электронной музыки, отсутствующей в GTZAN), отдельная временная шкала доминирующего жанра по окнам и общая диаграмма с накоплением по всем десяти классам.

Панель эмоциональной траектории отображает квадрат Расселла с четырьмя квадрантами, на котором серой линией нарисована траектория всего трека, а красной «кометой» подсвечены последние 20 секунд. Координаты для каждой точки траектории рассчитываются не из регрессионных, а из классификационных вероятностей по формуле

$$x_{\text{val}} = 0.5 + 0.5 \cdot (P(\text{Bright}) - P(\text{Dark})), \quad y_{\text{aro}} = 0.5 + 0.5 \cdot (P(\text{High}) - P(\text{Low})).$$

Регрессионные предсказания были опробованы напрямую, но оказались систематически смещены к центру: почти все треки сгущались в нижнем левом квадранте «грустное-спокойное», что искажало интерпретацию.

§ 6.3. Ключевые UX-решения

Несколько решений на стороне интерфейса заслуживают отдельного упоминания, потому что они напрямую связаны с академическими ограничениями модели и предотвращают ошибочную интерпретацию результатов пользователем.

Жанровая панель показывает три наиболее вероятных предсказания и предупреждение об уверенности для явного информирования пользователя в случаях, когда входной трек выходит за пределы обучающего распределения (см. §7.3). На современной электронике, лоу-фае, фонке и других жанрах, отсутствующих в GTZAN, модель уверенно выдаст неправильный класс. Отображение трёх вариантов и предупреждение делают эту неуверенность видимой.

Эмоциональная траектория строится по классификационным вероятностям, а не по регрессионным предсказаниям. Это устраняет систематическое смещение к центру и даёт визуально интерпретируемую траекторию по квадрантам Расселла.

Имена файлов треков в галерее приводятся к читаемому виду через DP-сегментацию (web/frontend/src/utls/displayName.ts). Файл 0375_dynamite.mp3 превращается в Dynamite, а конструкции вида genre.NNNNN из GTZAN правильно распознаются как «жанр, номер примера».

Загрузка любых тяжёлых элементов сопровождается shimmer-плейхолдерами (loading skeletons) и информативными пустыми состояниями. Это снижает воспринимаемое время отклика, особенно осязаемое на первом анализе свежезагруженного трека (около 8 секунд на инференс AST).

В верхней части галереи находится тулбар с поиском и сортировкой по нескольким полям (Recent, Название, Длительность, Жанр), без которого коллекция в 20+ треков быстро становится неудобной для навигации.

Цветовая палитра приглушённая, на базе Tableau 10 muted с двумя выделенными акцентами: синий #2563eb зарезервирован за интерактивными элементами, красный #dc2626 за положением playhead.

§ 6.4. Технологический стек

Сводка по технологическому стеку приведена в табл. 6.1.

Таблица 6.1. Технологический стек прототипа

Слой	Технология	Обоснование выбора
ML inference	Python 3.12 + PyTorch + FastAPI	Прямое использование чекпоинта обучения
Бэкенд	Bun + Elysia + TypeScript	Быстрый старт (~100 мс), нативный TypeScript
Фронтенд	React 19 + Vite + TypeScript	Стандарт индустрии, hot reload
Визуализация	d3-scale, d3-shape, d3-scale-chromatic	Лёгкие модули для scales и colormap
Стили	Plain CSS с переменными	Полный контроль над стилем
Состояние	React Context (DashboardContext)	Достаточно для прототипа

На уровне фронтенда сознательно не использовалось несколько популярных решений. Redux и Zustand оказались избыточными при имеющемся объёме общего состояния (флаги проигрывания, текущая позиция курсора и закладки). TailwindCSS не нужен для стилизации шести панелей. Готовые библиотеки графиков (Recharts, Visx) уступают по гибкости связке d3-scale и собственного canvas-рендеринга. На уровне бэкенда выбран Bun вместо Node.js из-за примерно четырёхкратной скорости старта, что критично при частых перезапусках во время разработки.

§ 6.5. Визуальный редизайн и расширения интерфейса

После первой работающей версии дашборда визуальное оформление было переработано в стилистике glassmorphism: панели стали полупрозрачными с эффектом размытия фона на тёмной подложке, поверх которой многослойными радиальными градиентами проступает «цвет настроения» трека, вычисленный из его эмоционального профиля. Типографика построена на сочетании моноширинных uppercase-меток и серифного шрифта Fraunces для заголовков.

Отдельным дополнением стал Vibe Mode, полноэкранный визуализатор на фрагментном шейдере GLSL ES 3.00, реализующий SDF raymarching тоннеля. На вход шейдеру подаётся около тринадцати uniform-переменных, обновляемых на каждом кадре: три полосы FFT, огибающие баса и общей громкости с разной инерцией, onset-детектор, текущие классификационные значения возбуждения и валентности, интенсивность сегментной задачи и пять жанровых параметров (оттенок, число рёбер, резкость, спарклы, твист). Чтение семантических данных модели учитывает задержку аудиовывода AudioContext.outputLatency в диапазоне 40–80 миллисекунд, без чего визуализация отставала бы от слышимого звука на несколько кадров.

Аудиоплеер и временная ось объединены в одну glass-карточку с фоновым waveform и монохромными маркерами сегментов, прозрачность которых пропорциональна уверенности предсказания. При наведении появляется glass-tooltip вида «T: 2:08 · ПРИПЕВ», в момент проигрывания на текущей позиции бьётся зелёный пульс. Несколько панелей дашборда получили обновления второй итерации: эмоциональный профиль обзавёлся хронологи-

чески окрашенным хвостом траектории, кривые возбуждения и валентности перешкалированы из $[-1, 1]$ в $[0, 1]$, у мел-спектрограммы появилась аулога colormap с bloom-эффектом, в жанровой панели топ-1 победитель отмечается звёздочкой.

Галерея треков превратилась в grid в стиле Apple Music и Spotify: квадратные cover-плитки с соотношением сторон 1:1, fallback-градиент по «цвету настроения», duration-chip в углу и play-overlay при наведении. Метаданные тянутся из двух источников. Из ID3-тегов аудиофайла (через prn-пакет music-metadata) извлекаются исполнитель, название и встроенная картинка APIC-фрейма. Для треков, скачанных через yt-dlp, дополнительно подгружаются uploader и thumbnail видео.

Глава 7

Анализ результатов и ограничения

В этой главе подводятся итоги по пяти исследовательским вопросам из §2.2, фиксируется итоговая конфигурация прототипа, обсуждаются основные ограничения подхода и приводится сопоставление со state-of-the-art по каждой задаче.

§ 7.1. Сводные ответы на исследовательские вопросы

Жизнеспособность мультизадачного подхода (RQ1) подтвердилась. Конфигурация CNN v2 даёт сопоставимые с однозадачными моделями результаты сразу по трём из четырёх задач: точность по жанру 83,9 % попадает в диапазон опубликованных базовых свёрточных моделей 75–87 % по литературе [6; 29], точности по возбуждению и валентности 62.0% и 51.7% оказались близки к опубликованным однозадачным результатам на DEAM [35; 40], а точность сегментной задачи 35.3% укладывается в типичный диапазон 30–45 % для шестиклассовой разметки секций [16; 39]. Главное беспокойство, которое было до экспериментов (что мультизадачное обучение приведёт к катастрофической деградации одной из задач), не оправдалось. Прямого сравнения с собственной однозадачной базовой моделью в работе не проводилось из-за ограничений вычислительного бюджета, однако сопоставление с опубликованными однозадачными результатами по литературе (§7.4) показывает, что отставание остаётся в пределах 5–8 процентных пунктов.

Что касается надстройки BiLSTM (RQ2), её эффект оказался неоднозначным. На свёрточном бэкбоне рекуррентный слой действительно помогает эмоциональным задачам (рост возбуждения и валентности на 0.3 и 2.5 процентных пункта соответственно), но катастрофически вредит жанровой за счёт переобучения: после агрегации по последовательностям 699 трёхминутных GTZAN-треков превращаются в слишком малую обучающую выборку, и модель не может выучить устойчивое представление десяти жанров. На замороженной PANNs эффект BiLSTM мягче, поскольку нижние веса не двигаются. Главным же недостатком рекуррентной надстройки на используемых данных оказывается резкое сокращение числа эффективных обучающих примеров с примерно 16 тысяч окон до примерно 500 последовательностей.

Гипотеза о преимуществе предобученных эмбедингов PANNs CNN14 (RQ3) подтвердилась с обратным знаком. PANNs+Linear проигрывает CNN v2 на трёх из четырёх задач: -11.3 процентных пункта по сегменту, -0.8 по возбуждению, -2.0 по жанру. Преимущество есть только по валентности ($+2.1$). Объяснение в общем-то простое. AudioSet ориентирован на разметку звуковых событий, а не на музыкальный структурный анализ, и замороженные эмбединги не адаптируются под новую задачу. Полноценный transfer learning из AudioSet работает только при возможности дообучения хотя бы части ствола, что и подтвердил эксперимент с AST (см. RQ5).

На вопрос о главном факторе влияния (RQ4) ответ парадоксально неоднозначный: ни один из двух заложенных в план факторов не оказался решающим. Внутри 2×2 факторного эксперимента максимальная разница между лучшей и средней конфигурациями составила всего 3–5 процентных пунктов. Реальный качественный прорыв пришёл не с какой-либо из двух ортогональных осей плана, а с третьим фактором, не входившим в исходные четыре конфигурации, то есть со сменой семейства архитектур на трансформеры (RQ5).

Эксперимент с AST (RQ5) дал положительный ответ с очевидным trade-off. AST v2 показал лучший результат на структурной сегментации (40.6% против 35.3% у CNN v2, прирост 5.3 процентных пункта) и лучший средний результат по всем четырём задачам (58.5%). Основным источником прироста именно глобальное самовнимание, способное распознавать повторяющиеся структурные паттерны куплет-припев и им подобные. На жанровой задаче AST v2 уступает CNN v2 на 2,4 процентных пункта; вероятное объяснение в том, что для десятиклассовой классификации на коротких 30-секундных GTZAN-фрагментах индуктивное смещение (inductive bias) свёрток оказывается эффективнее. Платой за это улучшение становится тридцатикратный

рост размера чекпоинта (574 МБ против 21 МБ) и примерно четырёхкратное увеличение времени инференса (8 секунд против 2 на одном трёхминутном треке).

§ 7.2. Финальная конфигурация прототипа

В качестве финальной модели прототипа выбрана AST v2 с постобработкой v2. Это решение оправдано прежде всего тем, что AST v2 показал наибольшее качество по структурной сегментации, являющейся приоритетной задачей системы. По общему среднему результату AST v2 опережает CNN v2 лишь на 0,3 процентных пункта (58,5 % против 58,2 %), что находится в пределах статистической погрешности; то есть выбор не является безусловно оптимальным для всех четырёх задач. Основные параметры финальной конфигурации сведены в табл. 7.1.

Таблица 7.1. Финальная конфигурация прототипа

Параметр	Значение
Бэкбон	MIT/ast-finetuned-audioset-10-10-0.4593
Обучаемая часть	верхние 4 трансформерных слоя, LayerNorm, CLS, 4 головы (~14М параметров)
Время инференса	8 секунд на 3-минутный трек, GPU 12 ГБ
Постобработка	декодер Витерби с матрицей переходов, $T = 1.4$
Позиционные приоры	boundary=12%, penalty=14, boost=1.0
Min duration	Verse 15 с, Chorus 12 с, Instrumental 15 с, Bridge 8 с, Intro/Outro 5 с
Дополнительно	novelty snapping, repetition consistency
Качество (Segment)	40.6% accuracy, 30.8% macro-F1, 0.45 Boundary F1 ± 3 с
Качество (Arousal)	60.6% / 60.4%
Качество (Valence)	51.1% / 50.4%
Качество (Genre)	81.5% / 80.8%

Эта конфигурация обеспечивает наилучший баланс качества при приемлемой сложности развёртывания и пригодна для интерактивной демонстрации в реальном времени.

§ 7.3. Ограничения текущего подхода

Ниже рассматриваются основные ограничения текущей реализации, разделённые на шесть содержательных групп.

Первое и самое заметное это поведение жанровой головы на современной музыке. Модель обучена на GTZAN с десятью устаревшими классами 2002 года. Жанры *electronic*, *ambient*, *lo-fi*, *phonk* и *hyperpop* в обучающей выборке не представлены вовсе. Эмпирически замечено, что электроника и *ambient* попадают в *classical* как ближайший доступный класс для не-ударного инструментального материала, а *lo-fi* уходит в *hiphop* по *drum*-паттернам. В прототипе эта проблема частично смягчена показом трёх наиболее вероятных жанров и предупреждением о низкой уверенности, однако содержательно решить её можно только дообучением на современных датасетах, например на FMA с 161 субжанром или MagnaTagATune с 188 multi-label метками.

Второе ограничение это нижний предел по структурной задаче. Точность 40.6% у AST v2 на шестиклассовой разметке секций упирается сразу в несколько причин. Классы сильно несбалансированы: *Verse* и *Chorus* в сумме занимают 60% окон *Harmonix*. Сами аннотаторы расходятся между собой примерно в 25% случаев [7]. Часть пар классов (*Verse* и *Pre-chorus*, *Intro* и *Outro*) акустически близка к неразличимой. И, наконец, есть выраженный доменный сдвиг: *Harmonix* преимущественно представляет поп 2000-х, а пользовательские треки могут быть из любой эпохи и жанра. Постобработка повышает Boundary F1 с 0.31 до 0.45, плюс 14 процентных пунктов, но фундаментальный потолок без новых данных оценивается примерно в 50%. Долгосрочное решение это добавление в обучающую выборку датасетов с другой жанровой палитрой, например SALAMI с разметкой *classical*, *jazz* и *world*.

Третье ограничение связано с размером модели и латентностью. Чекпоинт AST v2 весит 574 МБ, инференс на одном трёхминутном треке занимает порядка 8 секунд. Для мобильных приложений, *real-time*-обработки и *batch*-сценариев (порядка 2.2 часов на 1000 треков) это категорически непригодно. В прототипе предусмотрена возможность переключения на CNN v2 (21 МБ, 2 секунды) через флаг `-ckpt checkpoints/cnn_v2/best.pt` в `serve_ml.py` ценой

потери 5.3 процентных пунктов на сегменте и приобретения 2.4 на жанре. В перспективе можно применить дистилляцию AST в более компактный CNN и квантизацию весов в INT8.

Четвёртое ограничение методологическое: модель предсказывает один доминирующий жанр, тогда как реальные треки часто мульти-жанровые, например pop-rock или electronic-jazz. В прототипе это сглажено показом топ-3, но честная multi-label постановка требует другого датасета и другой функции потерь (бинарная кросс-энтропия с независимыми порогами по каждому классу).

Пятое ограничение связано с очень длинными треками (свыше восьми минут). Накопленный объём кадровых предсказаний начинает заметно влиять на интерфейс. Сама модель AST обрабатывает такие треки без проблем (память тратится постокно), но рендеринг шести панелей становится ощутимо медленнее. Тестировались треки длительностью до пяти минут включительно. Решение это либо потоковая обработка со скользящим окном, либо иерархический анализ с агрегацией предсказаний по укрупнённым интервалам.

Наконец, шестое ограничение носит методологический характер. Все приведённые в работе метрики получены по одному запуску с фиксированным сидом, без bootstrap-оценки доверительных интервалов, многократных запусков с разными начальными сидами и формальных тестов значимости различий между моделями. Из-за стоимости полного обучения такая оценка в рамках работы не проводилась, и небольшие различия в метриках (порядка 1–2 процентных пункта) следует считать ориентировочными. В качестве направления дальнейшей работы напрашиваются повторные запуски всех конфигураций с тремя–пятью разными сидами, расчёт стандартных отклонений и применение bootstrap-тестов для статистической проверки различий.

§ 7.4. Сопоставление с state-of-the-art

Сводное сравнение полученных результатов с опубликованными SOTA по каждой задаче приведено в табл. 7.2.

Таблица 7.2. Сравнение с state-of-the-art

Задача	Метрика	Наша модель	SOTA	Источник
Genre (GTZAN)	Accuracy	83.9% (CNN v2)	89%	AST [15]
Arousal (DEAM 3-clс)	Accuracy	64.9% (PANNS+LSTM)	70%	Won 2020 [40]
Valence (DEAM 3-clс)	Accuracy	55.0% (PANNS+LSTM)	60%	Won 2020 [40]
Section (Harmonix 6-clс)	Accuracy	40.6% (AST v2)	~45%	Wang 2022 [39]
Section	Boundary F1 ± 3 с	0.45 (AST v2 + postproc)	0.62	Gong 2023 [16]

В среднем полученные в работе результаты отстают от SOTA на 5–8 процентных пунктов. Причин этому несколько. Прежде всего, вычислительный бюджет: обучение проводилось на одной видеокарте 12 ГБ за три часа, тогда как опубликованные SOTA-системы обучаются на кластерах из нескольких A100 в течение недель. Кроме того, разрабатываемая модель решает четыре задачи одновременно, и типичный multi-task tax относительно однозадачной модели составляет 3–7 процентных пунктов на задачу. Используемая обучающая выборка для структурной задачи это 743 трека Harmonix, тогда как в опубликованных SOTA-системах часто используется объединение Harmonix с SALAMI, Beatles и Isophonics, что даёт суммарно три и более тысяч треков. Наконец, работа изначально планировалась как демонстрационный прототип с веб-интерфейсом, поэтому существенная часть ресурсов ушла на разработку фронтенда и серверной части, а не на чистое обучение моделей.

Тем не менее разрыв с SOTA нельзя назвать неприемлемым. По результатам проведённого обзора литературы это, по всей видимости, первая реализация мультизадачной модели для одновременного анализа структуры, эмоций и жанра в едином академически документированном прототипе с веб-интерфейсом, построенная в условиях существенных ресурсных ограничений.

§ 7.5. Научная новизна и практическая значимость

Научную новизну работы можно сформулировать в нескольких отдельных направлениях. Прежде всего, систематического сравнения пяти архитектур для мультизадачного MIR на едином датасете в проведённом обзоре литературы обнаружить не удалось. Типичные публикации сравнивают 2–3 подхода. Далее, эксперимент CNN v3 даёт документированный отрицательный результат (negative result) для агрессивного перевзвешивания. Такие результаты в академических работах обычно остаются в незаписанных лабораторных журналах, тогда как в данной работе он включён вместе с разбором причин провала. Композитный пайплайн постобработки (декодер Витерби с матрицей переходов, позиционными приорами и итеративным слиянием коротких сегментов) представлен с количественной оценкой вклада каждого компонента, что облегчает его перенос на чужие задачи. Наконец, предложен паттерн пользовательского интерфейса с явным отображением неопределённости предсказания (три наиболее вероятных жанра вместе с предупреждением о низкой уверенности) как практическое решение проблемы данных вне обучающего распределения (out-of-distribution) для классификации с заведомо устаревшей таксономией.

Практически работа значима как open-source прототип, готовый для исследовательской и учебной работы, как воспроизводимый пайплайн (все эксперименты управляются YAML-конфигами в configs/) и как демонстрационная система, которую можно развернуть и показать музыкантам, исследователям и разработчикам музыкальных приложений. Она также может служить базой для дальнейших расширений: real-time inference, мобильное развёртывание, подключение современных датасетов.

Заключение

Основные результаты

Поставленная цель достигнута. Разработан прототип системы автоматического мультизадачного анализа музыкальных композиций, который по входному аудио за один проход модели формирует структурную разметку, эмоциональный профиль и распределение по жанрам. Главный неожиданный сюрприз работы это, пожалуй, эксперимент CNN v3: гипотеза о том, что усиление компенсаций дисбаланса даст ещё прирост к сегментной задаче, не подтвердилась с обратным знаком, и именно этот провал в итоге стал аргументом для перехода к трансформерной архитектуре. По ходу работы получены следующие результаты.

Реализованы и обучены пять архитектур мультизадачных моделей: свёрточная сеть с блоками канального внимания, её надстройка двунаправленной LSTM, два варианта работы поверх замороженных эмбеддингов PANNs CNN14 и дообученный Audio Spectrogram Transformer. По ним проведены четыре последовательных эксперимента (v1, v2, AST v2 и негативный CNN v3) с единым протоколом оценки.

Лучшая по совокупности задач конфигурация AST v2 показала среднее ассигасу 58.5%, точность по структурной сегментации 40.6% (на 5.3 процентных пункта выше CNN v2), по жанру 81.5%. Эта конфигурация и развёрнута в прототипе.

Реализован композитный пайплайн постобработки сегментных предсказаний (декодер Витерби с асимметричной матрицей переходов, позиционными приорами и поклассовыми ограничениями минимальной длительности). Полный пайплайн повышает Boundary F1 на 14 процентных пунктов относительно базового аргмакса и сокращает среднее число выдаваемых сегментов с 28 до 7-8 на трёхминутный трек.

Разработан веб-прототип с трёхзвенной архитектурой (FastAPI для инфе-

ренса, Elysia на Bun для бэкенда, React с Vite для фронтенда), синхронизированным дашбордом из шести панелей и полноэкранным визуализатором Vibe Mode на основе WebGL2-шейдера, реагирующего на спектр, огибающие, onset-детектор и семантические выходы модели.

Аккуратно идентифицированы и документированы основные ограничения подхода. Жанровая голова плохо работает на современной музыке, отсутствующей в обучающем GTZAN. Шестиклассовая сегментация упирается в потолок около 50% по причинам данных и разметки. Размер AST в 574 МБ и время инференса 8 секунд на трек затрудняют развёртывание в реальном времени. И, наконец, текущая постановка не поддерживает мульти-жанровые предсказания.

Направления дальнейшей работы

Главное направление развития, способное дать наибольший прирост качества на структурной задаче, это надстройка sequence-level декодера (BiLSTM или CRF) поверх эмбеддингов AST: по литературе такая комбинация даёт ещё 10-15 процентных пунктов к Boundary F1.

Содержательно полезным расширением выглядит дообучение жанровой головы на современных датасетах FMA-medium с 161 субжанром или MagnaTagATune с 188 multi-label метками. Это снимет основную часть проблем out-of-distribution на электронной музыке.

Для практической применимости на мобильных устройствах и в real-time-сценариях имеет смысл попробовать дистилляцию знаний из AST в более компактный CNN (например, MobileViT) и квантизацию весов в INT8. Это позволит уменьшить модель в 10-20 раз без катастрофической потери качества.

Для обработки треков произвольной длительности нужна реализация потокового инференса со скользящим окном и фиксированной памятью, что особенно актуально для DJ-инструментов и live-приложений.

В перспективе интересны и более глубокие изменения парадигмы: совместное обучение с генеративными задачами, self-supervised pretraining непосредственно на музыкальных данных без AudioSet-инициализации, а также cross-modal расширения (например, привязка к текстам песен или клипам).

Список литературы

- [1] A Tutorial on Deep Learning for Music Information Retrieval / K. Choi, G. Fazekas, M. Sandler [и др.] // arXiv preprint arXiv:1709.04396. — 2017.
- [2] Aljanaki, A. Developing a benchmark for emotional analysis of music / A. Aljanaki, Y.-H. Yang, M. Soleymani // PLoS ONE. — 2017. — Т. 12, № 3. — e0173392.
- [3] An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale / A. Dosovitskiy, L. Beyer, A. Kolesnikov [и др.] // International Conference on Learning Representations (ICLR). — 2021.
- [4] AudioSet: An ontology and human-labeled dataset for audio events / J. F. Gemmeke, D. P. W. Ellis, D. Freedman [и др.] // ICASSP. — 2017. — С. 776—780.
- [5] Caruana, R. Multitask Learning / R. Caruana // Machine Learning. — 1997. — Т. 28, № 1. — С. 41—75.
- [6] Convolutional recurrent neural networks for music classification / K. Choi, G. Fazekas, M. Sandler [и др.] // ICASSP. — 2017. — С. 2392—2396.
- [7] Design and Creation of a Large-Scale Database of Structural Annotations / J. B. L. Smith, J. A. Burgoyne, I. Fujinaga [и др.] // ISMIR. — 2011.
- [8] Downie, J. S. Music Information Retrieval / J. S. Downie // Annual Review of Information Science and Technology. — 2003. — Т. 37, № 1. — С. 295—340.
- [9] ESSENTIA: an audio analysis library for music information retrieval / D. Bogdanov, N. Wack, E. Gómez [и др.] // ISMIR. — 2013. — С. 493—498.
- [10] Evaluation of algorithms using games: The case of music tagging / E. Law, K. West, M. Mandel [и др.] // ISMIR. — 2009. — С. 387—392.
- [11] FMA: A dataset for music analysis / M. Defferrard, K. Benzi, P. Vandergheynst [и др.] // ISMIR. — 2017.

-
- [12] Focal Loss for Dense Object Detection / T.-Y. Lin, P. Goyal, R. Girshick [и др.] // ICCV. — 2017. — С. 2980—2988.
 - [13] Foote, J. Automatic audio segmentation using a measure of audio novelty / J. Foote // IEEE International Conference on Multimedia and Expo (ICME). — 2000. — С. 452—455.
 - [14] Forney, G. D. The Viterbi Algorithm / G. D. Forney // Proceedings of the IEEE. — 1973. — Т. 61, № 3. — С. 268—278.
 - [15] Gong, Y. AST: Audio Spectrogram Transformer / Y. Gong, Y.-A. Chung, J. Glass // Interspeech. — 2021. — С. 571—575.
 - [16] Gong, Y. Music Structural Segmentation with Pretrained Audio Spectrogram Transformers / Y. Gong, J. Glass // ICASSP. — 2023.
 - [17] Hevner, K. Experimental studies of the elements of expression in music / K. Hevner // American Journal of Psychology. — 1936. — Т. 48, № 2. — С. 246—268.
 - [18] Hochreiter, S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // Neural Computation. — 1997. — Т. 9, № 8. — С. 1735—1780.
 - [19] Howard, J. Universal Language Model Fine-tuning for Text Classification / J. Howard, S. Ruder // ACL. — 2018. — С. 328—339.
 - [20] Hu, J. Squeeze-and-Excitation Networks / J. Hu, L. Shen, G. Sun // IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2018. — С. 7132—7141.
 - [21] Lartillot, O. MIR in Matlab (II): A Toolbox for Musical Feature Extraction from Audio / O. Lartillot, P. Toivainen // ISMIR. — 2007. — С. 127—130.
 - [22] Loshchilov, I. Decoupled Weight Decay Regularization / I. Loshchilov, F. Hutter // ICLR. — 2019.
 - [23] madmom: A new Python audio and music signal processing library / S. Böck, F. Korzeniowski, J. Schlüter [и др.] // ACM Multimedia. — 2016. — С. 1174—1178.
 - [24] McFee, B. Analyzing song structure with spectral clustering / B. McFee, D. P. W. Ellis // International Society for Music Information Retrieval Conference (ISMIR). — 2014. — С. 405—410.
 - [25] mixup: Beyond Empirical Risk Minimization / H. Zhang, M. Cisse, Y. N. Dauphin [и др.] // ICLR. — 2018.

-
- [26] Music Structure Analysis Using Convolutional Neural Networks and Hidden Markov Models / J. Serrà, M. Müller, P. Grosche [и др.] // ICASSP. — 2018.
 - [27] PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition / Q. Kong, Y. Cao, T. Iqbal [и др.] // IEEE/ACM Transactions on Audio, Speech, and Language Processing. — 2020. — Т. 28. — С. 2880—2894.
 - [28] Russell, J. A. A circumplex model of affect / J. A. Russell // Journal of Personality and Social Psychology. — 1980. — Т. 39, № 6. — С. 1161—1178.
 - [29] Sigitia, S. Improved music feature learning with deep neural networks / S. Sigitia, S. Dixon // ICASSP. — 2014. — С. 6959—6963.
 - [30] SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition / D. S. Park, W. Chan, Y. Zhang [и др.] // Interspeech. — 2019. — С. 2613—2617.
 - [31] Stevens, S. S. A scale for the measurement of the psychological magnitude pitch / S. S. Stevens, J. Volkman, E. B. Newman // The Journal of the Acoustical Society of America. — 1937. — Т. 8, № 3. — С. 185—190.
 - [32] Sturm, B. L. The state of the art ten years after a state of the art: Future research in music information retrieval / B. L. Sturm // Journal of New Music Research. — 2014. — Т. 43, № 2. — С. 147—172.
 - [33] The Harmonix Set: Beats, Downbeats, and Functional Segment Annotations of Western Popular Music / O. Nieto, M. McCallum, M. E. P. Davies [и др.] // ISMIR. — 2019. — С. 565—572.
 - [34] The Million Song Dataset / T. Bertin-Mahieux, D. P. W. Ellis, B. Whitman [и др.] // ISMIR. — 2011. — С. 591—596.
 - [35] Towards Time-Varying Music Auto-Tagging based on CAL500 Expansion / S.-Y. Wang, J.-C. Wang, Y.-H. Yang [и др.] // IEEE International Conference on Multimedia and Expo (ICME). — 2017.
 - [36] Tzanetakis, G. Musical genre classification of audio signals / G. Tzanetakis, P. Cook // IEEE Transactions on Speech and Audio Processing. — 2002. — Т. 10, № 5. — С. 293—302.
 - [37] Ullrich, K. Boundary detection in music structure analysis using convolutional neural networks / K. Ullrich, J. Schlüter, T. Grill // ISMIR. — 2014. — С. 417—422.

-
- [38] Unsupervised Music Structure Annotation by Time Series Structure Features and Segment Similarity / J. Serrà, M. Müller, P. Grosche [и др.] // IEEE Transactions on Multimedia. — 2014. — Т. 16, № 5. — С. 1229—1240.
 - [39] Wang, J.-C. To catch a chorus, verse, intro, or anything else: Analyzing a song with structural functions / J.-C. Wang, Y.-N. Hung, J. B. L. Smith // IEEE/ACM Transactions on Audio, Speech, and Language Processing. — 2022. — Т. 30.
 - [40] Won, M. Toward interpretable music tagging with self-attention / M. Won, S. Chun, X. Serra // arXiv preprint arXiv:1906.04972. — 2020.

Приложение А

Описание датасетов

Таблица А.1. Сводные характеристики используемых датасетов

Параметр	DEAM	Harmonix Set	GTZAN
Источник	MediaEval 2013–2018	Nieto et al., 2019	Tzanetakis & Cook, 2002
Размер исходный	1802 фрагмента	912 треков	1000 файлов
Использовано	1802 (все)	743 (через yt-dlp)	999
Длительность	45 с каждый	3:43 среднее	30 с каждый
Sample rate	44100 Гц → 22050	Варьируется → 22050	22050 Гц mono
Лицензия	CC (FMA)	MIT (анн.) + YouTube	Public domain
Аннотации	arousal/valence (0,5 с)	section labels (17 → 6)	genre (10 классов)
Inter-ann. agreement	$\rho_a = 0,59$; $\rho_v = 0,55$	$\sim 75\%$ section	—

Датасет DEAM используется для обучения голов arousal_cls и valence_cls (по три класса, дискретизация порогами $\pm 0,2$) и регрессионных голов.

Маппинг 17 категорий Harmonix Set в 6 базовых меток сегментов выполняется следующим образом:

intro*	-> Intro
verse*, theme	-> Verse
bridge, transition*	-> Bridge
chorus*, hook	-> Chorus
instrumental, solo	-> Instrumental
outro, fadeout	-> Outro

Жанровые метки GTZAN: blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, rock (по 100 треков на класс).

Приложение Б

Гиперпараметры экспериментов

Таблица В.1. Сводные гиперпараметры трёх конфигураций

Параметр	CNN v2	AST v2	CNN v3 (fail)
Optimizer	AdamW	AdamW	AdamW
LR	1,0e-3	5e-5 (bb) / 1e-3 (h)	1,0e-3
Weight decay	5e-4	0,01	5e-4
Batch size	64	16 (ga=4)	64
Epochs (patience)	50 (15)	30 (10)	50 (15)
Scheduler	cosine WR ($T_0 = 10$)	cosine WR	cosine WR
Loss	Focal ($\gamma = 1,5$)	Focal (1,5)	Focal (2,5)
Max class weight	2,5	2,5	3,5
Mixup α	0,2	—	0,2
Dropout	0,4	0,3	0,4
Segment loss weight	1,5	1,5	3,5
AST freeze_layers	—	8 (из 12)	—
Trainable params	~ 800 тыс.	~ 14,4 млн	~ 800 тыс.

Общие для всех конфигураций: window=10 с, hop=1 с, $n_{\text{mels}} = 128$, hop_length=512, SpecAugment (freq_mask=27, time_mask=60, $n = 2$), seed=42.

Приложение В

Confusion matrices и графики

Графические результаты сохранены в results/plots/:

- `cnn_v2/cm_{segment,arousal,valence,genre}.png` — confusion matrices CNN v2.
- `ast_v2/cm_{segment,arousal,valence,genre}.png` — confusion matrices AST v2.
- `comparison_5configs.png` — сравнение 5 архитектур по 4 задачам.
- `factorial_heatmap.png` — тепловая карта 2×2-дизайна.
- `v1_vs_v2_cnn.png` — изменения метрик $v1 \rightarrow v2$.
- `timeline_example.png`, `timeline_classical.png` — примеры инференса.

Приложение Г

JSON-схема timeline

Структура ответа `/api/tracks/:id`:

```
{
  "id": "uuid", "filename": "uuid.mp3",
  "timeline": {
    "metadata": {
      "duration_sec": 204.1,
      "window_seconds": 10.0, "hop_seconds": 1.0
    },
    "segment": [
      { "start": 0.0, "end": 8.0,
        "label": "Chorus", "confidence": 0.63 }, ...
    ],
    "arousal": [...], "valence": [...], "genre": [...],
    "frame_predictions": {
      "segment_probs": [[0.18, 0.13, ...], ...],
      "arousal_reg": [0.36, 0.38, ...],
      "valence_reg": [0.42, 0.45, ...]
    },
    "audio_features": {
      "tempo_bpm": 123.0,
      "key": { "key": "F", "mode": "Minor", "confidence": 0.78 }
    }
  }
}
```

Приложение Д

CLI-команды воспроизведения

Полный исходный код проекта (модель, пайплайн обучения, веб-прототип и автоматические тесты) опубликован в открытом репозитории GitHub: <https://github.com/mindtnv/musicml-timeline>.

```
# Source code
git clone https://github.com/mindtnv/musicml-timeline
cd musicml-timeline

# Environment
source .venv/bin/activate      # Linux/Mac
.venv/Scripts/activate        # Windows

# Data preparation
python scripts/prepare_deam.py      --data-dir data/deam
python scripts/download_harmonix_audio.py --data-dir data/structure
python scripts/prepare_structure.py --data-dir data/structure
python scripts/prepare_gtzan.py     --data-dir data/gtzan

# Training (example: final AST v2)
python scripts/train.py --config configs/ast.yaml \
    --deam-dir data/deam --structure-dir data/structure \
    --gtzan-dir data/gtzan --output-dir checkpoints/ast_v2

# Evaluation and inference
python scripts/eval.py --ckpt checkpoints/ast_v2/best.pt \
    --config configs/ast.yaml --output results/eval_ast_v2.csv \
    --deam-dir data/deam --structure-dir data/structure --gtzan-dir
    data/gtzan
python scripts/infer.py --audio path/to/song.mp3 \
    --ckpt checkpoints/ast_v2/best.pt --config configs/ast.yaml \
    --output results/timeline.json --plot results/timeline.png
```

```
# Web prototype (three services in one command)
bun run scripts/dev-all.ts    # ml-api:8000, backend:3000, frontend
                               :5173

# Tests and linter
pytest tests/ -v               # 128 tests
ruff check musicml/ scripts/ tests/
```